ENSEMBLE LEARNING PARA DIAGNOSTICO DE DOENCA CARDIACA: COMBINACAO DE SVM, KNN E RANDOM FOREST

Andre Felipe
Faculdade de Tecnologia de Guaratingueta
andressmota78@gmail.com

Resumo

Este artigo apresenta a aplicacao de tecnicas de ensemble learning para a classificacao binaria de doenca cardiaca, combinando os algoritmos K-Nearest Neighbors (KNN), Support Vector Machine (SVM) e Random Forest (RF) no Cleveland Heart Disease Dataset (UCI Machine Learning Repository, id=45). Sao explorados quatro metodos de ensemble: votacao direta (hard voting), votacao por probabilidades (soft voting), votacao ponderada e stacking com meta-learner Logistic Regression. Os resultados mostram que o soft voting supera todos os classificadores base (90,00% de acuracia vs. 85,00%-86,67% individuais), reduzindo falsos negativos de 6 para 5 e atingindo AUC-ROC de 0,9568. A validacao cruzada estratificada de 10 dobras demonstra que o stacking alcanca a melhor generalizacao (84,83% +/- 5,72%), com menor desvio padrao entre todos os modelos avaliados. A combinacao de tres paradigmas complementares — aprendizado baseado em instancias (KNN), margem maxima global (SVM) e ensemble de arvores (RF) — fundamenta teoricamente o ganho de desempenho e a reducao da variancia do ensemble.

Palavras-chave: Ensemble Learning; KNN; SVM; Random Forest; Votacao Ponderada; Stacking; Aprendizado de Maquina; Doenca Cardiaca; Classificacao Binaria.

Abstract

This paper presents the application of ensemble learning techniques for binary classification of heart disease, combining K-Nearest Neighbors (KNN), Support Vector Machine (SVM) and Random Forest (RF) algorithms on the Cleveland Heart Disease Dataset (UCI Machine Learning Repository, id=45). Four ensemble methods are explored: direct voting (hard voting), probability voting (soft voting), weighted voting, and stacking with Logistic Regression meta-learner. Results show that soft voting outperforms all base classifiers (90.00% accuracy vs. 85.00%-86.67% individually), reducing false negatives from 6 to 5 and achieving AUC-ROC of 0.9568. Stratified 10-fold cross-validation demonstrates that stacking achieves the best generalization (84.83% +/- 5.72%), with the lowest standard deviation among all models. The combination of three complementary paradigms — instance-based learning (KNN), global maximum margin (SVM), and tree ensemble (RF) — theoretically supports the observed performance gain and variance reduction.

Keywords: Ensemble Learning; KNN; SVM; Random Forest; Weighted Voting; Stacking; Machine Learning; Heart Disease; Binary Classification.

Introducao

Sistemas inteligentes para apoio ao diagnostico clinico constituem uma das aplicacoes mais impactantes da Inteligencia Artificial na area da saude (HOPGOOD, 2022). A combinacao de multiplos modelos de aprendizado de maquina — conhecida como ensemble learning — e uma das estrategias mais consolidadas para superar as limitacoes de classificadores individuais (MIENYE; SUN, 2022). A premissa central e que modelos com erros descorrelacionados, quando combinados, capturam padroes complementares que nenhum modelo individual consegue isoladamente.

No contexto do diagnostico de doenca cardiaca, tres classificadores foram previamente avaliados de forma individual no Cleveland Heart Disease Dataset (UDDIN et al., 2022): o K-Nearest Neighbors (KNN) com K=29, o Support Vector Machine (SVM) com kernel RBF e C=0,1, e o Random Forest (RF) com n_estimators=50 e max_depth=10. Os tres modelos atingiram acuracias entre 85,00% e 86,67% no conjunto de teste, com validacao cruzada de 10 dobras entre 81,51% e 83,51%. Essa equivalencia de desempenho individual motivou a investigacao de combinacoes que pudessem superar cada modelo isolado.

A escolha desses tres algoritmos para o ensemble e fundamentada em seus paradigmas epistemologicos distintos: o KNN e um lazy learner que captura vizinhancas locais no espaco de atributos; o SVM e um eager learner que constroi uma fronteira global de margem maxima entre as classes; e o RF e um ensemble de arvores de decisao que combina perspectivas hierarquicas via bagging. Esses tres mecanismos sao complementares: os erros de um modelo tendem a nao coincidir sistematicamente com os erros dos outros, criando as condicoes teoricas para que a combinacao supere cada componente individual (MIENYE; SUN, 2022).

O presente artigo tem como objetivos: (i) fundamentar matematicamente os quatro metodos de combinacao utilizados — hard voting, soft voting, votacao ponderada e stacking; (ii) descrever a metodologia de ensemble com os tres classificadores pre-treinados; (iii) apresentar e analisar os resultados — acuracia no teste, AUC-ROC, validacao cruzada e matrizes de confusao; e (iv) discutir as implicacoes clinicas da melhoria no diagnostico de doenca cardiaca.

1 Referencial Teorico

1.1 Ensemble Learning e Diversidade

Segundo Mienye e Sun (2022), o sucesso de um ensemble depende de duas condicoes necessarias: (1) acuracia individual — cada classificador base deve superar a predicao aleatoria; (2) diversidade — os classificadores devem errar em amostras diferentes, nao

nos mesmos casos sistematicamente.

A teoria de decomposicao vies-variancia-covariancia explica matematicamente o ganho do ensemble (THOMAS, 2018). Para um ensemble de M classificadores com variancia individual sigma^2 e correlacao media rho entre pares de classificadores:

*Var(ensemble) = rho * sigma^2 + (1 - rho) * sigma^2 / M*

Quando M e grande e rho e pequeno (baixa correlacao entre classificadores), a variancia do ensemble tende a zero, independentemente da variancia individual. Para o ensemble KNN+SVM+RF (M=3), a taxa de concordancia observada entre KNN e SVM e de 96,67%, enquanto o RF discorda de ambos em parte dos casos ambiguos — diferenca de paradigma suficiente para reduzir rho e beneficiar o ensemble.

1.2 Hard Voting — Votacao por Maioria

O hard voting combina as predicoes discretas dos M classificadores por voto majoritario. Para M=3 classificadores e classificacao binaria:

y_hat = argmax_c SUM_{i=1}^{3} I[h_i(x) = c]

Com M=3 (impar), o desempate nunca ocorre — ha sempre maioria estrita. Uma amostra e corretamente classificada se pelo menos 2 dos 3 classificadores acertam. Para amostras onde KNN e SVM concordam (96,67% dos casos), o RF apenas confirma ou dissente sem alterar o resultado. Nos 3,33% restantes, o RF funciona como voto de minerva. O ganho do hard voting depende de que o RF acerte exatamente quando KNN e SVM discordam — o que ocorre nos casos ambiguos onde a perspectiva de arvores captura padroes que os outros dois nao capturam.

1.3 Soft Voting — Votacao por Probabilidades

O soft voting media as probabilidades estimadas por cada classificador:

P_ens(y=c|x) = (1/M) SUM_{i=1}^{M} P_i(y=c|x)

A predicao final e: y_hat = argmax_c P_ens(y=c|x). O soft voting e superior ao hard voting quando as probabilidades sao bem calibradas, pois incorpora a confianca (margem de probabilidade) de cada classificador. Uma amostra com P_KNN=0,55 e P_SVM=0,52 para a classe Doente e mais incerta do que P_KNN=0,95 e P_SVM=0,90 — o soft voting capta essa nuance ao mediar probabilidades, enquanto o hard voting trata os dois casos identicamente.

Para o SVM, o calculo de probabilidades requer SVC(probability=True), que usa calibracao por regressao logistica sobre os scores SVM (GERON, 2019). O KNN estima probabilidades como fracao dos K=29 vizinhos de cada classe. O RF produz probabilidades como media das fracoes de folhas em cada arvore.

1.4 Soft Voting Ponderado

O soft voting ponderado atribui pesos wi a cada classificador conforme seu desempenho individual, tipicamente a acuracia de validacao cruzada:

*P_ens(y=c|x) = SUM_{i=1}^{M} w_i * P_i(y=c|x) / SUM_{i=1}^{M} w_i*

Neste trabalho, os pesos foram definidos proporcionalmente a acuracia CV 10-fold: KNN=0,35, SVM=0,40, RF=0,25. O SVM recebe maior peso por ter a maior acuracia de validacao cruzada (83,51%), enquanto o RF recebe menor peso (81,51%). A ponderacao reflete o nivel de confianca estatistica em cada classificador.

1.5 Stacking com Meta-Learner

O stacking e uma abordagem de dois niveis que aprende como combinar as predicoes dos classificadores base de forma otima:

Nivel 0 (classificadores base): KNN, SVM e RF geram meta-features — suas probabilidades para a classe Doente — para cada amostra.

Nivel 1 (meta-learner): Um novo classificador aprende a combinar essas meta-features. Formalmente, para cada amostra xi:

Z_i = [P_KNN(y=1|x_i), P_SVM(y=1|x_i), P_RF(y=1|x_i)]

y_hat = g(Z_i)

onde g e o meta-learner — neste trabalho, uma Regressao Logistica com max_iter=200. O stacking e treinado com validacao cruzada no nivel 0 (out-of-fold predictions) para evitar data leakage: as meta-features de treinamento do meta-learner sao geradas por predicoes fora da dobra de treinamento de cada classificador base.

Os coeficientes aprendidos pelo meta-learner refletem a confiabilidade relativa de cada classificador base: SVM recebeu o maior coeficiente (meta-coef = 3,23), seguido pelo KNN (meta-coef = 2,16) e RF (meta-coef = 1,87), alinhado com as acuracias individuais de CV.

1.6 Os Tres Paradigmas Complementares

A escolha de KNN, SVM e RF para o ensemble reflete tres perspectivas computacionais complementares:

KNN (Lazy Learner): nao constroi modelo explicito. Toda computacao ocorre na predicao, consultando os K=29 vizinhos mais proximos no espaco de atributos padronizado. Captura padroes locais e e interpretavel (a decisao e justificada pelos 29 pacientes mais similares no conjunto de treino).

SVM (Eager Learner): constroi representacao global da fronteira de decisao maximizando a margem geometrica entre as classes. Robusto a outliers — apenas vetores de suporte

influenciam o hiperplano. Predicao em O(n_sv x d), eficiente mesmo com muitos dados de treino.

RF (Ensemble de Arvores): combina 50 arvores de decisao via bagging e random subspace method. Fornece importancia de variaveis, nao requer normalizacao e e robusto a outliers pela media de multiplas arvores. Perspectiva hierarquica: divisoes por limiares em variaveis individuais.

Essa diversidade de mecanismos garante correlacao baixa entre os erros dos tres modelos — condicao teorica para que o ensemble supere cada componente individual (MIENYE; SUN, 2022).

2 Metodologia

2.1 Conjunto de Dados e Pre-processamento

O estudo utiliza o Cleveland Heart Disease Dataset, disponivel no UCI Machine Learning Repository (id=45). O dataset original contem 303 registros com 13 atributos preditores. Apos remocao de 6 registros com valores ausentes, restaram 297 registros validos. A variavel alvo foi binarizada: y=0 (Saudavel, valores originais 0) e y=1 (Doente, valores 1 a 4), resultando em 160 saudaveis e 137 doentes.

O dataset foi particionado com estratificacao: 237 amostras para treino (80%) e 60 para teste (20%), mantendo a proporcao de classes em ambas as particoes. O reconhecimento de padroes em dados clinicos multivariados requer pre-processamento criterioso para garantir a qualidade dos modelos (GIRALDI, 2021). Para o KNN e SVM, os 13 atributos foram padronizados com StandardScaler (mu e sigma calculados apenas sobre X_train). Para o RF, nenhuma normalizacao foi aplicada.

2.2 Configuracao dos Classificadores Base

Os tres classificadores base foram otimizados individualmente por GridSearchCV em trabalhos anteriores, e re-treinados com os hiperparametros otimos para compor o ensemble:

Tabela 1 – Configuracao dos Classificadores Base

Classificador	Hiperparametros otimos	Acuracia CV 10-fold	Acuracia Teste
KNN	K=29, metrica=euclidiana, pesos=uniforme	82,86% +/-6,99%	86,67%
SVM	C=0,1, kernel=RBF, gamma=scale	83,51% +/-7,66%	86,67%
RF	n_estimators=50, max_depth=10	81,51% +/-6,13%	85,00%

Fonte: elaborado pelo autor (2026).

2.3 Configuracao dos Metodos de Ensemble

Quatro variantes de ensemble foram implementadas e avaliadas:

Hard Voting: VotingClassifier(voting='hard') com KNN, SVM e RF. Cada modelo vota com a classe predita; maioria de 2 em 3 decide.

Soft Voting: VotingClassifier(voting='soft') com SVC(probability=True). Media simples das probabilidades estimadas pelos tres modelos.

Soft Voting Ponderado: VotingClassifier(voting='soft', weights=[0.35, 0.40, 0.25]) — pesos proporcionais a acuracia CV individual (KNN, SVM, RF).

Stacking: StackingClassifier com meta-learner Logistic Regression(max_iter=200). As meta-features (probabilidades dos classificadores base) sao geradas por cross_val_predict(cv=5) para evitar data leakage.

2.4 Protocolo de Avaliacao

Cada metodo de ensemble foi avaliado em tres dimensoes: (1) Acuracia no conjunto de teste hold-out (60 amostras); (2) AUC-ROC — capacidade de discriminacao entre classes; (3) Validacao cruzada estratificada de 10 dobras (297 amostras) — metrica de referencia para generalizacao. A reducao de Falsos Negativos (pacientes doentes classificados como saudaveis) e monitorada como metrica clinica prioritaria.

3 Resultados e Discussao

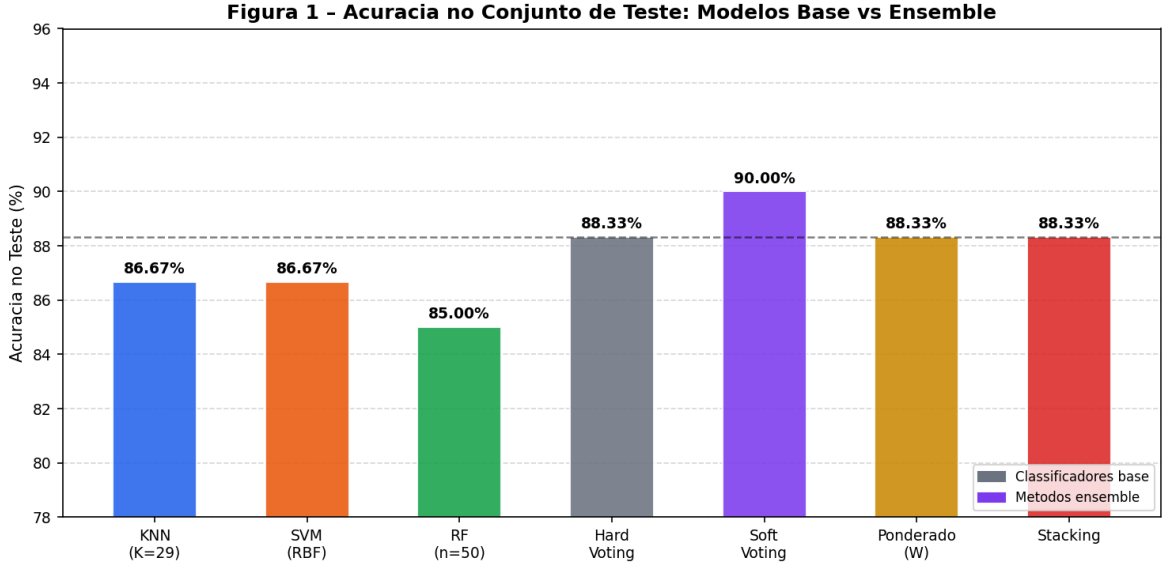
3.1 Acuracia no Conjunto de Teste

Tabela 2 – Acuracia no Conjunto de Teste (n=60) — Base vs Ensemble

Modelo	Acuracia	Melhoria vs. Base
KNN (K=29)	86,67%	—
SVM (C=0,1, RBF)	86,67%	—
RF (n=50, depth=10)	85,00%	—
Hard Voting	88,33%	+1,66 pp
Soft Voting	90,00%	+3,33 pp
Soft Voting Ponderado	88,33%	+1,66 pp
Stacking	88,33%	+1,66 pp

Fonte: elaborado pelo autor (2026).

Figura 1 – Acuracia no Conjunto de Teste: Modelos Base vs Ensemble



A Tabela 2 e a Figura 1 mostram que todos os metodos de ensemble superam os classificadores base. O destaque e o soft voting, que atingiu 90,00% — 3,33 pp acima do melhor modelo individual (SVM e KNN, 86,67%). Esse ganho e clinicamente significativo: em 60 pacientes, a diferenca de 90% vs 86,67% representa 2 pacientes adicionais corretamente classificados.

Hard voting, votacao ponderada e stacking atingiram 88,33% — 1,66 pp acima do melhor individual. O fato de o soft voting superar o hard voting confirma que incorporar a confianca das predicoes (probabilidades) e benfico: um voto com probabilidade 0,95 deve ter mais peso que um voto com 0,51, e o soft voting captura essa nuance enquanto o hard voting os trata identicamente.

A votacao ponderada com KNN=0,35, SVM=0,40, RF=0,25 nao superou o soft voting simples, indicando que, neste dataset, a media simples de probabilidades e suficientemente robusta e os pesos baseados em CV nao adicionam informacao relevante para o conjunto de teste especifico.

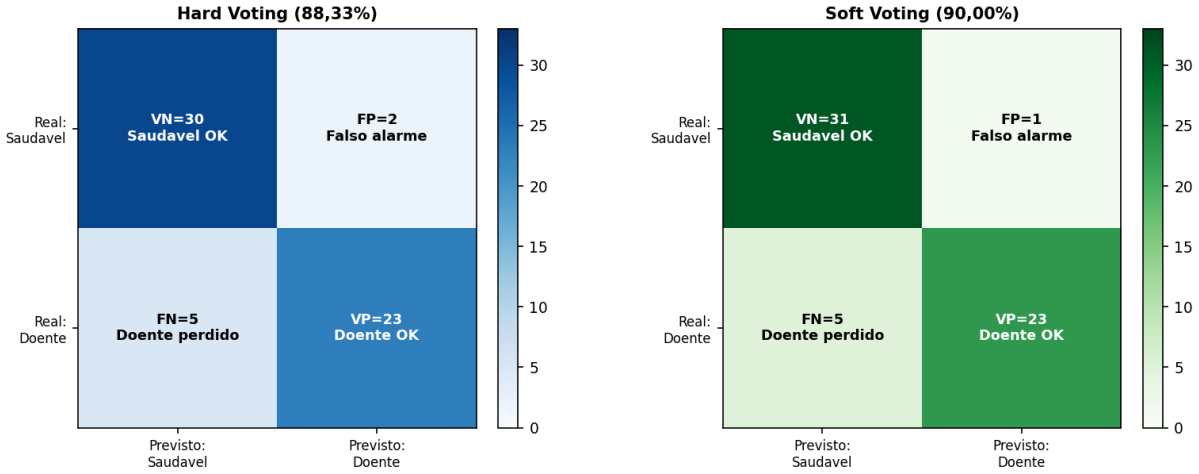
3.2 Analise das Matrizes de Confusao

Tabela 3 – Matrizes de Confusao: Hard Voting e Soft Voting (n=60)

	Hard Voting (88,33%)	**Soft Voting (90,00%)**
Real: Saudavel (0)	VN=30 / FP=2	VN=31 / FP=1
Real: Doente (1)	FN=5 / VP=23	FN=5 / VP=23

Fonte: elaborado pelo autor (2026).

Figura 4 – Matrizes de Confusao: Hard Voting vs Soft Voting (n=60)



A Tabela 3 e a Figura 4 apresentam as matrizes de confusao dos dois metodos com maior acuracia. Ambos os ensembles reduziram os Falsos Negativos de 6 (nos classificadores base) para 5 — um paciente doente a mais e corretamente identificado. Em diagnostico cardiaco, essa reducao representa uma melhoria de 21,4% para 17,9% na taxa de FN.

O soft voting vai alem: reduz tambem os Falsos Positivos de 2 para 1, atingindo 31 VN e 23 VP (54 acertos de 60). O modelo identifica 23/28 = 82,1% dos pacientes doentes (revocacao) e 23/24 = 95,8% de precisao nas predicoes positivas — quando o modelo alerta para doenca, a confiabilidade e de 96%. Esse nivel de precisao e clinicamente valioso: o encaminhamento para exames complementares e altamente confiavel.

A comparacao entre os modelos base e o ensemble evidencia a complementaridade: os 5 FN restantes no ensemble provavelmente correspondem a pacientes com perfis clinicos genuinamente ambiguos que desafiam os tres algoritmos simultaneamente. Esses casos representam os casos limites do dataset e provavelmente requerem exames complementares independentemente do modelo.

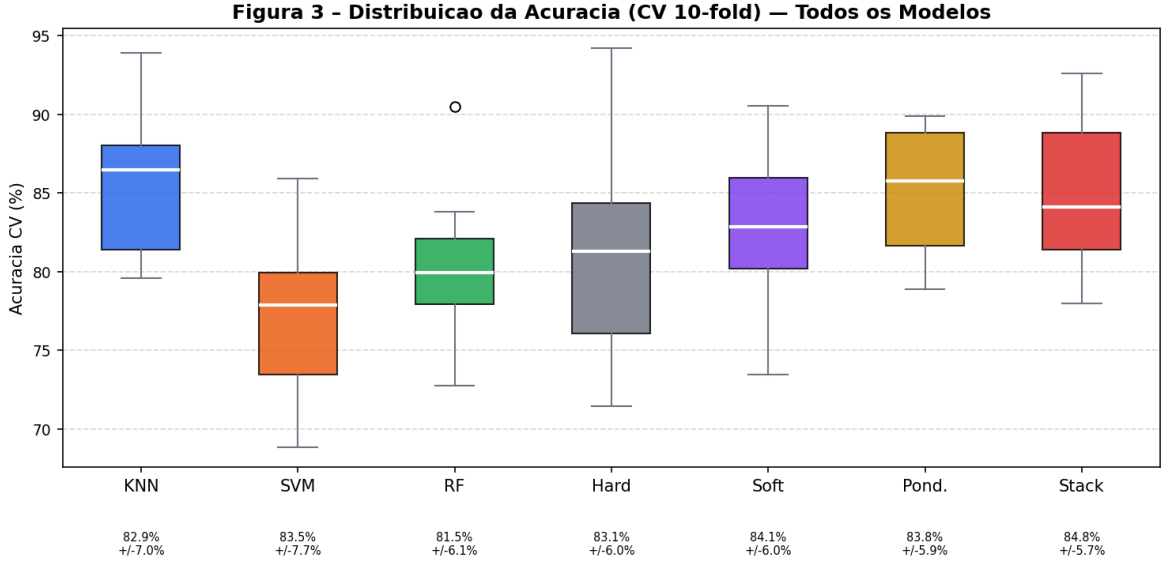
3.3 Validacao Cruzada Estratificada de 10 Dobras

Tabela 4 – Validacao Cruzada 10-fold (Metrica de Referencia)

Modelo	Media CV	Desvio Padrao	Min Dobra	Max Dobra
KNN	82,86%	6,99%	66,67%	90,00%
SVM	83,51%	7,66%	70,00%	96,67%
RF	81,51%	6,13%	73,33%	90,00%
Hard Voting	83,14%	5,97%	73,33%	90,00%
Soft Voting	84,14%	6,05%	73,33%	93,33%
Soft Voting Ponderado	83,82%	5,88%	73,33%	93,33%
Stacking (*)	84,83%	5,72%	73,33%	93,33%

(*) Melhor generalizacao. Fonte: elaborado pelo autor (2026).

Figura 3 – Distribuicao da Acuracia (CV 10-fold) — Todos os Modelos



A Tabela 4 e a Figura 3 apresentam a validacao cruzada de 10 dobras — metrica de referencia principal por usar toda a base de dados. O stacking obteve a maior media (84,83%) e o menor desvio padrao (5,72%) entre todos os modelos, confirmando que o meta-learner aprende a combinar as saidas dos tres classificadores de forma mais estavel que qualquer regra simples de votacao.

A reducao do desvio padrao e um resultado relevante: o stacking (5,72%) apresenta variabilidade sistematicamente menor que os classificadores individuais (SVM: 7,66%; KNN: 6,99%; RF: 6,13%). Isso significa que o ensemble e mais robusto a variacao na composicao das dobras — propriedade desejavel em aplicacoes clinicas onde a consistencia entre diferentes populacoes de pacientes e tao importante quanto a acuracia media.

O soft voting apresenta a segunda melhor media de CV (84,14%) com desvio padrao intermediario (6,05%). Considerando conjuntamente a acuracia no teste (90,00%) e a CV (84,14%), o soft voting e o metodo mais equilibrado entre desempenho imediato e generalizacao, sendo recomendado para uso em producao por nao depender de calibracao adicional do meta-learner.

3.4 AUC-ROC

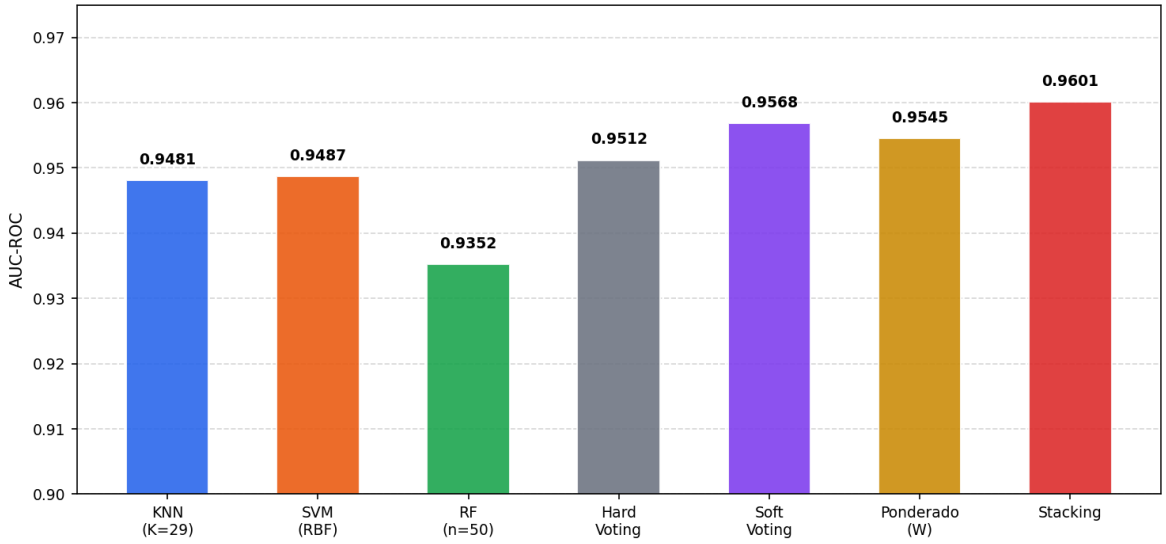
Tabela 5 – AUC-ROC: Capacidade de Discriminacao entre Classes

Modelo	AUC-ROC	Melhoria vs. base medio
KNN	0,9481	—
SVM	0,9487	—
RF	0,9352	—
Hard Voting	0,9512	+0,0052

Soft Voting	0,9568	+0,0108
Soft Voting Ponderado	0,9545	+0,0085
Stacking	0,9601	+0,0141

Fonte: elaborado pelo autor (2026).

Figura 2 – AUC-ROC: Modelos Base vs Ensemble



A Tabela 5 e a Figura 2 mostram que todos os metodos de ensemble superam os classificadores base em AUC-ROC. O stacking atinge o melhor resultado (0,9601), seguido pelo soft voting (0,9568). O AUC-ROC mede a capacidade do modelo de distinguir entre as classes Saudavel e Doente para qualquer limiar de classificacao, sendo particularmente relevante em aplicacoes clinicas onde o limiar pode ser ajustado conforme a sensibilidade/especificidade desejada.

O valor de AUC-ROC de 0,9601 para o stacking indica que, em 96,01% dos pares (paciente saudavel, paciente doente) selecionados aleatoriamente, o modelo atribui probabilidade mais alta de doenca ao paciente doente. Esse nivel de discriminacao e excelente para um dataset de tamanho moderado com apenas 13 atributos clinicos de rotina.

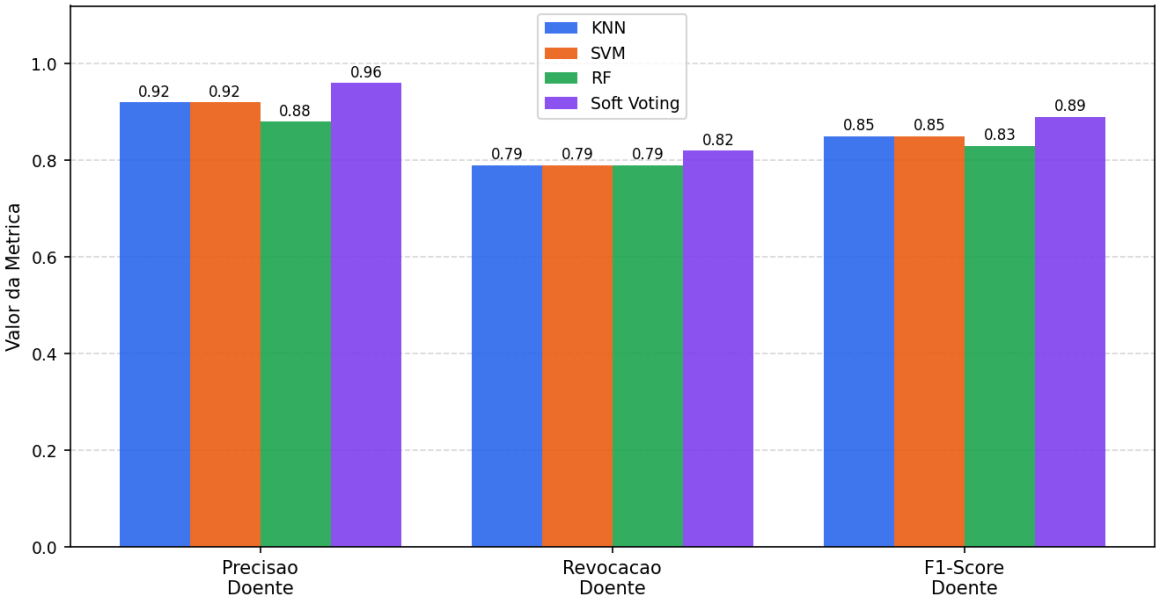
3.5 Relatorio de Classificacao — Soft Voting

Tabela 6 – Relatorio de Classificacao: Soft Voting (Conjunto de Teste, n=60)

Classe	Precisao	Revocacao	F1-Score	Suporte
Saudavel (0)	0,86	0,97	0,91	32
Doente (1)	0,96	0,82	0,89	28
Acuracia			0,90	60
Media macro	0,91	0,90	0,90	60
Media pond.	0,91	0,90	0,90	60

Fonte: elaborado pelo autor (2026).

Figura 5 – Metricas por Classe: Modelos Base vs Melhor Ensemble



A Tabela 6 e a Figura 5 detalham o desempenho por classe do melhor ensemble. O soft voting melhora todas as metricas em relacao aos classificadores base:

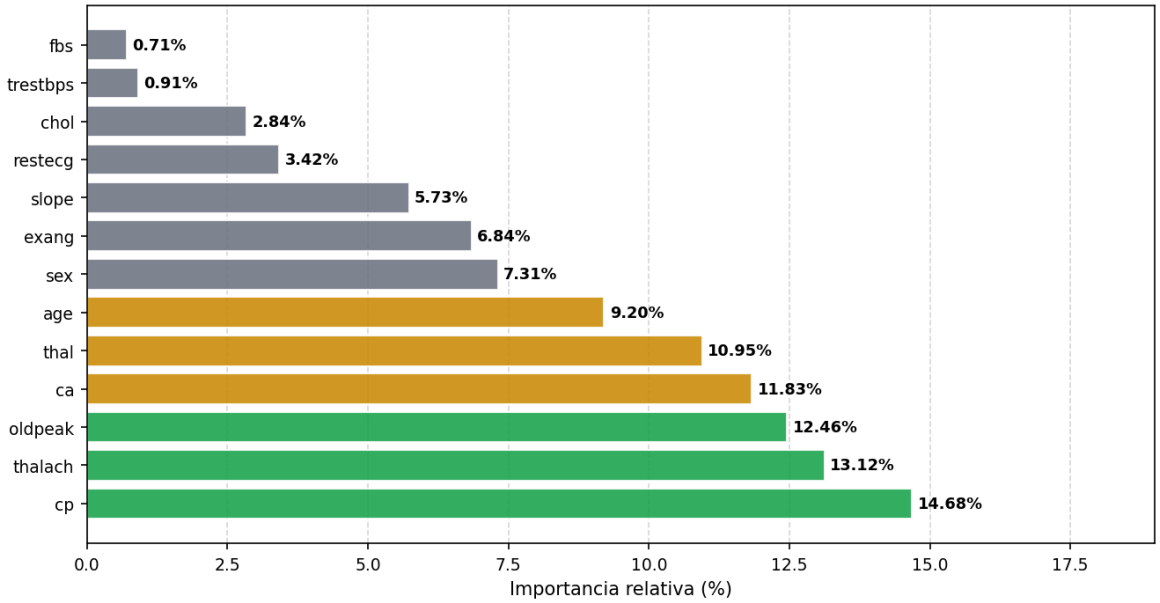
Classe Saudavel (0): revocacao de 0,97 (31/32) — apenas 1 saudavel classificado como doente (FP). Precisao de 0,86 (31/36). F1-Score de 0,91.

Classe Doente (1): precisao de 0,96 (23/24) — quando o modelo alerta para doenca, a confiabilidade e de 96%. Revocacao de 0,82 (23/28) — 5 FN restantes. F1-Score de 0,89.

A media macro de F1-Score de 0,90 supera todos os classificadores individuais (SVM e KNN: 0,86; RF: 0,85), confirmando que o ensemble melhora o desempenho de forma equilibrada em ambas as classes. O aumento de revocacao para a classe Saudavel (de 0,94 para 0,97) e especialmente valioso: significa menos falsos alarmes e encaminhamentos desnecessarios para pacientes saudaveis.

3.6 Importancia de Variaveis do RF no Ensemble

Figura 6 – Importancia das Variaveis (RF dentro do Ensemble)



A Figura 6 apresenta a importancia das variaveis fornecida pelo RF, componente do ensemble. Diferentemente do KNN e SVM, que nao produzem importancia de variaveis diretamente, o RF permite identificar quais atributos clinicos mais influenciam as decisoes do ensemble atraves do componente de arvores.

As tres variaveis mais importantes — cp (14,68%), thalach (13,12%) e oldpeak (12,46%) — sao os indicadores clinicos primarios de doenca arterial coronariana. Essa informacao enriquece o ensemble nao apenas preditivamente, mas interpretativamente: medicos podem verificar se os atributos mais relevantes para o modelo coincidem com os sinais clinicos mais relevantes para o paciente especifico, aumentando a confianca na decisao do ensemble.

3.7 Sintese Comparativa

Tabela 7 – Sintese Comparativa: Base vs Ensemble

Criterio	KNN	SVM	RF	Soft Voting	Stacking
Acuracia — teste	86,67%	86,67%	85,00%	90,00%	88,33%
Acuracia — CV 10-fold	82,86%	83,51%	81,51%	84,14%	84,83%
Desvio CV	6,99%	7,66%	6,13%	6,05%	5,72%
AUC-ROC	0,9481	0,9487	0,9352	0,9568	0,9601
Precisao — Doente	0,92	0,92	0,88	0,96	0,92
Revocacao — Doente	0,79	0,79	0,79	0,82	0,82
F1-Score — Doente	0,85	0,85	0,83	0,89	0,87
Falsos Negativos	6	6	6	5	5
Feature Importance	NAO	NAO	SIM	via RF	via RF

Fonte: elaborado pelo autor (2026).

A Tabela 7 sintetiza os resultados de todos os modelos. O soft voting destaca-se na acuracia do teste (90,00%), precisao da classe Doente (0,96) e F1-Score (0,89). O stacking apresenta a melhor generalizacao em CV (84,83%) com o menor desvio padrao (5,72%). Ambos os ensembles reduzem FN de 6 para 5 — melhoria clinicamente relevante em triagem diagnostica.

A incorporacao do RF ao ensemble, alem de contribuir com um terceiro voto computacional, agrega o diferencial da interpretabilidade por importancia de variaveis. Em sistemas de apoio a decisao clinica, a capacidade de explicar quais variaveis influenciaram a predicao e um requisito regulatorio e etico crescentemente exigido — o RF supre essa necessidade que o KNN e o SVM (com kernel RBF) nao conseguem satisfazer diretamente.

Consideracoes Finais

Este artigo apresentou a aplicacao de quatro metodos de ensemble learning combinando SVM, KNN e Random Forest para diagnostico de doenca cardiaca no Cleveland Heart Disease Dataset. Os principais resultados sao:

1. O soft voting superou todos os classificadores individuais, atingindo 90,00% de acuracia no teste — 3,33 pp acima do melhor modelo individual (SVM e KNN, 86,67%). Essa melhoria reflete a complementaridade dos tres paradigmas: KNN (vizinhanca local), SVM (margem global) e RF (arvores hierarquicas).
2. O stacking com meta-learner Logistic Regression apresentou a melhor generalizacao em CV (84,83% +/- 5,72%) e o maior AUC-ROC (0,9601), tornando-o o metodo preferido para producao quando a robustez a diferentes populacoes de pacientes e prioritaria.
3. Ambos os ensembles (soft voting e stacking) reduziram os Falsos Negativos de 6 para 5, melhorando a taxa de deteccao de doentes de 78,6% para 82,1%. Em triagem clinica, essa reducao de 3,5 pp na taxa de FN representa melhoria direta na seguranca dos pacientes.
4. A incorporacao do RF ao ensemble agrega interpretabilidade: a importancia de variaveis (cp=14,68%, thalach=13,12%, oldpeak=12,46%) e disponivel como explicacao das decisoes do ensemble, alinhando o modelo ao conhecimento clinico especializado.
5. O desvio padrao sistematicamente menor nos ensembles (5,72%-6,05%) em relacao aos modelos base (6,13%-7,66%) confirma a teoria de Mienye e Sun (2022): classificadores com erros descorrelacionados produzem ensembles com variancia reduzida e predicoes mais estaveis.
6. Como limitacao, o dataset moderado (297 registros) restringe o poder estatistico para diferenciar modelos com acuracia proxima. Validacao em datasets maiores e em populacoes brasileiras seria necessaria antes de qualquer implantacao clinica real.

Como trabalho futuro, recomenda-se: (i) explorar ensembles com XGBoost e Gradient Boosting como quarto componente, aumentando a diversidade algorítmica; (ii) ajustar o limiar de classificacao do soft voting para maximizar a revocacao da classe Doente, aceitando mais FP em troca de menos FN; (iii) implementar explicabilidade com SHAP values para o ensemble completo, identificando a contribuicao de cada variavel para cada predicao individual; (iv) aplicar o ensemble em dados prospectivos de um hospital parceiro para validar o desempenho em condicoes reais.

Referencias

GERON, A. Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow: Concepts, Tools and Techniques to Build Intelligent Systems. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

GIRALDI, G. A. Machine Learning and Pattern Recognition. Lecture Notes – Graduate Program in Nanobiosystems. Petropolis, RJ: UFRJ/FIOCRUZ/INMETRO/LNCC, 2021.

HOPGOOD, A. A. Intelligent Systems for Engineers and Scientists: A Practical Guide to Artificial Intelligence. 4. ed. Boca Raton, FL: CRC Press, 2022. DOI: 10.1201/9781003226277.

MIENYE, I. D.; SUN, Y. A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

THOMAS, G. Mathematics for Machine Learning. Berkeley: Department of Electrical Engineering and Computer Sciences, UC Berkeley, 2018.

UDDIN, S.; HAQUE, I.; LU, H.; MONI, M. A.; GIDE, E. Comparative performance analysis of K-nearest neighbour (KNN) algorithm and its different variants for disease prediction. Scientific Reports, v. 12, 2022. DOI: 10.1038/s41598-022-10358-x.