K-NEAREST NEIGHBORS APLICADO AO DIAGNÓSTICO DE DOENÇA CARDÍACA: FUNDAMENTOS MATEMÁTICOS, IMPLEMENTAÇÃO E ANÁLISE DE DESEMPENHO

André Felipe
Faculdade de Tecnologia de Guaratinguetá
andressmota78@gmail.com

Resumo

Este artigo apresenta a aplicação do algoritmo K-Nearest Neighbors (KNN) para a classificação binária de doença cardíaca utilizando o Cleveland Heart Disease Dataset (UCI Machine Learning Repository). São abordados os fundamentos matemáticos do algoritmo, incluindo métricas de distância, regra de votação majoritária e seleção do hiperparâmetro K por meio de validação cruzada estratificada. A implementação foi desenvolvida em Python com a biblioteca scikit-learn, empregando padronização Z-score, particionamento estratificado e otimização automática de K via GridSearchCV. O melhor valor encontrado foi K = 29, obtendo acurácia de 86,67% no conjunto de teste e 82,86% ± 6,99% na validação cruzada de 10 dobras. Os 297 pacientes avaliados foram analisados por matriz de confusão, relatório de classificação e distribuição de acertos em blocos de 50 registros. O trabalho posiciona o KNN frente à literatura de aprendizado em conjunto, evidenciando seu papel como algoritmo de referência e suas limitações comparativas frente a métodos como Random Forest e XGBoost.

Palavras-chave: K-Nearest Neighbors; Aprendizado de Máquina; Doença Cardíaca; Classificação Binária; Validação Cruzada.

Abstract

This paper presents the application of the K-Nearest Neighbors (KNN) algorithm for binary classification of heart disease using the Cleveland Heart Disease Dataset (UCI Machine Learning Repository). The mathematical foundations of the algorithm are covered, including distance metrics, majority voting decision rules and selection of the hyperparameter K through stratified cross-validation. The Python implementation uses Z-score standardization, stratified data partitioning and automatic K optimization via GridSearchCV. The best value found was K = 29, achieving 86.67% accuracy on the test set and 82.86% +/- 6.99% in 10-fold cross-validation over 297 evaluated patients. The work positions KNN against the ensemble learning literature, highlighting its role as a baseline algorithm and its comparative limitations against methods such as Random Forest and XGBoost.

Keywords: K-Nearest Neighbors; Machine Learning; Heart Disease; Binary Classification; Cross-Validation.

Introdução

As doenças cardiovasculares representam a principal causa de mortalidade global segundo a Organização Mundial da Saúde. O diagnóstico precoce é essencial para reduzir óbitos e custos hospitalares, mas exames como eletrocardiogramas avançados e

cineangiocoronariografias possuem alto custo e disponibilidade limitada, especialmente em países em desenvolvimento (MIENYE; SUN, 2022).

O aprendizado de máquina (AM) tem se consolidado como ferramenta de suporte à decisão clínica, sendo aplicado ao diagnóstico de diabetes, hipertensão, câncer e doenças renais. Géron (2019) destaca que algoritmos de classificação podem identificar padrões em dados clínicos com acurácia comparável à de especialistas, democratizando o acesso à triagem médica.

Dentre os algoritmos de classificação, o K-Nearest Neighbors (KNN) se destaca pela simplicidade conceitual, transparência e facilidade de implementação. Por não construir um modelo explícito durante o treinamento — postergando toda a computação para o momento da predição —, é classificado como algoritmo de aprendizado lazy (preguiçoso) e baseado em instâncias (GÉRON, 2019). Essa característica o torna especialmente adequado para aplicações clínicas onde a interpretabilidade é relevante.

O presente artigo tem como objetivos: (i) fundamentar matematicamente o algoritmo KNN; (ii) descrever a metodologia de implementação sobre o Cleveland Heart Disease Dataset; (iii) apresentar e analisar os resultados experimentais; e (iv) posicionar o KNN em relação à literatura de aprendizado em conjunto, identificando seus limites e as direções para trabalhos futuros.

1 Referencial Teórico

1.1 O Algoritmo K-Nearest Neighbors

O algoritmo KNN foi proposto por Fix e Hodges em 1951 e formalizado por Cover e Hart em 1967. Sua premissa é intuitiva: um ponto de consulta pertence à mesma classe que a maioria de seus K vizinhos mais próximos no espaço de características.

Dado um conjunto de treinamento D = {(x1,y1), ..., (xn,yn)}, onde xi em R^d é o vetor de atributos e yi é o rótulo de classe, a predição para uma nova amostra xq é definida por:

y_hat = argmax_c SUM_{i em N_K(xq)} 1[yi = c]

onde N_K(xq) denota o conjunto dos K índices mais próximos de xq segundo uma métrica de distância, e 1[·] é a função indicadora. Na classificação binária adotada (c em {0,1}), a regra se reduz a:

y_hat = 1, se SUM_{i em N_K(xq)} yi > K/2

y_hat = 0, caso contrário

O modelo não constrói nenhuma função paramétrica durante o treinamento; toda a computação é realizada no momento da previsão, justificando sua classificação como algoritmo lazy. Géron (2019, p. 10) lista o KNN entre os algoritmos de aprendizado

supervisionado mais importantes, ao lado de Regressão Logística, SVM, Árvores de Decisão e Redes Neurais.

1.2 Métricas de Distância

A noção de proximidade entre amostras é central ao KNN. A família de métricas de Minkowski generaliza as distâncias mais utilizadas:

$$d_p(x, z) = (SUM_{j=1}^{d} |xj - zj|^p)^(1/p)$$

Os casos especiais mais relevantes são:

Distância Euclidiana (p = 2) — métrica padrão do scikit-learn, adequada para dados numéricos contínuos após normalização:

$$d_E(x, z) = SQRT(SUM_{j=1}^{d} (xj - zj)^2)$$

Distância de Manhattan (p = 1) — menos sensível a valores extremos, por somar diferenças absolutas:

$$d_M(x, z) = SUM_{j=1}^{d} |xj - zj|$$

Distância de Chebyshev (p → ∞) — considera apenas o atributo com maior diferença entre os pontos:

$$d_inf(x, z) = max_j |xj - zj|$$

As métricas de distância fundamentais para o KNN — Euclidiana, p-norm e Chebyshev — são formalizadas por Giraldi (2021, p. 88) nas expressões (7.19)–(7.21) da seção 7.8 (Measures of Similarity and Dissimilarity). A implementação deste trabalho utiliza a distância Euclidiana, padrão do KNeighborsClassifier do scikit-learn (PEDREGOSA et al., 2011).

1.3 Necessidade de Normalização

Por ser fundamentado em distâncias, o KNN é altamente sensível à escala dos atributos. Um atributo com amplitude numérica elevada — como pressão arterial (80–200 mmHg) — dominaria o cálculo da distância em relação a atributos com menor variação — como sexo biológico (0 ou 1) — distorcendo as vizinhanças e prejudicando a classificação. Géron (2019) enfatiza que atributos com escalas muito diferentes são um problema para algoritmos sensíveis à distância; Giraldi (2021, p. 90) formaliza o processo de normalização na seção 7.9 como solução para garantir que todos os atributos operem no mesmo espaço métrico.

A Padronização Z-score (StandardScaler) transforma cada atributo j de acordo com:

$$zij = (xij - x_mean_j) / sigma_j$$

onde x_mean_j é a média e sigma_j é o desvio padrão calculados exclusivamente sobre o conjunto de treinamento, garantindo que informações do conjunto de teste não

contaminem o pré-processamento — prática conhecida como prevenção de data leakage. Após a transformação, todos os atributos possuem média zero e desvio padrão unitário.

1.4 Seleção do Hiperparâmetro K e o Trade-off Viés-Variância

O valor de K é o principal hiperparâmetro do KNN e governa o equilíbrio entre viés e variância:

K pequeno: o modelo é muito sensível a variações locais, resultando em alta variância e risco de overfitting.

K grande: o modelo suaviza excessivamente as fronteiras de decisão, aumentando o viés e levando ao underfitting.

O erro esperado de generalização pode ser decomposto como:

Erro(xq) = Vies^2 + Variancia + epsilon (ruido irredutivel)

O método padrão para seleção de K é a busca em grade com validação cruzada estratificada (GridSearchCV + StratifiedKFold). Para cada candidato k em {1, ..., K_max}:

K = argmax_k (1/v) SUM_{i=1}^{v} Acc(k, dobra_i)*

1.5 Validação Cruzada Estratificada

A validação cruzada k-fold estratificada (StratifiedKFold) garante que a proporção de classes em cada dobra reflita a distribuição global do conjunto. Para um conjunto D particionado em v dobras (GÉRON, 2019, p. 59):

Acc_CV = (1/v) SUM_{i=1}^{v} Acc(M_{D \ Di}, Di)

onde M_{D/Di} é o modelo treinado em todas as dobras exceto a dobra i, e avaliado sobre Di. Segundo Géron (2019), a validação cruzada é a métrica mais confiável para estimar a capacidade de generalização. Esta é a métrica de referência principal deste artigo.

1.6 Métricas de Avaliação de Classificadores

O desempenho do classificador é analisado com base na matriz de confusão. As métricas derivadas são definidas como:

Acurácia = (VP + VN) / (VP + VN + FP + FN)

Precisão = VP / (VP + FP)

Revocação (Recall) = VP / (VP + FN)

F1-Score = 2 · (Precisão × Revocação) / (Precisão + Revocação)

Em triagem clínica, os Falsos Negativos — pacientes doentes classificados como saudáveis — são o erro de maior impacto, pois podem resultar em ausência de tratamento para pacientes em risco.

1.7 O KNN no Contexto do Aprendizado em Conjunto

Mienye e Sun (2022) classificam o KNN como um algoritmo estável: pequenas perturbações nos dados de treinamento produzem variações mínimas no modelo. Essa estabilidade implica que técnicas de bagging têm eficácia reduzida com o KNN como aprendiz de base.

> "k-nearest Neighbor (KNN) and naïve Bayes are examples of stable algorithms, and bagging does not perform well with these algorithms as base learners" (MIENYE; SUN, 2022, p. 99136).

Contudo, o KNN é frequentemente empregado em sistemas de conjunto heterogêneos, contribuindo com seu padrão de erros distinto para aumentar a diversidade do ensemble. Velusamy e Ramasamy (2021, apud MIENYE; SUN, 2022) propuseram um classificador heterogêneo combinando SVM, KNN e Random Forest para detecção de doença cardíaca, alcançando 100% de acurácia com votação ponderada. Nanglia et al. (2022, apud MIENYE; SUN, 2022) igualmente utilizaram o KNN em uma pilha de múltiplos classificadores para detecção de câncer de mama, obtendo 78% de acurácia.

2 Metodologia

2.1 Conjunto de Dados

O estudo utiliza o Cleveland Heart Disease Dataset, disponibilizado pelo UCI Machine Learning Repository sob o identificador id=45 (JANOSI et al., 1988). O dataset original contém 303 registros e 14 atributos — 13 preditores clínicos e 1 variável alvo com 5 classes (0 = sem doença; 1 a 4 = graus crescentes). Após remoção de registros com valores ausentes, restaram 297 registros válidos. A Tabela 1 descreve os atributos utilizados.

Tabela 1 – Atributos do Cleveland Heart Disease Dataset

Atributo	Descrição	Tipo
age	Idade do paciente (anos)	Numérico
sex	Sexo (1 = masculino; 0 = feminino)	Binário
cp	Tipo de dor torácica (0–3)	Categórico
trestbps	Pressão arterial em repouso (mmHg)	Numérico
chol	Colesterol sérico (mg/dl)	Numérico
fbs	Glicemia em jejum > 120 mg/dl (1/0)	Binário
restecg	Resultado do ECG em repouso (0–2)	Categórico
thalach	Frequência cardíaca máxima (bpm)	Numérico
exang	Angina induzida por exercício (1/0)	Binário
oldpeak	Depressão do segmento ST	Numérico
slope	Inclinação do segmento ST de pico	Categórico

ca	Número de vasos coloridos (0–3)	Ordinal
thal	Resultado do teste de estresse com tálio	Categórico

Fonte: JANOSI et al. (1988).

2.2 Binarização da Variável Alvo

O dataset original apresenta 5 classes, introduzindo ambiguidade entre graus intermediários de doença. Adotou-se a binarização da variável alvo, estratégia amplamente utilizada na literatura para este dataset (MIENYE; SUN, 2022):

y_binário = 0 se y_original = 0 (Saudável)

y_binário = 1 se y_original > 0 (Doente)

Essa redução de 5 para 2 classes simplifica a interpretação clínica e melhora o desempenho do modelo, eliminando ambiguidades entre classes intermediárias.

2.3 Pipeline de Pré-processamento

O pipeline compreende três etapas sequenciais:

Etapa 1 — Remoção de valores ausentes: registros com NaN em qualquer atributo foram descartados. Dos 303 registros originais, 6 foram removidos, resultando em 297 registros válidos.

Etapa 2 — Padronização Z-score: todos os 13 atributos foram padronizados com StandardScaler, calculando média e desvio padrão exclusivamente sobre X_train para evitar data leakage.

Etapa 3 — Particionamento estratificado: os dados foram divididos em 80% treinamento (237 registros) e 20% teste (60 registros) com estratificação pela variável alvo (stratify=y, random_state=42).

2.4 Otimização do Hiperparâmetro K

A busca pelo melhor K foi conduzida com GridSearchCV sobre o intervalo K em {1, 2, ..., 30}, empregando validação cruzada estratificada de 5 dobras (StratifiedKFold) sobre X_train, com critério scoring='accuracy':

K = argmax_{k em {1,...,30}} (1/5) SUM_{i=1}^{5} Acc(k, dobra_i)*

2.5 Protocolo de Avaliação Final

Após definido K* = 29, o modelo foi retreinado com todos os dados de treinamento e avaliado em três instâncias:

1. Conjunto de teste (hold-out de 20%, 60 registros): avaliação em dados não vistos durante o treinamento.

2. Validação cruzada 10-fold sobre os 297 registros: métrica de referência mais robusta.

3. Conjunto completo (297 registros): análise granular em blocos consecutivos de 50 registros.

Algoritmo 1 – KNN para Classificação de Doença Cardíaca

```
Entrada : Dataset UCI Heart Disease (id=45), K_RANGE = {1,...,30}
Saída   : Modelo KNN otimizado e relatório de classificação

1. CARREGAR dados via ucimlrepo.fetch_ucirepo(id=45)
2. SELECIONAR os 13 atributos clínicos da Tabela 1
3. REMOVER registros com valores ausentes  ->  297 registros
4. BINARIZAR alvo: y = 1 se y_orig > 0; y = 0 caso contrário
5. PADRONIZAR: X_scaled = StandardScaler().fit(X_train).transform(X)
6. PARTICIONAR: train/test (80%/20%), stratify=y, random_state=42
7. OTIMIZAR K via GridSearchCV + StratifiedKFold(5):
     K* = argmax Acc(k) para k em {1,...,30}  ->  K* = 29
8. TREINAR: KNeighborsClassifier(n_neighbors=29).fit(X_train, y_train)
9. AVALIAR em teste, validação cruzada 10-fold e conjunto completo
10. GERAR confusion_matrix e classification_report
```

3 Resultados e Discussão

3.1 Otimização do Hiperparâmetro K

A Tabela 2 apresenta os 5 melhores valores de K identificados na busca em grade:

Tabela 2 – Top-5 valores de K na validação cruzada (5-fold, conjunto de treino)

K	Acurácia CV Média
29 (melhor)	83,97%
27	83,55%
17	83,55%
30	83,55%
26	83,55%

Fonte: elaborada pelo autor (2026).

O agrupamento dos melhores resultados na faixa K em [17, 30] indica que o dataset apresenta padrões relativamente suaves que beneficiam vizinhanças maiores. K menores (K < 10) apresentaram maior variabilidade entre dobras, evidenciando sensibilidade a ruídos locais (overfitting). O fato de K = 30 ter desempenho marginalmente inferior a K = 29 sugere que o modelo começa a perder resolução local nessa fronteira, consistente com o trade-off viés-variância descrito por Géron (2019).

3.2 Acurácia por Blocos de Registros

A Tabela 3 apresenta a distribuição de acurácia por blocos consecutivos sobre os 297 pacientes:

Tabela 3 – Acurácia do KNN (K=29) por bloco de registros

Bloco	Registros	Acertos	Acurácia (%)
1	1 – 50	45/50	90,00
2	51 – 100	42/50	84,00
3	101 – 150	45/50	90,00
4	151 – 200	40/50	80,00
5	201 – 250	43/50	86,00
6	251 – 297	37/47	78,72
Total	1 – 297	252/297	84,85

Fonte: elaborada pelo autor (2026).

A variação entre blocos (78,72% a 90,00%) reflete a heterogeneidade das amostras. O bloco 6 apresentou o menor desempenho (78,72%), possivelmente por conter maior proporção de casos ambíguos — pacientes cujo perfil de atributos se sobrepõe às duas classes na vizinhança de K = 29. Os blocos 1 e 3 atingiram 90,00%, sugerindo regiões do espaço de características com fronteiras de decisão mais bem definidas.

3.3 Métricas Consolidadas do Modelo

A Tabela 4 resume o desempenho global do classificador:

Tabela 4 – Resumo de desempenho do classificador KNN (K=29)

Métrica	Valor
Acurácia — conjunto de teste (hold-out 20%)	86,67%
Acurácia — validação cruzada 10-fold (métrica principal)	82,86% ± 6,99%
Acurácia — conjunto completo (297 registros)	84,85%
K (vizinhos)	29
Total de registros avaliados	297

Fonte: elaborada pelo autor (2026).

A validação cruzada 10-fold (82,86% ± 6,99%) é a métrica de referência mais confiável, pois estima a capacidade de generalização por meio de 10 partições independentes. O desvio padrão de ±6,99% é esperado para um dataset de tamanho moderado (297 registros), conforme aponta Géron (2019). A avaliação qualitativa do modelo é classificada como BOA: acurácias de cross-validation entre 75% e 85% indicam que o modelo classifica bem a maioria dos casos, com margem para melhoria por algoritmos

mais sofisticados.

3.4 Matriz de Confusão

A Tabela 5 apresenta a matriz de confusão sobre os 60 registros do conjunto de teste:

Tabela 5 – Matriz de confusão (conjunto de teste, n=60)

	Previsto: Saudável	**Previsto: Doente**
Real: Saudável	30 (VN)	2 (FP)
Real: Doente	6 (FN)	22 (VP)

Fonte: elaborada pelo autor (2026).

Os 6 Falsos Negativos representam o erro mais crítico em termos clínicos: pacientes com doença cardíaca que receberiam diagnóstico negativo pelo modelo. Com 28 pacientes doentes no conjunto de teste, isso equivale a uma taxa de falsos negativos de 21,4% — aceitável para um modelo de referência, porém insuficiente para uso clínico autônomo sem supervisão médica.

3.5 Relatório de Classificação por Classe

A Tabela 6 apresenta o relatório completo de classificação:

Tabela 6 – Relatório de classificação (conjunto de teste, n=60)

Classe	**Precisão**	**Revocação**	**F1-Score**	**Suporte**
Saudável (0)	0,83	0,94	0,88	32
Doente (1)	0,92	0,79	0,85	28
Acurácia geral			0,87	60
Média macro	0,88	0,86	0,86	60
Média ponderada	0,87	0,87	0,87	60

Fonte: elaborada pelo autor (2026).

A análise por classe revela: (i) precisão da classe Doente = 0,92 — quando o modelo prevê "Doente", está correto em 92% dos casos; (ii) revocação da classe Doente = 0,79 — o modelo detecta 79% dos pacientes efetivamente doentes; (iii) F1-Score equilibrado (0,85 e 0,88) — sem desvio marcante para nenhuma das classes; (iv) F1-Score macro médio = 0,86 — confirma desempenho equilibrado entre as duas classes.

3.6 Análise Qualitativa dos Erros

Os 45 erros observados nos 297 registros (15,15% do total) se dividem em dois padrões:

Falsos Negativos (doente classificado como saudável): ocorrem quando um paciente doente possui perfil clínico semelhante ao de pacientes saudáveis na vizinhança de K = 29. Exemplos: registros 17, 23, 34, 45, 52, 53 e 58.

Falsos Positivos (saudável classificado como doente): ocorrem quando um paciente saudável apresenta características próximas às de pacientes doentes no espaço padronizado. Exemplos: registros 33 e 81.

Esse padrão é inerente ao KNN, que toma decisões estritamente locais sem capturar relações globais entre atributos, especialmente interações não lineares entre variáveis como cp (tipo de dor torácica), thal (resultado do tálio), ca (vasos coloridos) e oldpeak (depressão do ST) — as mais preditivas do Cleveland dataset segundo a literatura (MIENYE; SUN, 2022).

3.7 Comparação com a Literatura

A Tabela 7 compara os resultados obtidos com trabalhos aplicados ao mesmo dataset:

Tabela 7 – Comparação com a literatura (Cleveland Heart Disease Dataset)

Referência	Algoritmo	Acurácia
Este trabalho	KNN (K=29, binário)	86,67% (teste) / 82,86% (CV-10)
GAO et al. (2021)	Random Forest + PCA/LDA	98,6%
MIENYE et al. (2020)	WAE + CART (ensemble)	93,0%
VELUSAMY; RAMASAMY (2021)	Ensemble SVM + KNN + RF (WAV)	100%
MIENYE; SUN (2022)	XGBoost + SMOTE-ENN + RFE	95,6%

Fonte: MIENYE; SUN (2022).

O KNN com K = 29 obtém desempenho competitivo como algoritmo de referência (baseline), sendo superado pelos métodos ensemble e pelos algoritmos baseados em árvores de decisão. Essa diferença ilustra a afirmação de Mienye e Sun (2022), segundo a qual

> "ensemble classifiers are more robust and perform better than the individual ensemble learners" (MIENYE; SUN, 2022, p. 99129).

Vale destacar que o resultado de 100% de Velusamy e Ramasamy (2021) foi obtido com um ensemble que inclui o próprio KNN como componente, reforçando que o KNN, embora limitado individualmente, agrega valor quando combinado com outros classificadores em arquiteturas heterogêneas.

Considerações Finais

Este trabalho apresentou a aplicação do algoritmo K-Nearest Neighbors para classificação binária de doença cardíaca sobre o Cleveland Heart Disease Dataset, com ênfase nos fundamentos matemáticos, nas decisões metodológicas de implementação e na análise rigorosa dos resultados experimentais.

Os principais achados são:

1. O KNN com K = 29 obteve acurácia de 86,67% no conjunto de teste e 82,86% ± 6,99% na validação cruzada de 10 dobras, desempenho classificado como BOM e competitivo para um algoritmo não paramétrico de baixa complexidade computacional.

2. A binarização da variável alvo (5 classes → 2 classes) foi decisiva: eliminou ambiguidades entre graus intermediários da doença e tornou o problema clinicamente mais interpretável.

3. A padronização Z-score é condição necessária para o KNN operar corretamente sobre dados heterogêneos com escalas distintas, conforme ressaltado por Géron (2019).

4. A validação cruzada 10-fold (82,86%) é a métrica de referência mais honesta para o TCC, por avaliar o modelo em dados não utilizados no treinamento por meio de 10 partições independentes.

5. As limitações do KNN ficam evidentes nos 45 erros observados: o algoritmo não captura relações globais entre atributos nem interações não lineares, sendo superado por métodos ensemble como XGBoost e Random Forest que, segundo Mienye e Sun (2022), regularmente atingem 93% a 98% de acurácia no mesmo dataset.

Como trabalho futuro, recomenda-se: (i) aplicar seleção de atributos por Recursive Feature Elimination (RFE) para identificar as variáveis mais informativas (cp, thal, ca, oldpeak, exang); (ii) comparar formalmente o KNN com Random Forest e XGBoost sobre o mesmo protocolo experimental; (iii) investigar métricas de distância alternativas (Manhattan, Minkowski com $p \neq 2$); e (iv) avaliar o impacto de técnicas de balanceamento de classes como SMOTE sobre a revocação da classe Doente.

Referências

COVER, T. M.; HART, P. E. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, v. 13, n. 1, p. 21–27, 1967. DOI: 10.1109/TIT.1967.1053964.

FIX, E.; HODGES, J. L. Discriminatory Analysis: Nonparametric Discrimination, Consistency Properties. USAF School of Aviation Medicine, Randolph Field, Texas. Technical Report n. 4, 1951.

GÉRON, Aurélien. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

GIRALDI, Gilson Antonio. Machine Learning and Pattern Recognition. Notas de Aula do Programa de Pós-Graduação. Petrópolis, RJ: UFRJ, 2021.

JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. Heart Disease Dataset. UCI Machine Learning Repository, 1988. Disponível em: https://archive.ics.uci.edu/dataset/45/heart+disease. Acesso em: mar. 2026.

MIENYE, I. D.; SUN, Y. A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, v. 10, p. 99129–99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html. Acesso em: mar. 2026.