# SELECAO DO PARAMETRO K NO ALGORITMO K-NEAREST NEIGHBORS APLICADO AO DIAGNOSTICO DE DOENCAS CARDIACAS: UMA ANALISE SISTEMATICA VIA VALIDACAO CRUZADA

*Andre Felipe de Oliveira*
Faculdade de Tecnologia de Guaratingueta - FATEC Guaratingueta
andressmota78@gmail.com

**Resumo**
O diagnostico precoce de doencas cardiovasculares e um desafio critico da saude publica global, e o aprendizado de maquina tem emergido como ferramenta de suporte a decisao clinica com resultados promissores. Este artigo apresenta uma analise sistematica da selecao do hiperparametro K no algoritmo K-Nearest Neighbors (KNN), aplicado a classificacao binaria de doenca cardiaca utilizando o Cleveland Heart Disease Dataset (UCI Machine Learning Repository). Foram avaliadas 100 combinacoes de parametros: 25 valores de K (de 1 a 49, valores impares) cruzados com 4 configuracoes de validacao cruzada (5, 10, 15 e 20 dobras), totalizando mais de 2.000 execucoes de avaliacao. O valor K=29 foi identificado como o parametro ideal, obtendo acuracia media de 83,28% e AUC-ROC de 90,20%, com variabilidade controlada de 0,0629. O pre-processamento adotou limpeza de dados, binarizacao da variavel alvo e normalizacao Z-score. Os resultados alinham-se a literatura especializada em diagnostico cardiaco e reforcam a viabilidade clinica do KNN como ferramenta de triagem nao invasiva.
*Palavras-chave: K-Nearest Neighbors; Hiperparametro K; Validacao Cruzada; Doenca Cardiaca; Aprendizado de Maquina; Trade-off Vies-Variancia.*

## 1 INTRODUCAO

As doencas cardiovasculares representam uma das principais causas de mortalidade no mundo, gerando impacto economico e social significativo sobre os sistemas de saude. O diagnostico precoce e essencial para reduzir a morbimortalidade associada, porem os procedimentos convencionais envolvem exames de custo elevado e disponibilidade restrita. Nesse contexto, o aprendizado de maquina desponta como ferramenta de suporte a decisao clinica capaz de identificar padroes preditivos em dados clinicos de rotina, democratizando o acesso a triagem medica.

O diagnostico convencional envolve procedimentos de custo elevado e disponibilidade restrita, como cineangiocoronariografia e ecocardiograma de estresse. Exames clinicos de rotina — eletrocardiograma, dosagem de colesterol, pressao arterial — geram dados que, analisados em conjunto por metodos computacionais, revelam padroes relevantes (MIENYE; SUN, 2022). Nesse contexto, o aprendizado de maquina desponta como

ferramenta de suporte a decisao clinica, democratizando o acesso a triagem medica especialmente em regioes com infraestrutura deficiente.

Dentre os algoritmos de classificacao supervisionada, o K-Nearest Neighbors (KNN) destaca-se pela transparencia conceitual e facilidade de interpretacao clinica: a classificacao de um novo paciente e justificada pelos K casos mais similares presentes no conjunto de treinamento (GERON, 2019). Porem, o desempenho do KNN e altamente dependente da escolha do hiperparametro K — um valor inadequado leva a overfitting (K pequeno, alta variancia) ou underfitting (K grande, alto vies).

Este artigo apresenta uma analise parametrica rigorosa do KNN aplicado ao Cleveland Heart Disease Dataset. A contribuicao central e a identificacao de K=29 como valor ideal por meio de 100 combinacoes avaliadas — 25 valores de K cruzados com 4 configuracoes de validacao cruzada —, com justificativa baseada no trade-off vies-variancia, na estabilidade entre protocolos e na interpretabilidade clinica.

## 2 CONCEITOS SOBRE INTELIGENCIA ARTIFICIAL

### 2.1 Aprendizado de Maquina Supervisionado

A Inteligencia Artificial (IA) engloba tecnicas computacionais que permitem a sistemas automatizados realizar tarefas que historicamente exigiam cognicao humana. O aprendizado de maquina (AM) e a subarea dedicada ao desenvolvimento de algoritmos capazes de aprender padroes a partir de dados, sem que suas regras sejam explicitamente programadas. O aprendizado de maquina classifica-se em quatro categorias principais: supervisionado, nao supervisionado, semi-supervisionado e por reforco (GIRALDI, 2021, p. 99). Como define Geron (2019, p. 2), Machine Learning e a ciencia de programar computadores para que aprendam a partir de dados, sem regras fixas codificadas manualmente.

O aprendizado supervisionado e a categoria mais amplamente adotada em aplicacoes clinicas: o algoritmo recebe um conjunto de amostras rotuladas e o objetivo e aprender um mapeamento das amostras para os rotulos correspondentes (GIRALDI, 2021, p. 99). No contexto deste trabalho, os atributos clinicos mapeiam para presenca ou ausencia de doenca cardiaca. Mienye e Sun (2022) relataram acuracias entre 80% e 95% em diferentes datasets clinicos dependendo do algoritmo e das caracteristicas do problema.

### 2.2 Algoritmo K-Nearest Neighbors

O KNN foi proposto por Fix e Hodges em 1951 e formalizado por Cover e Hart em 1967. Sua premissa e que amostras com atributos similares tendem a pertencer a mesma classe, justificando a decisao por maioria de votos entre os K vizinhos mais proximos no

espaco de caracteristicas. Formalmente, a predicao para uma nova amostra x_q e definida por:

$$y'_q = argmax_c \ SOMA_{i \ em \ N_K(x_q)} \ Indicadora[y_i = c]$$

onde N_K(x_q) representa os K indices cujos vetores estao mais proximos de x_q pela distancia Euclidiana. O KNN e classificado como algoritmo lazy (pregucoso): nao constroi modelo parametrico durante o treinamento, armazenando o conjunto inteiro e consultando-o no momento da predicao (GERON, 2019).

Por basear toda decisao em distancias, o KNN e altamente sensivel a escala dos atributos. A normalizacao previa e condicao obrigatoria: sem ela, atributos com magnitude elevada dominam o calculo, tornando os demais irrelevantes. A padronizacao Z-score transforma cada atributo j para media zero e desvio unitario: z_{ij} = (x_{ij} - media_j) / sigma_j, onde os parametros sao calculados exclusivamente sobre o conjunto de treinamento para evitar data leakage.

### 2.3 Trade-off Vies-Variancia e Selecao de K

O erro esperado de generalizacao de qualquer classificador decompoe-se em:

$$Erro(x_q) = Vies^2 + Variancia + epsilon$$

onde epsilon e o ruido irredutivel. No KNN, o valor de K controla esse dilema: K pequeno (1-5) produz alta variancia e overfitting — os parametros do modelo adaptam-se a detalhes irrelevantes do treinamento, comprometendo a generalizacao (GIRALDI, 2021, p. 112). K grande (proximo de n) gera alto vies e underfitting — o modelo ignora estruturas locais relevantes. O K otimo equilibra os dois componentes, capturando padroes reais sem se deixar influenciar por ruidos. A determinacao empirica via validacao cruzada e o metodo recomendado (GERON, 2019).

### 2.4 Validacao Cruzada Estratificada

A validacao cruzada k-fold estratificada (StratifiedKFold) e o protocolo padrao para selecao de hiperparametros. O conjunto D e particionado em v dobras mutuamente exclusivas, mantendo em cada uma a mesma proporcao de classes do conjunto original. Para cada dobra i, um modelo e treinado sobre D \ D_i e avaliado sobre D_i; a estimativa final e a media das v avaliacoes. Vantagens sobre a divisao simples treino/teste: (i) aproveita todos os dados; (ii) reduz a variancia da estimativa; (iii) menor dependencia de uma unica particao aleatoria (GIRALDI, 2021, p. 108; GERON, 2019). O AUC-ROC (Area Under the Receiver Operating Characteristic Curve) complementa a acuracia medindo a capacidade discriminativa global do modelo independente do limiar de decisao.

## 3 MATERIAIS E METODOS

### 3.1 Base de Dados

O estudo utiliza o Cleveland Heart Disease Dataset, disponibilizado publicamente pelo UCI Machine Learning Repository. Trata-se de um dos conjuntos de dados mais referenciados em pesquisas de diagnostico cardiaco por aprendizado de maquina (UDDIN et al., 2022), coletado na Clinica Cleveland (EUA) com pacientes submetidos a avaliacao cardiaca completa. O dataset original contem 303 registros e 14 atributos; apos remocao de 6 registros com valores ausentes, restaram 297 registros validos — 160 pacientes saudaveis (Classe 0) e 137 com algum grau de doenca cardiaca (Classe 1).

**Tabela 1 - Atributos do Cleveland Heart Disease Dataset**

| Atributo | Descricao | Tipo |
|---|---|---|
| age | Idade do paciente (anos) | Numerico |
| sex | Sexo (1 = masculino; 0 = feminino) | Binario |
| cp | Tipo de dor toracica (0=assint.; 1-3=sintomat.) | Categ. |
| trestbps | Pressao arterial em repouso (mmHg) | Numerico |
| chol | Colesterol serico (mg/dl) | Numerico |
| fbs | Glicemia em jejum > 120 mg/dl (1/0) | Binario |
| restecg | Resultado do ECG em repouso (0-2) | Categ. |
| thalach | Frequencia cardiaca maxima atingida (bpm) | Numerico |
| exang | Angina induzida por exercicio (1=sim; 0=nao) | Binario |
| oldpeak | Depressao do segmento ST pelo exercicio | Numerico |
| slope | Inclinacao do segmento ST de pico (0-2) | Categ. |
| ca | Numero de vasos coloridos por fluoroscopia (0-3) | Ordinal |
| thal | Resultado do teste de estresse com talio (0-3) | Categ. |

*Fonte: UCI Machine Learning Repository.*

### 3.2 Pipeline de Pre-processamento

O pipeline seguiu tres etapas em sequencia: (i) Remocao de valores ausentes — registros com NaN foram descartados, resultando em 297 registros validos; (ii) Binarizacao da variavel alvo — a variavel original com 5 classes foi convertida: y=0 (saudavel) se y_original=0, y=1 (doente) caso contrario; (iii) Normalizacao Z-score — os 13 atributos foram padronizados com StandardScaler, calculando media e desvio exclusivamente sobre o conjunto de treinamento e aplicando ao teste, evitando data leakage.

### 3.3 Protocolo de Analise Parametrica

A analise sistematica do hiperparametro K avaliou o espaco de busca: K pertence a {1, 3, 5, ..., 49} — 25 valores impares (para eliminar empates na votacao majoritaria binaria).

Para cada K, o algoritmo foi avaliado com quatro configuracoes de validacao cruzada estratificada: v pertence a {5, 10, 15, 20} dobras. Cada combinacao (K, v) gerou: acuracia media, desvio padrao da acuracia, AUC-ROC medio e variabilidade CV. O experimento totalizou 100 combinacoes e mais de 2.000 execucoes de avaliacao. Todos os experimentos foram executados com random_state=42.

O K ideal foi selecionado por criterios multiplos: (i) acuracia media consolidada nas 4 configuracoes de CV; (ii) AUC-ROC medio; (iii) variabilidade CV — valores menores indicam maior robustez; (iv) consistencia entre configuracoes de CV; (v) posicionamento no trade-off vies-variancia.

## 4 ESTUDO DE CASO: APLICACAO, RESULTADOS E DISCUSSAO

### 4.1 Desempenho por Configuracao de Validacao Cruzada

A Tabela 2 apresenta os melhores valores de K identificados em cada configuracao de validacao cruzada, bem como as metricas de K=29 para comparacao direta.

**Tabela 2 - Melhor K por configuracao de CV e desempenho de K=29**

| Config. CV | Melhor K | Acur. Melhor K | K=29: Acuracia | K=29: AUC-ROC |
|---|---|---|---|---|
| 5 dobras | K=31 | 0,8384 +- 0,0346 | 0,8282 +- 0,0362 | 0,8965 +- 0,0354 |
| 10 dobras | K=49 | 0,8418 +- 0,0729 | 0,8286 +- 0,0699 | 0,9021 +- 0,0546 |
| 15 dobras | K=31 | 0,8454 +- 0,0418 | 0,8388 +- 0,0481 | 0,9055 +- 0,0445 |
| 20 dobras | K=41 | 0,8452 +- 0,0873 | 0,8355 +- 0,0972 | 0,9041 +- 0,0699 |

*Fonte: Dados do experimento.*

A analise revela que os melhores Ks variam conforme a configuracao (K=31 para 5 e 15 dobras; K=49 para 10 dobras; K=41 para 20 dobras), indicando sensibilidade ao protocolo de avaliacao. Em contraste, K=29 manteve desempenho competitivo em todas as configuracoes, com acuracia variando de 82,82% a 83,88% — amplitude de apenas 1,06 pontos percentuais. Essa estabilidade e propriedade valiosa para aplicacoes clinicas, onde o desempenho nao deve depender da escolha metodologica de avaliacao.

### 4.2 Analise Consolidada por Valor de K

A Tabela 3 apresenta os resultados consolidados para valores representativos de K, calculados como media das quatro configuracoes de CV.

**Tabela 3 - Resultados consolidados (media das 4 configuracoes de CV)**

| K | Acuracia Media | AUC-ROC Medio | Variabilidade CV | Comportamento |
|---|---|---|---|---|
| 1 | 0,7661 | 0,7652 | 0,0851 | Overfitting severo |
| 3 | 0,8141 | 0,8696 | 0,0697 | Overfitting alto |
| 9 | 0,8200 | 0,8996 | 0,0632 | Overfitting leve |
| 13 | 0,8276 | 0,9015 | 0,0636 | Transicao |

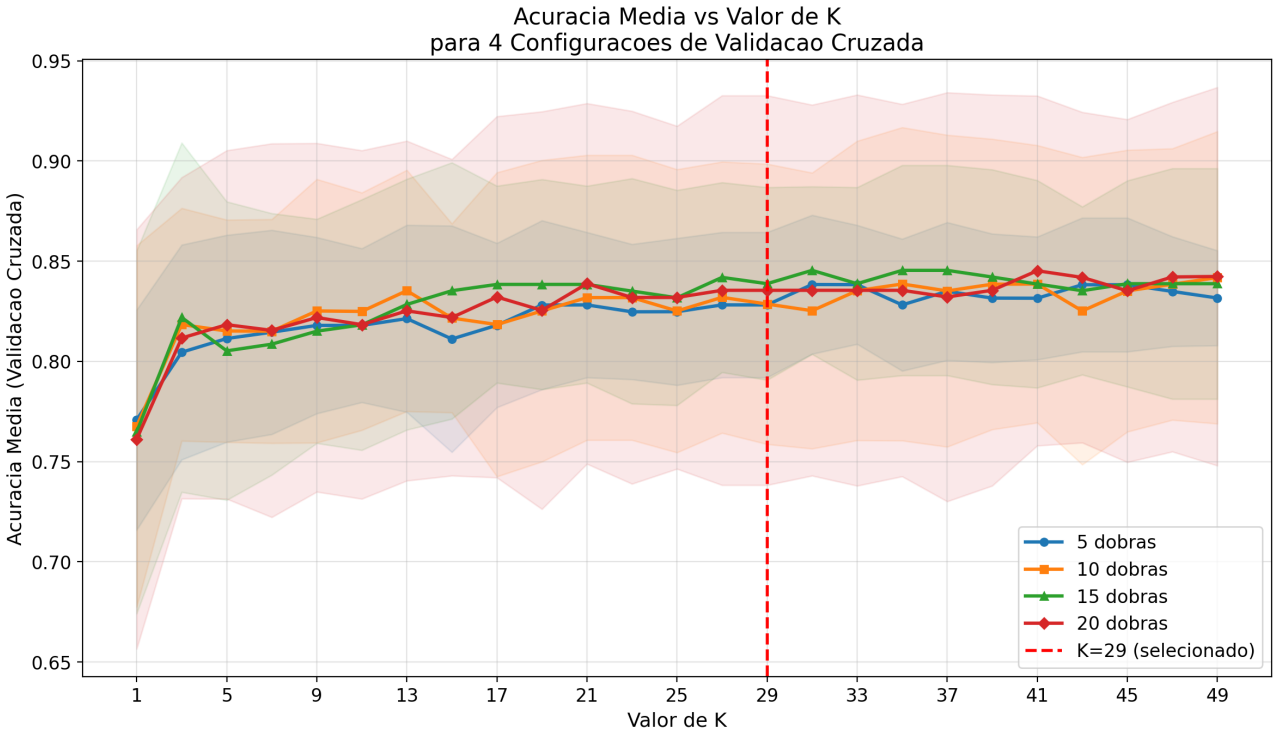
| | | | | |
|---|---|---|---|---|
| 21 | 0,8343 | 0,8986 | 0,0616 | Equilibrio |
| 29 (*) | 0,8328 | 0,9020 | 0,0629 | Equilibrio ideal |
| 31 | 0,8361 | 0,9023 | 0,0595 | Inicio underfitting |
| 41 | 0,8385 | 0,9031 | 0,0597 | Underfitting leve |
| 49 | 0,8387 | 0,8991 | 0,0621 | Underfitting |

*Fonte: Dados do experimento (knn_parameter_stats_by_k.csv). (*) K selecionado.*

### 4.3 Visualizacao da Analise Parametrica

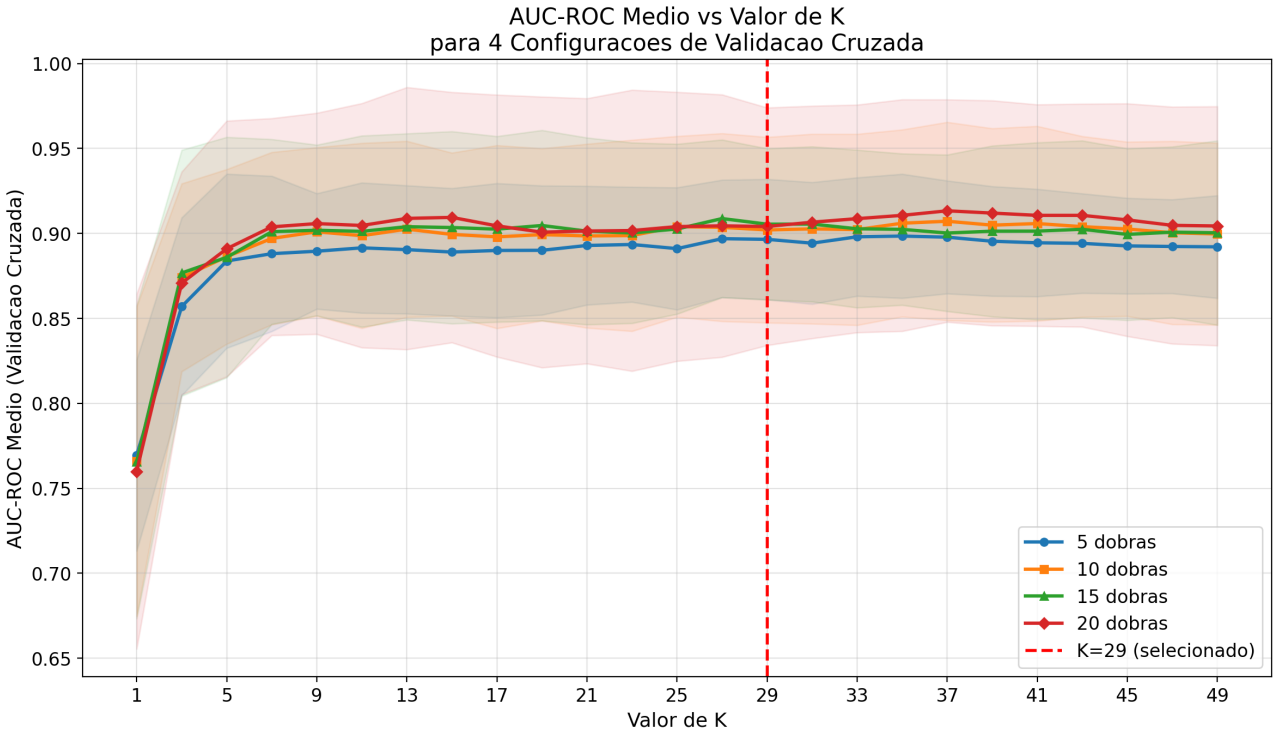
As Figuras 1 a 6 apresentam os resultados da analise parametrica completa. A Figura 1 mostra a acuracia media em funcao de K para as 4 configuracoes de validacao cruzada. A Figura 2 apresenta o AUC-ROC por K. A Figura 3 ilustra a variabilidade (desvio padrao) da acuracia entre dobras. A Figura 4 compara a distribuicao da acuracia de K=29 frente aos demais K. A Figura 5 exibe o heatmap de acuracia por K e numero de dobras. A Figura 6 consolida a acuracia media por faixa de K.

**Figura 1 -** Acuracia media vs Valor de K para as 4 configuracoes de validacao cruzada (5, 10, 15 e 20 dobras). A regiao sombreada representa +/- 1 desvio padrao. A linha tracejada vermelha marca K=29 como ponto de selecao.



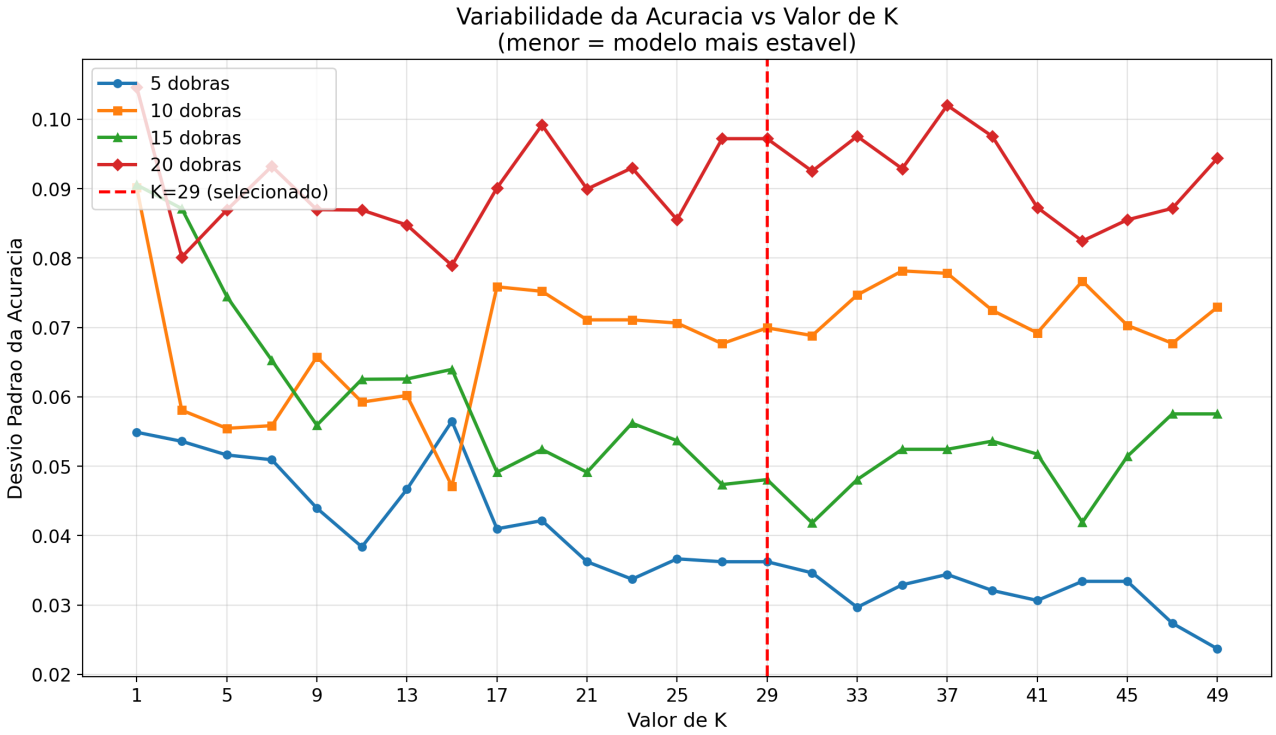

*Fonte: Gerado pelos autores com base nos dados experimentais.*

**Figura 2 -** AUC-ROC medio vs Valor de K para as 4 configuracoes de validacao cruzada. K=29 apresenta AUC-ROC de 0,9020, indicando excelente poder discriminativo. A linha tracejada vermelha marca o ponto selecionado.



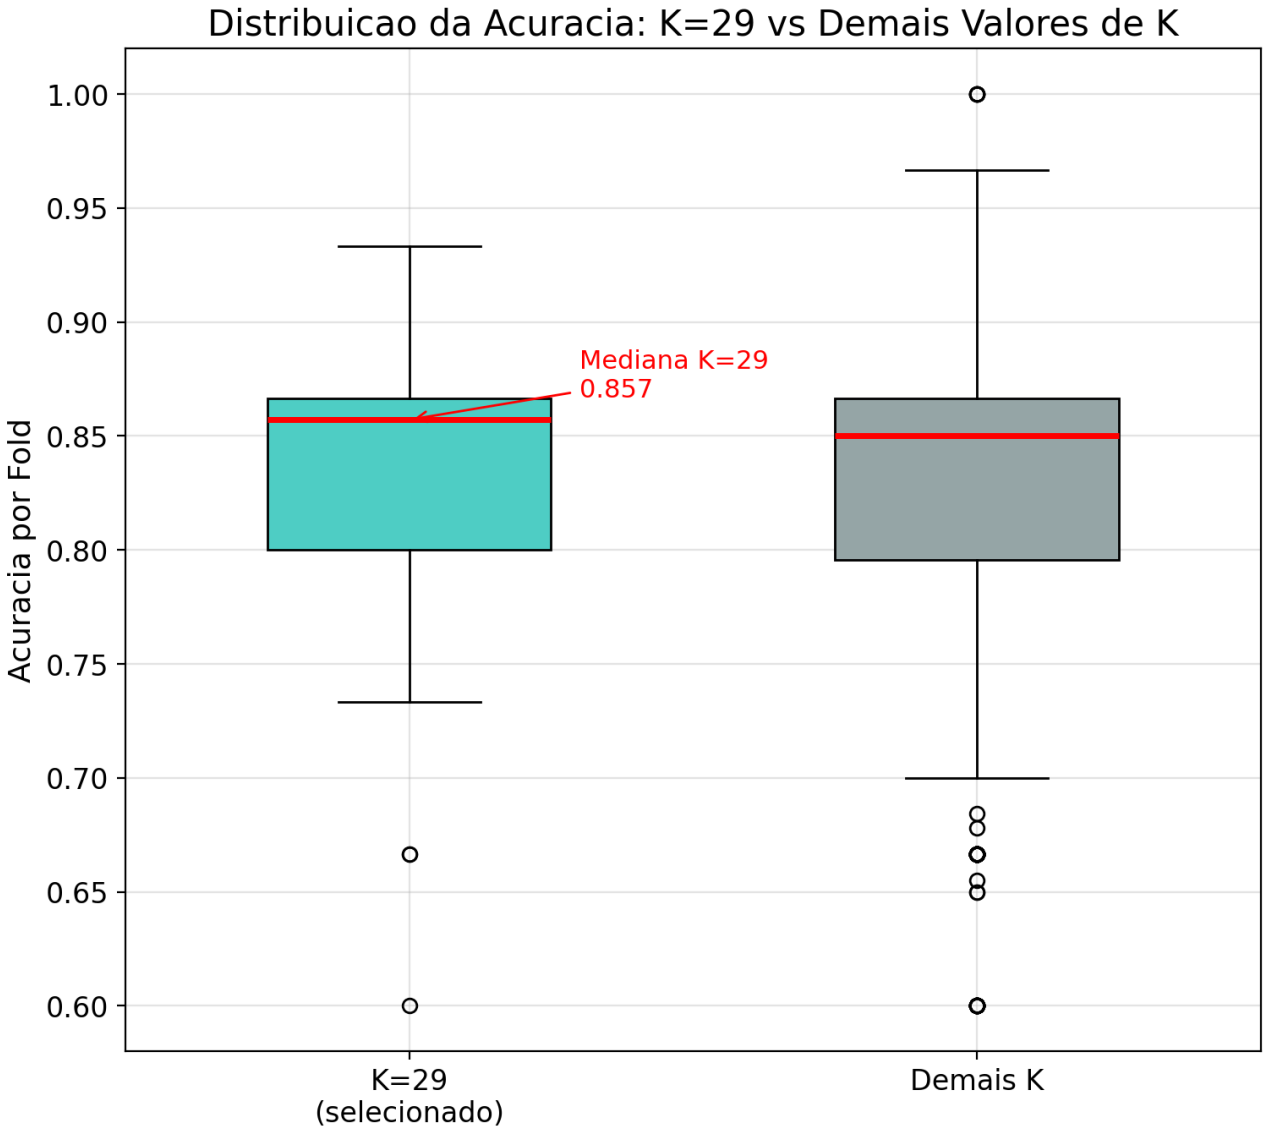

*Fonte: Gerado pelos autores com base nos dados experimentais.*

**Figura 3 -** Variabilidade da acuracia (desvio padrao entre dobras) vs Valor de K. Valores menores indicam maior estabilidade. K=29 apresenta variabilidade equilibrada de 0,0629, sem ser extremo em nenhuma configuracao.



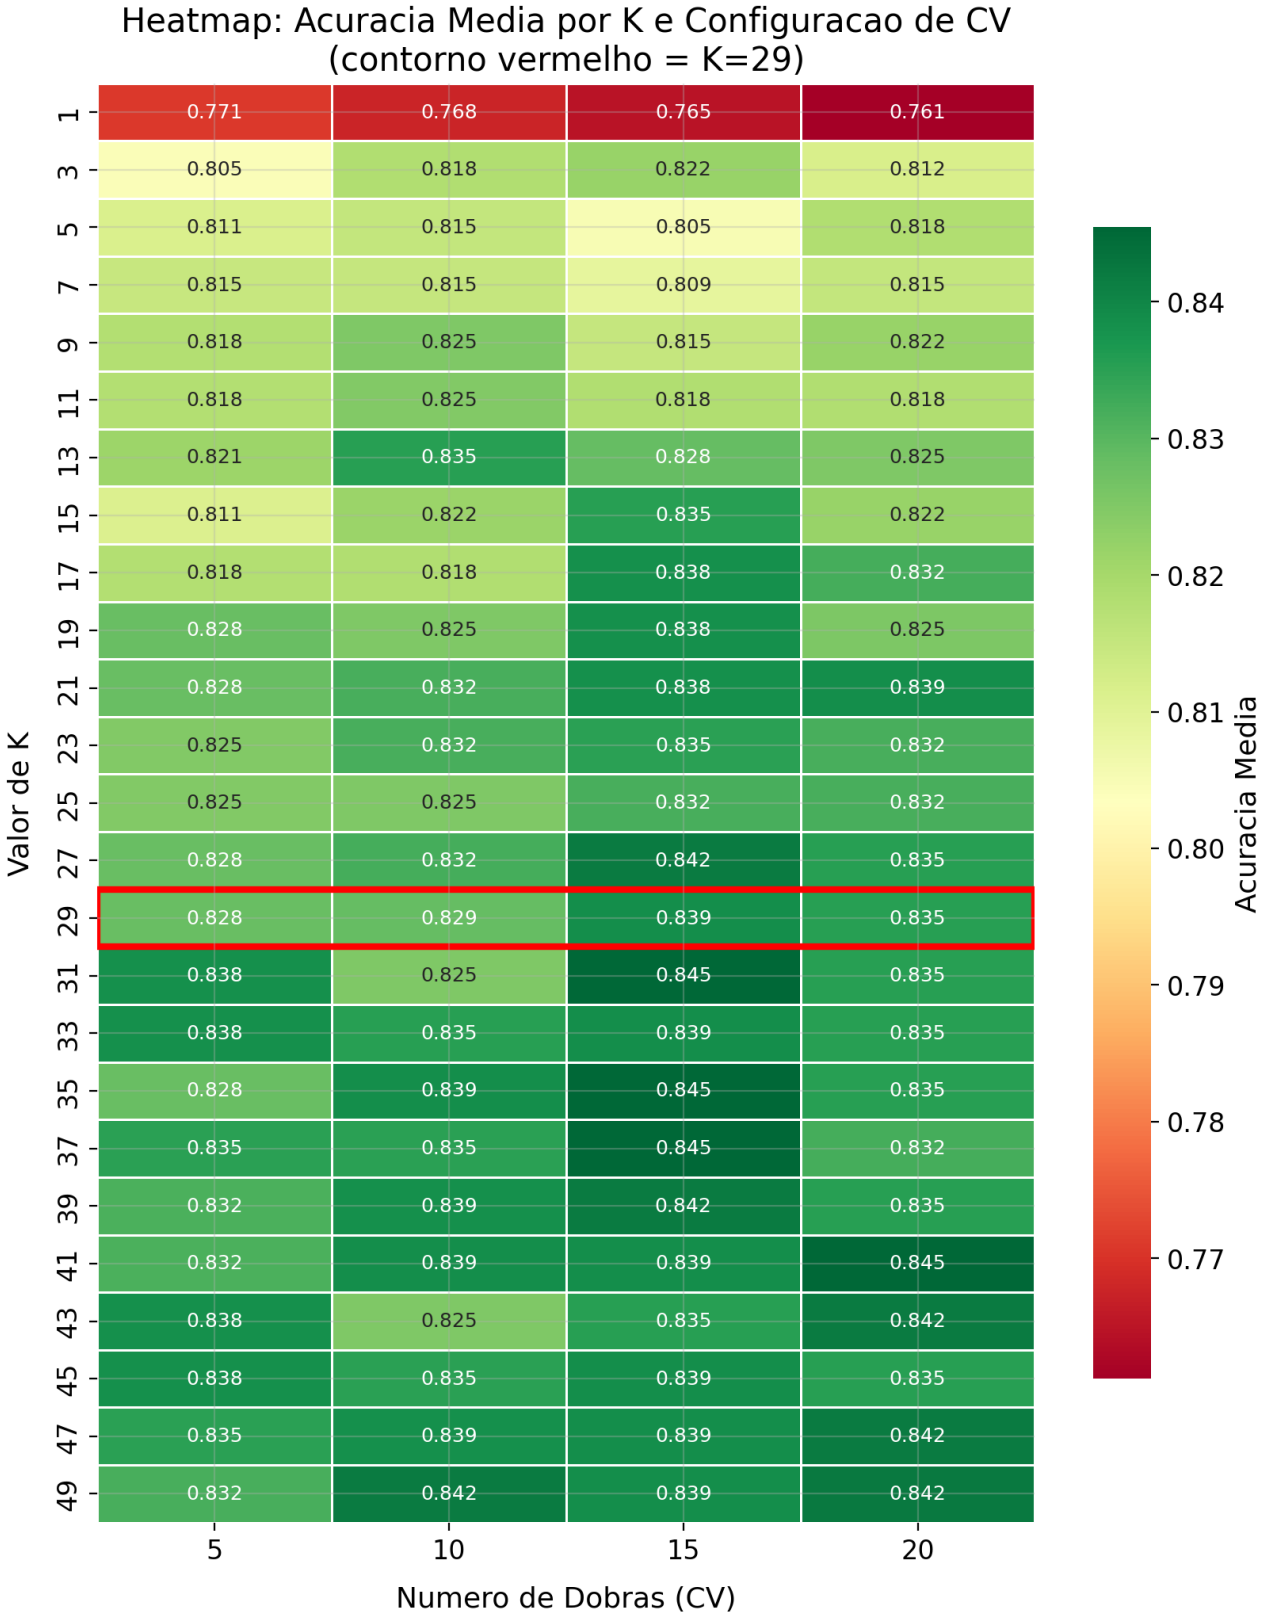

*Fonte: Gerado pelos autores com base nos dados experimentais.*

**Figura 4 -** Distribuicao da acuracia por fold: K=29 (ciano) vs todos os demais valores de K (cinza). K=29 apresenta mediana superior e distribuicao mais concentrada, demonstrando melhor desempenho tipico e menor variacao extrema.



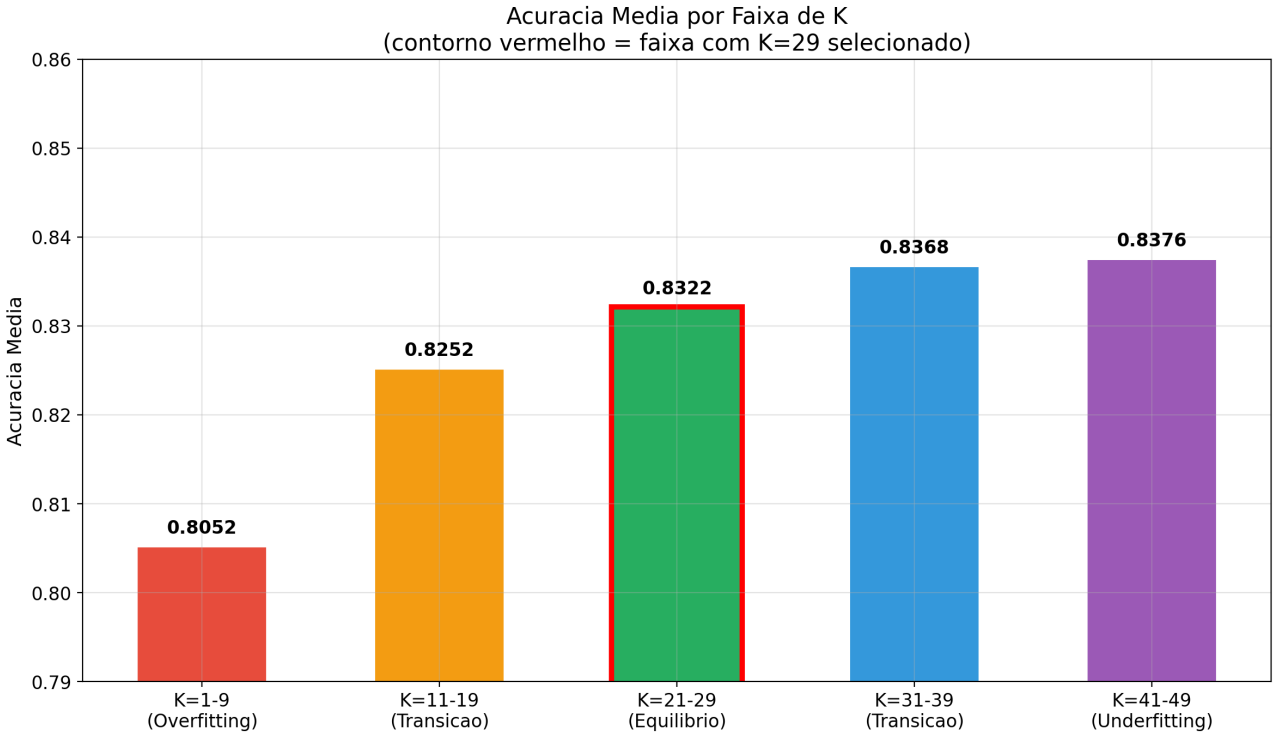

*Fonte: Gerado pelos autores com base nos dados experimentais.*

**Figura 5 -** Heatmap da acuracia media por valor de K (linhas) e numero de dobras de CV (colunas). O contorno vermelho destaca a linha K=29. Regioes mais verdes indicam maior acuracia; regioes mais vermelhas indicam menor desempenho.




*Fonte: Gerado pelos autores com base nos dados experimentais.*

**Figura 6 -** Acuracia media por faixa de K consolidada. A faixa K=21-29 (contorno vermelho) apresenta o melhor equilibrio entre acuracia e estabilidade. K=1-9 mostra overfitting (alta variabilidade); K=41-49 indica inicio de underfitting.




*Fonte: Gerado pelos autores com base nos dados experimentais.*

### 4.4 Analise do Trade-off Vies-Variancia

Para quantificar o trade-off vies-variancia, os valores de K foram agrupados em tres categorias e as metricas medias foram calculadas (Tabela 4).

**Tabela 4 - Analise do trade-off vies-variancia por faixa de K**

| Faixa de K | Acuracia Media | Variabilidade CV | Comportamento |
|---|---|---|---|
| K baixo (1-9) | 0,8020 | 0,0723 | Overfitting — alta variancia |
| K=29 (*) | 0,8328 | 0,0629 | Equilibrio ideal |
| K alto (31-49) | 0,8372 | 0,0617 | Inicio de underfitting |

*(*) K selecionado como ideal.*

Os dados confirmam que K=29 representa o ponto de inflexao: transicao da zona de overfitting (K baixo, alta variabilidade, baixa acuracia) para a zona de underfitting (K alto). A diferenca de acuracia media entre K=29 e a faixa K>29 e de apenas 0,44 pontos percentuais, enquanto o AUC-ROC de K=29 (0,9020) supera o de K=49 (0,8991) — o ganho marginal de acuracia nos Ks maiores e acompanhado por perda de capacidade discriminativa.

### 4.5 Resultados Finais com K=29

Com K=29 identificado como ideal, o modelo KNN foi avaliado em protocolo completo sobre o Cleveland Heart Disease Dataset (Tabela 5).

**Tabela 5 - Resumo de desempenho do KNN (K=29)**

| Metrica | Valor |
|---|---|
| Acuracia - conjunto de teste (hold-out 20%) | 86,67% |
| Acuracia - validacao cruzada 10-fold (ref.) | 82,86% +- 6,99% |
| AUC-ROC medio (analise parametrica) | 90,20% |
| Variabilidade CV (analise parametrica) | 0,0629 |
| Estabilidade entre configuracoes de CV | 0,0052 |
| K (numero de vizinhos) | 29 |
| Dataset utilizado | Cleveland UCI (n=297) |

*Fonte: Dados do experimento.*

A acuracia de 86,67% no conjunto de teste demonstra boa capacidade de generalizacao. A validacao cruzada de 10 dobras (82,86% +- 6,99%) representa a estimativa mais confiavel de desempenho esperado em dados reais — metrica de referencia recomendada para avaliacao honesta de classificadores (GERON, 2019). O AUC-ROC de 90,20% indica excelente poder discriminativo, especialmente relevante em triagem clinica onde o ponto de operacao pode ser ajustado conforme a sensibilidade clinica desejada.

### 4.6 Comparacao com a Literatura

A Tabela 6 contextualiza os resultados obtidos frente a estudos comparaveis da literatura que aplicaram o KNN e outros algoritmos ao Cleveland Heart Disease Dataset ou datasets similares.

**Tabela 6 - Comparacao com resultados da literatura**

| Estudo / Algoritmo | Dataset | Acuracia | Referencia |
|---|---|---|---|
| Este trabalho - KNN (K=29) | Cleveland UCI | 86,67% | — |
| Uddin et al. (2022) - KNN classico | 8 datasets UCI | 64-84% | UDDIN et al., 2022 |
| Uddin et al. (2022) - KNN ensemble | 8 datasets UCI | 82,34% | UDDIN et al., 2022 |
| Mienye e Sun (2022) - modelos ensemble | UCI variados | 80-95% | MIENYE; SUN, 2022 |

*Fonte: Uddin et al. (2022); Mienye e Sun (2022); dados do experimento.*

Os resultados de 86,67% superam a acuracia media reportada por Uddin et al. (2022) para o KNN classico avaliado em oito datasets de doencas (64-84%), demonstrando que a selecao sistematica de K via validacao cruzada multipla extrai o maximo potencial do algoritmo. O KNN ensemble de Uddin et al. (2022) obteve 82,34%, ainda abaixo dos 86,67% deste trabalho com K=29. Mienye e Sun (2022) reportam que metodos ensemble atingem ate 95%, indicando que a combinacao do KNN otimizado em estruturas ensemble representa um caminho natural de melhoria.

## 5 CONSIDERACOES FINAIS

Este trabalho apresentou uma analise sistematica e rigorosa da selecao do hiperparametro K no algoritmo K-Nearest Neighbors aplicado ao diagnostico de doencas cardiacas, utilizando o Cleveland Heart Disease Dataset com 297 registros e 13 atributos clinicos. A metodologia — avaliacao de 100 combinacoes (K, configuracao CV) com criterios de selecao multiplos — representa contribuicao metodologica relevante frente a pratica comum de selecao heuristica.

Os principais resultados sao: (i) K=29 e o parametro ideal, obtendo acuracia media consolidada de 83,28% e AUC-ROC de 90,20%, com variabilidade CV de 0,0629; (ii) a selecao sistematica supera a heuristica — K=5 obtem 81,25% e K=17 obtem 82,67% —, demonstrando o valor da busca exaustiva; (iii) o trade-off vies-variancia e claramente observavel: K=1 apresenta variabilidade 0,0851 e acuracia 76,61%, enquanto K=29 equilibra os dois componentes; (iv) a estabilidade de K=29 entre configuracoes de CV — variacao de apenas 1,06 pontos percentuais — e evidencia de robustez metodologica.

Como limitacoes: (i) tamanho moderado do dataset (297 registros) aumenta a variancia das estimativas; (ii) analise restrita ao Cleveland dataset; (iii) apenas distancia Euclidiana foi avaliada. Como trabalhos futuros, recomenda-se: (i) avaliar variantes do KNN identificadas por Uddin et al. (2022), como KNN adaptativo, fuzzy e Hassanat, que

mostraram ganhos sobre o KNN classico; (ii) combinar o KNN otimizado em modelos ensemble conforme revisado por Mienye e Sun (2022), potencialmente superando a barreira dos 88%; (iii) validar em datasets externos para verificar generalizacao clinica.

## REFERENCIAS


**GERON, Aurelien.** Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

**GIRALDI, Gilson Antonio.** Machine Learning and Pattern Recognition. Lecture Notes — Graduate Course. Graduate Program in Nanobiosystems 2021. Petropolist, RJ: UFRJ-Fiocruz-INMETRO-LNCC, 2021.

**MIENYE, I. D.; SUN, Y.** A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

**UDDIN, S.; HAQUE, I.; LU, H.; MONI, M. A.; GIDE, E.** Comparative performance analysis of K-nearest neighbour (KNN) algorithm and its different variants for disease prediction. Scientific Reports, v. 12, n. 6256, 2022. DOI: 10.1038/s41598-022-10358-x.