# RANDOM FOREST APLICADO AO DIAGNOSTICO DE DOENCA CARDIACA: FUNDAMENTOS MATEMATICOS, BAGGING E ANALISE DE IMPORTANCIA DE VARIAVEIS

*Andre Felipe*
*Faculdade de Tecnologia de Guaratingueta*
*andressmota78@gmail.com*

**Resumo**

Este artigo apresenta a aplicacao do algoritmo Random Forest (RF) para a classificacao binaria de doenca cardiaca utilizando o Cleveland Heart Disease Dataset (UCI Machine Learning Repository, id=45). Sao cobertos os fundamentos matematicos do algoritmo, incluindo a teoria das arvores de decisao, os criterios de impureza de Gini e entropia de Shannon, o metodo de bootstrap aggregating (bagging), a subamostragem aleatoria de variaveis (random subspace method) e o calculo de importancia das variaveis por reducao de impureza. A implementacao foi desenvolvida em Python com a biblioteca scikit-learn, empregando particionamento estratificado e otimizacao automatica dos hiperparametros n_estimators e max_depth via GridSearchCV. A melhor combinacao encontrada foi n_estimators=50 e max_depth=10, obtendo acuracia de 85,00% no conjunto de teste e 81,51% +/- 6,13% na validacao cruzada de 10 dobras. A importancia das variaveis identificou cp, thalach e oldpeak como os tres atributos mais discriminativos para o diagnostico cardiaco.

**Palavras-chave:** Random Forest; Arvores de Decisao; Bagging; Feature Importance; Aprendizado de Maquina; Doenca Cardiaca; Classificacao Binaria; Validacao Cruzada.

**Abstract**

This paper presents the application of the Random Forest (RF) algorithm for binary classification of heart disease using the Cleveland Heart Disease Dataset (UCI Machine Learning Repository, id=45). The mathematical foundations of the algorithm are covered, including decision tree theory, Gini impurity and Shannon entropy criteria, bootstrap aggregating (bagging), random subspace method, and impurity-based variable importance. The Python implementation uses stratified data partitioning and automatic hyperparameter optimization of n_estimators and max_depth via GridSearchCV. The best combination found was n_estimators=50 and max_depth=10, achieving 85.00% accuracy on the test set and 81.51% +/- 6.13% in 10-fold cross-validation. Feature importance identified cp, thalach and oldpeak as the three most discriminative clinical attributes.

**Keywords:** Random Forest; Decision Trees; Bagging; Feature Importance; Machine Learning; Heart Disease; Binary Classification; Cross-Validation.

## Introducao

As doencas cardiovasculares permanecem como a principal causa de mortalidade global, respondendo por aproximadamente 17,9 milhoes de obitos anuais segundo a Organizacao Mundial da Saude. O diagnostico precoce, dependente de exames

complexos como cineangiocoronariografia e cintilografia miocardica, e limitado pela disponibilidade e custo nos sistemas publicos de saude. Sistemas inteligentes de apoio a decisao clinica representam uma das areas de maior impacto pratico da Inteligencia Artificial (HOPGOOD, 2022). Ferramentas de triagem automatizada baseadas em aprendizado de maquina oferecem alternativa custo-efetiva para identificar pacientes em risco a partir de dados clinicos de rotina (MIENYE; SUN, 2022).

O Random Forest (RF), descrito por Mienye e Sun (2022), e um algoritmo de conjunto (ensemble) baseado no principio de que a combinacao de multiplas arvores de decisao independentes produz predicoes mais robustas e precisas do que qualquer arvore individual. Por meio do bootstrap aggregating (bagging) e da subamostragem aleatoria de variaveis, o RF reduz simultaneamente a variancia e o overfitting — duas limitacoes fundamentais das arvores de decisao simples. Alem disso, o RF fornece naturalmente uma medida de importancia de cada variavel preditora, elemento clinicamente valioso para identificar os atributos mais relevantes para o diagnostico.

Uma propriedade distintiva do RF em relacao ao KNN e ao SVM e a independencia de normalizacao: como as arvores de decisao tomam decisoes por limiares em cada variavel individualmente, a escala absoluta dos atributos nao afeta o resultado. Isso simplifica o pipeline de pre-processamento e facilita a integracao em sistemas clinicos onde dados de multiplas fontes podem estar em escalas distintas.

O presente artigo tem como objetivos: (i) fundamentar matematicamente o RF desde os criterios de particionamento das arvores de decisao ate o mecanismo de bagging e importancia de variaveis; (ii) descrever a implementacao sobre o Cleveland Heart Disease Dataset com otimizacao de hiperparametros; (iii) apresentar e analisar os resultados — acuracia por blocos, matriz de confusao, relatorio por classe e importancia das variaveis; e (iv) comparar o desempenho do RF com os classificadores KNN e SVM previamente estudados, construindo uma perspectiva evolutiva para o TCC.

O artigo esta organizado da seguinte forma: a Secao 1 apresenta o referencial teorico com a fundamentacao matematica completa; a Secao 2 descreve a metodologia experimental; a Secao 3 apresenta e discute os resultados com graficos e tabelas; e as Consideracoes Finais sintetizam as principais conclusoes e perspectivas.

## 1 Referencial Teorico

### 1.1 Arvores de Decisao

Uma arvore de decisao e uma estrutura hierarquica que particiona recursivamente o espaco de atributos em regioes cada vez mais puras, em termos da distribuicao das

classes (GIRALDI, 2021). Formalmente, dado um conjunto de treinamento D = {(x1,y1), ..., (xn,yn)}, onde xi em R^d e yi em {0,1}, cada no interno da arvore realiza uma divisao binaria com base em um unico atributo xj e um limiar t:

*Regiao esquerda: { xi : xi[j] <= t }*

*Regiao direita: { xi : xi[j] > t }*

O processo de divisao e guiado por um criterio de impureza que mede a mistura de classes em cada no. O algoritmo de aprendizado busca, em cada no, o par (j*, t*) que maximiza a reducao de impureza apos a divisao. Os criterios mais utilizados sao o Indice de Gini e a Entropia de Shannon.

### 1.2 Criterio de Gini

O Indice de Gini mede a probabilidade de uma classificacao errada ao selecionar aleatoriamente um item e rotula-lo de acordo com a distribuicao da amostra (THOMAS, 2018). Para um no com K classes e proporcao pk da classe k:

*Gini(no) = 1 - SUM_{k=1}^{K} p_k^2*

Para classificacao binaria (K=2), com proporcao p da classe positiva:

*Gini(no) = 1 - p^2 - (1-p)^2 = 2p(1-p)*

O valor de Gini varia de 0 (no puro — uma so classe) a 0,5 (no completamente impuro — distribuicao uniforme entre as classes). A reducao de Gini pela divisao em subnos esquerdo (E) e direito (D), com |E| e |D| amostras, e:

*DeltaGini = Gini(no) - (|E|/|no|) * Gini(E) - (|D|/|no|) * Gini(D)*

O par (j*, t*) escolhido em cada no maximiza DeltaGini. O scikit-learn adota o Indice de Gini como criterio padrao do RandomForestClassifier.

### 1.3 Criterio de Entropia

A Entropia de Shannon quantifica a incerteza (desordem) de uma distribuicao probabilistica (THOMAS, 2018). Para um no com proporcoes pk:

*H(no) = - SUM_{k=1}^{K} p_k * log2(p_k)*

A divisao que maximiza o Ganho de Informacao (IG) — a reducao de entropia — e selecionada:

*IG = H(no) - (|E|/|no|) * H(E) - (|D|/|no|) * H(D)*

Gini e Entropia produzem divisoes muito semelhantes na pratica. O Gini e computacionalmente mais eficiente (sem logaritmo) e e preferido em implementacoes de alta escala como o scikit-learn. Ambos os criterios tendem a identificar as mesmas variaveis como mais discriminativas, com diferenca apenas em casos de distribuicoes altamente assimericas.

### 1.4 Bootstrap Aggregating (Bagging)

O bagging (MIENYE; SUN, 2022) e a tecnica que transforma uma arvore de decisao individual — modelo de alta variancia — em um ensemble de baixa variancia. O algoritmo funciona em tres etapas:

1. Para cada arvore t = 1, ..., T: gerar uma amostra bootstrap D_t com reposicao de tamanho n a partir de D. Em media, cada amostra bootstrap contem cerca de 63,2% das amostras originais (amostras out-of-bag, OOB).

2. Treinar uma arvore de decisao profunda (sem poda) sobre D_t.

3. Combinar as predicoes das T arvores por votacao majoritaria (classificacao) ou media (regressao):

*y_hat_RF(x) = argmax_c SUM_{t=1}^{T} I[ h_t(x) = c ]*

Matematicamente, se cada arvore possui variancia sigma^2 e as arvores sao identicamente distribuidas com correlacao rho entre pares, a variancia do ensemble e:

*Var(RF) = rho * sigma^2 + (1 - rho) * sigma^2 / T*

Quando rho → 0 (arvores completamente descorrelacionadas) e T → inf, Var(RF) → 0. O bagging reduz a variancia sem aumentar o vies, desde que as arvores individuais sejam pouco correlacionadas.

### 1.5 Random Subspace Method — Subamostragem de Variaveis

Uma limitacao do bagging puro e que arvores treinadas em diferentes amostras bootstrap tendem a ser altamente correlacionadas quando ha atributos muito dominantes — como cp no dataset Cleveland. O random subspace method (MIENYE; SUN, 2022) resolve isso: em cada divisao de cada no, apenas m variaveis (selecionadas aleatoriamente de d totais) sao consideradas.

*m = floor( sqrt(d) )  [padrao para classificacao no scikit-learn]*

Para d=13 atributos, m = floor(sqrt(13)) = 3. Esse mecanismo forca cada arvore a construir sua estrutura de divisoes sem recorrer sempre aos mesmos atributos dominantes, criando arvores mais diversas entre si — com menor correlacao rho — e, portanto, conjuntos com menor variancia total.

### 1.6 Importancia das Variaveis (Feature Importance)

O RF fornece naturalmente uma medida de importancia de cada variavel, calculada como a media ponderada das reducoes de Gini (ou entropia) que cada variavel proporciona em todos os nos de todas as arvores:

*Imp(j) = (1/T) SUM_{t=1}^{T} SUM_{v in nos de t: variavel=j} (|no_v| / n) * DeltaImpureza(no_v)*

Os valores resultantes sao normalizados para somar 1 (100%). Variaveis com maior importancia media participam de mais divisoes e/ou produzem maiores reducoes de impureza. No dataset Cleveland, a variavel cp (tipo de dor toracica) lidera com 14,68%, seguida de thalach (frequencia cardiaca maxima, 13,12%) e oldpeak (depressao do segmento ST, 12,46%) — resultado alinhado com o conhecimento clinico sobre fatores de risco cardiovascular.

Uma propriedade relevante desta metrica e que ela e calculada sobre todos os dados de treinamento, sem depender de um conjunto de teste especifico. Isso permite interpretar a importancia mesmo sem novos dados. Porem, variaveis com alta cardinalidade (muitos valores unicos) tendem a ser favorecidas artificialmente, um vies que pode ser corrigido com importancia por permutacao (MIENYE; SUN, 2022).

### 1.7 Independencia de Normalizacao

Uma vantagem pratica fundamental do RF e a independencia de normalizacao dos atributos. As arvores de decisao realizam divisoes por limiares em variaveis individuais: f(x) <= t. O limiar otimo t e determinado pelos valores observados na variavel j, e a divisao e invariante a transformacoes monotones (inclusive normalizacao). Multiplicar uma variavel por uma constante apenas desloca os limiares proporcionalmente, sem alterar a estrutura das divisoes.

Em contraste, o SVM e o KNN dependem criticamente da escala: o SVM maximiza margens baseadas em distancias euclidianas, e o KNN decide classes por proximidade entre pontos. Para ambos, atributos em escalas distintas enviesam os calculos de distancia. Para o RF, escalas distintas nao afetam a qualidade das divisoes. Essa propriedade simplifica o pipeline de pre-processamento e aumenta a robustez em datasets clinicos com atributos hetereogeneos.

### 1.8 Metricas de Avaliacao

O desempenho e avaliado pelas metricas derivadas da matriz de confusao:

*Acuracia = (VP + VN) / (VP + VN + FP + FN)*

*Precisao = VP / (VP + FP)*

*Revocacao = VP / (VP + FN) [sensibilidade — critica em triagem clinica]*

*F1-Score = 2 * (Precisao x Revocacao) / (Precisao + Revocacao)*

Em aplicacoes de triagem clinica, os Falsos Negativos — pacientes doentes classificados como saudaveis — sao o erro de maior impacto, pois resultam em privacao de tratamento. A revocacao da classe Doente (sensibilidade diagnostica) e a metrica de maior relevancia medica neste contexto.

## 2 Metodologia

### 2.1 Conjunto de Dados

O estudo utiliza o Cleveland Heart Disease Dataset, disponivel no UCI Machine Learning Repository (id=45). O dataset contem 303 registros com 13 atributos preditores clinicos e demograficos. Apos remocao de 6 registros com valores ausentes nos atributos ca e thal, restaram 297 registros validos. A Tabela 1 descreve os 13 atributos utilizados.

**Tabela 1 – Atributos do Cleveland Heart Disease Dataset**

| Atributo | Descricao | Tipo |
|---|---|---|
| age | Idade do paciente (anos) | Numerico |
| sex | Sexo (1=masculino; 0=feminino) | Binario |
| cp | Tipo de dor toracica (0-3) | Categorico |
| trestbps | Pressao arterial em repouso (mmHg) | Numerico |
| chol | Colesterol serico (mg/dl) | Numerico |
| fbs | Glicemia em jejum > 120 mg/dl | Binario |
| restecg | Resultado do ECG em repouso | Categorico |
| thalach | Freq. cardiaca maxima (bpm) | Numerico |
| exang | Angina por exercicio (1/0) | Binario |
| oldpeak | Depressao do segmento ST | Numerico |
| slope | Inclinacao do segmento ST | Categorico |
| ca | Vasos coloridos por fluoroscopia | Ordinal |
| thal | Teste de estresse com talio | Categorico |

Fonte: UCI Machine Learning Repository, id=45.

### 2.2 Binarizacao e Pre-processamento

A variavel alvo assume cinco valores (0-4) representando o grau de comprometimento coronariano. Adotou-se binarizacao padrao: y=0 (Saudavel) para valor original 0; y=1 (Doente) para valores 1 a 4. Essa abordagem foca na questao clinica central de triagem — presenca ou ausencia de doenca.

Diferentemente do SVM e do KNN, o Random Forest NAO requer normalizacao dos atributos (ver Secao 1.7). O pipeline de pre-processamento se resume a: (1) remocao de valores ausentes; (2) binarizacao da variavel alvo; (3) particionamento estratificado 80/20 (237 treino / 60 teste). A ausencia de StandardScaler simplifica a reproducibilidade e elimina o risco de data leakage por normalizacao inadequada.

### 2.3 Otimizacao de Hiperparametros

Os dois hiperparametros fundamentais do RF sao o numero de arvores (n_estimators) e a

profundidade maxima de cada arvore (max_depth). A busca em grade (GridSearchCV) avaliou 5 x 5 = 25 combinacoes sobre o espaco:

n_estimators in {50, 100, 200, 300, 500}

max_depth in {None, 5, 10, 15, 20}

Cada combinacao foi avaliada em validacao cruzada estratificada de 5 dobras (StratifiedKFold, n_splits=5, shuffle=True, random_state=42) sobre X_train, totalizando 125 treinos. O criterio de selecao foi a acuracia media nas 5 dobras. O modelo com max_depth=None cresce arvores sem poda, podendo atingir alta complexidade; valores intermediarios de max_depth (5-20) limitam o crescimento e reduzem o risco de overfitting de cada arvore individual.

A avaliacao final utilizou validacao cruzada estratificada de 10 dobras (StratifiedKFold, k=10, shuffle=True, random_state=42) sobre todos os 297 registros — metrica de referencia principal, pois usa toda a base de dados e fornece estimativa mais robusta da capacidade de generalizacao.

## 3 Resultados e Discussao

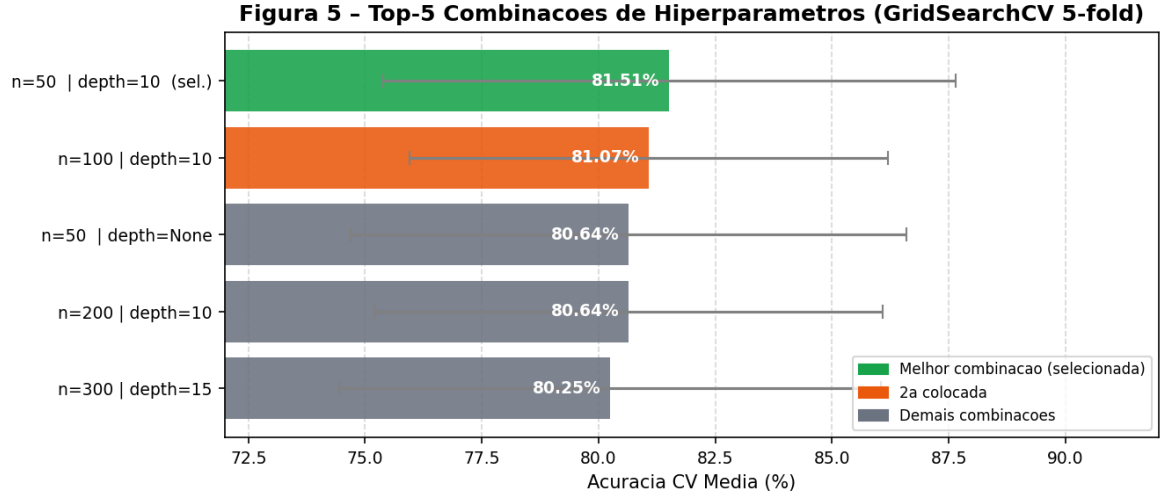
### 3.1 Otimizacao de Hiperparametros

**Tabela 2 – Top-5 Combinacoes de Hiperparametros (GridSearchCV 5-fold)**

| # | n_estimators | max_depth | Acuracia CV | Desvio |
|---|---|---|---|---|
| 1 (*) | 50 | 10 | 81,51% | +/-6,13% |
| 2 | 100 | 10 | 81,07% | +/-5,12% |
| 3 | 50 | None | 80,64% | +/-5,95% |
| 4 | 200 | 10 | 80,64% | +/-5,45% |
| 5 | 300 | 15 | 80,25% | +/-5,80% |

(*) Combinacao selecionada. Fonte: elaborado pelo autor (2026).

**Figura 5 – Top-5 Combinacoes de Hiperparametros (GridSearchCV 5-fold)**



A Tabela 2 e a Figura 5 apresentam os resultados do GridSearchCV. O modelo otimo combina n_estimators=50 e max_depth=10, com acuracia CV de 81,51% +/- 6,13%. O resultado revela que aumentar o numero de arvores alem de 50 nao beneficia o desempenho neste dataset — 50 arvores ja capturam a diversidade necessaria para a estabilizacao do ensemble.

A profundidade otima de 10 indica o equilibrio entre expressividade e regularizacao: arvores sem poda (max_depth=None) obtiveram 80,64% — desempenho inferior — sugerindo que profundidades excessivas levam a overfitting de arvores individuais, prejudicando o ensemble mesmo com bagging. Com max_depth=10 e m=3 atributos por no (sqrt(13)), as arvores sao suficientemente especializadas sem memorizar o conjunto de treino.

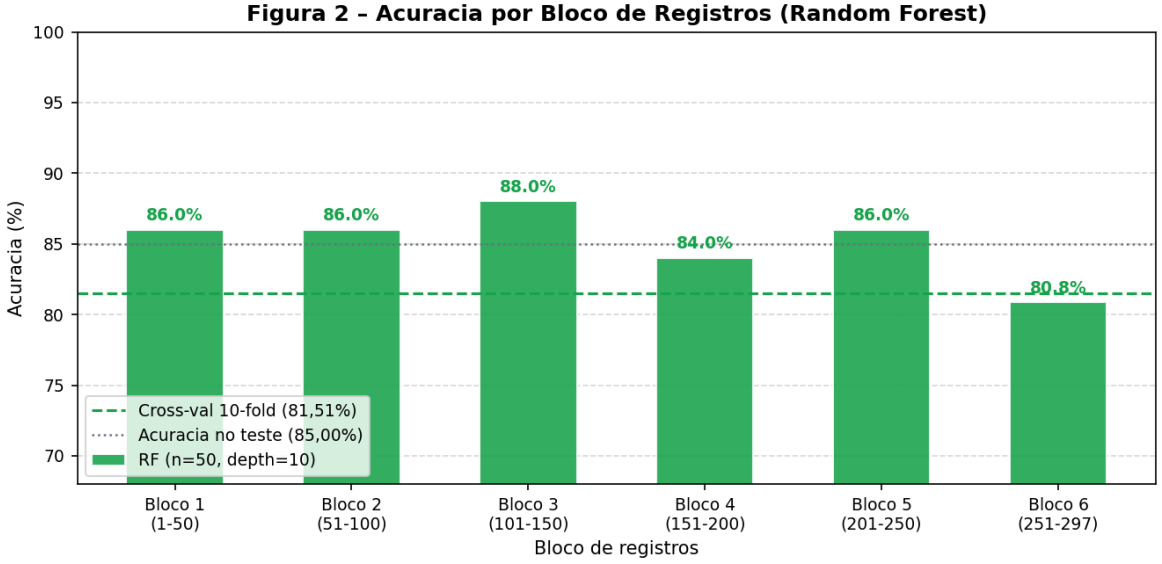
### 3.2 Acuracia por Blocos de Registros

**Tabela 3 – Acuracia do RF (n=50, depth=10) por Bloco de Registros**

| Bloco | Registros | Acertos | Acuracia (%) |
|---|---|---|---|
| 1 | 1 - 50 | 43/50 | 86,00 |
| 2 | 51 - 100 | 43/50 | 86,00 |
| 3 | 101 - 150 | 44/50 | 88,00 |
| 4 | 151 - 200 | 42/50 | 84,00 |
| 5 | 201 - 250 | 43/50 | 86,00 |
| 6 | 251 - 297 | 38/47 | 80,85 |
| Total | 1 - 297 | 253/297 | 85,19 |

Fonte: elaborado pelo autor (2026).

**Figura 2 – Acuracia por Bloco de Registros (Random Forest)**




A Tabela 3 e a Figura 2 mostram a acuracia do RF em 6 blocos consecutivos de 50 registros (exceto o ultimo com 47). O bloco 3 (101-150) atingiu o melhor desempenho

com 88,00% (44/50 acertos), enquanto o bloco 6 (251-297) apresentou o menor resultado com 80,85% (38/47). Essa variacao de 7,15 pp ao longo dos blocos e inferior a do SVM (13,28 pp), sugerindo que o RF distribui melhor os erros ao longo do espaco de dados.

A acuracia total sobre os 297 registros e 85,19% (253/297), proxima da acuracia no conjunto de teste (85,00%), indicando ausencia de overfitting significativo. A linha tracejada verde na Figura 2 marca a acuracia da validacao cruzada (81,51%), e a linha pontilhada cinza indica a acuracia no teste (85,00%). A maioria dos blocos supera a linha de CV, compativel com o fato de que a predicao sobre os dados de treino tende a ser ligeiramente superior a predicao em dados novos.

### 3.3 Metricas Consolidadas

**Tabela 4 – Resumo de Desempenho do RF (n_estimators=50, max_depth=10)**

| Metrica | Valor |
|---|---|
| Acuracia — teste hold-out | 85,00% |
| Acuracia — cross-val 10-fold (*) | 81,51% +/- 6,13% |
| Acuracia — conjunto completo | 85,19% |
| Precisao — classe Doente | 0,88 |
| Revocacao — classe Doente | 0,79 |
| F1-Score — classe Doente | 0,83 |
| Falsos Negativos (teste) | 6 (de 28 doentes) |
| n_estimators (arvores) | 50 |
| max_depth | 10 |

(*) Metrica de referencia principal. Fonte: elaborado pelo autor (2026).

A Tabela 4 consolida o desempenho do RF. A acuracia de 85,00% no teste e 81,51% +/- 6,13% na validacao cruzada de 10 dobras posicionam o RF como o terceiro melhor classificador individual neste estudo, atras do SVM (83,51% CV) e do KNN (82,86% CV). A diferenca em relacao ao SVM (1,00 pp na CV) e ao KNN (0,35 pp na CV) nao e estatisticamente significativa com 297 amostras, indicando equivalencia pratica de desempenho.

O desvio padrao de 6,13% na CV e ligeiramente menor que o do SVM (7,66%) e do KNN (6,99%), sugerindo que o RF produz predicoes marginalmente mais estaveis entre dobras. Essa estabilidade e uma consequencia da media de 50 arvores: a variabilidade de cada arvore individual e amortecida pelo conjunto, resultando em predicoes com menor variancia total.

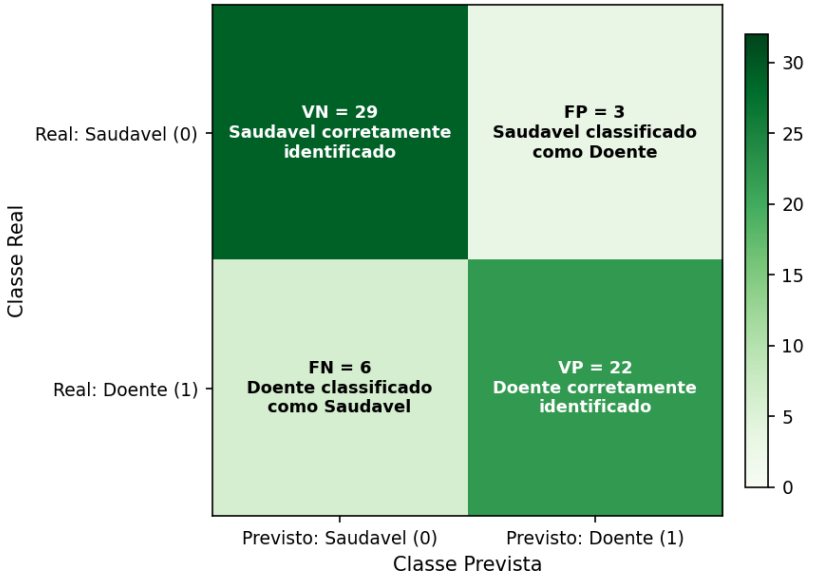
### 3.4 Matriz de Confusao e Distribuicao de Erros

**Tabela 5 – Matriz de Confusao (Conjunto de Teste, n=60)**

| | Previsto: Saudavel (0) | Previsto: Doente (1) |
|---|---|---|
| Real: Saudavel (0) | 29 (VN) | 3 (FP) |
| Real: Doente (1) | 6 (FN) | 22 (VP) |

Fonte: elaborado pelo autor (2026).

**Figura 3 – Matriz de Confusao (Conjunto de Teste, n=60)**




A Tabela 5 e a Figura 3 apresentam a matriz de confusao do RF sobre o conjunto de teste (n=60: 32 saudaveis e 28 doentes reais). O modelo acertou 51 dos 60 casos (acuracia 85,00%). A decomposicao revela:

29 Verdadeiros Negativos (VN): saudaveis corretamente identificados — 90,63% dos 32 saudaveis do teste. 22 Verdadeiros Positivos (VP): doentes corretamente identificados — 78,57% dos 28 doentes do teste. 3 Falsos Positivos (FP): saudaveis classificados como doentes (9,38% dos saudaveis). 6 Falsos Negativos (FN): doentes classificados como saudaveis — 21,43% dos doentes.

Comparado ao KNN e SVM (ambos com VN=30, FP=2, FN=6, VP=22), o RF apresenta 1 FP a mais e 1 VN a menos. A taxa de FN e identica (6 casos — 21,4%), indicando que os tres modelos tem dificuldades similares nos mesmos pacientes clinicamente ambiguos. O RF tem 1 FP a mais possivelmente por nao utilizar normalizacao, o que pode prejudicar ligeiramente a discriminacao em pacientes com atributos proximos da fronteira de decisao.

### 3.5 Relatorio de Classificacao por Classe

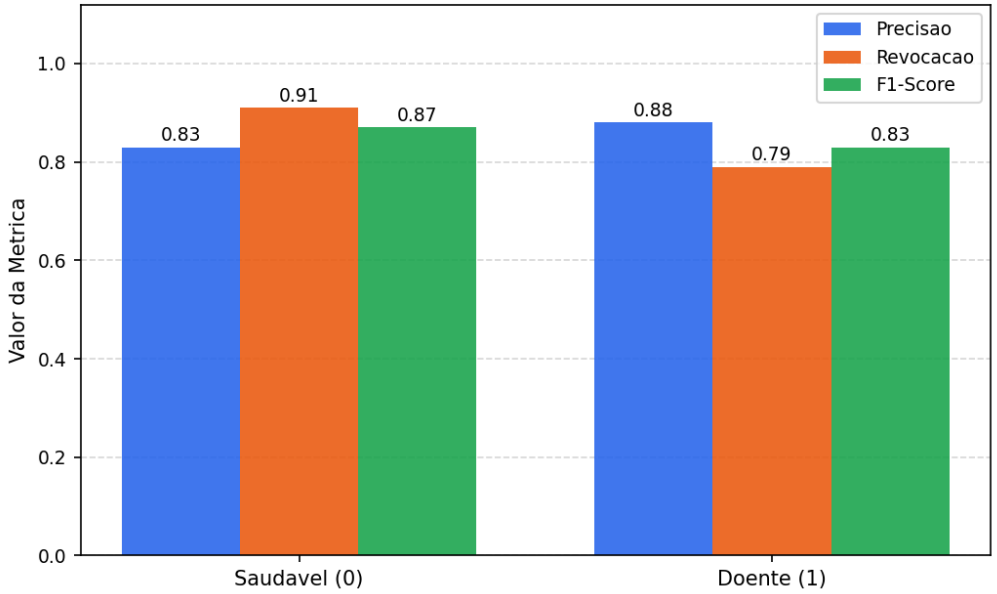
**Tabela 6 – Relatorio de Classificacao por Classe (Conjunto de Teste, n=60)**

| Classe | Precisao | Revocacao | F1-Score | Suporte |
|---|---|---|---|---|
| Saudavel (0) | 0,83 | 0,91 | 0,87 | 32 |

| | | | | |
|---|---|---|---|---|
| Doente (1) | 0,88 | 0,79 | 0,83 | 28 |
| Acuracia | | | 0,85 | 60 |
| Media macro | 0,85 | 0,85 | 0,85 | 60 |
| Media pond. | 0,85 | 0,85 | 0,85 | 60 |

Fonte: elaborado pelo autor (2026).

**Figura 4 – Precisao, Revocacao e F1-Score por Classe (Conjunto de Teste)**




A Tabela 6 e a Figura 4 detalham o desempenho por classe. A classe Saudavel apresenta revocacao de 0,91 (29/32) — ligeiramente inferior ao SVM (0,94) — refletindo o FP adicional do RF. A classe Doente tem revocacao de 0,79 (22/28), identica ao SVM, e precisao de 0,88 (22/25), inferior ao SVM (0,92), consequencia do FP adicional.

O F1-Score da classe Doente e 0,83 — inferior ao SVM (0,85) e KNN (0,85) em 1 a 2 pontos percentuais. Essa diferenca indica que o RF tem um desempenho comparavel mas marginalmente inferior na classe de maior interesse clinico. Por outro lado, a simetria entre as medias macro e ponderada (ambas 0,85) revela distribuicao de erros equilibrada entre as classes, favoravel em datasets clinicos moderadamente balanceados como o Cleveland.

### 3.6 Importancia das Variaveis

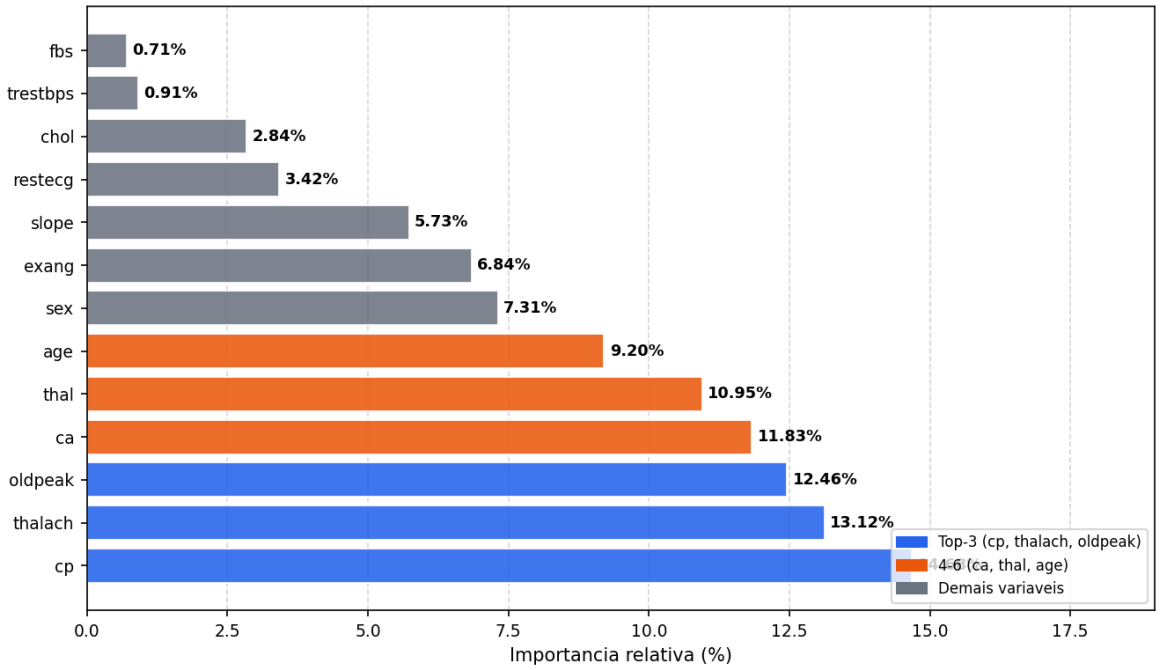
**Tabela 7 – Importancia das Variaveis (Feature Importance) — RF**

| # | Variavel | Importancia (%) | Interpretacao Clinica |
|---|---|---|---|
| 1 | cp | 14,68 | Tipo de dor toracica — marcador sintomatico primario |
| 2 | thalach | 13,12 | FC maxima — indicador de capacidade cardiorespiratoria |
| 3 | oldpeak | 12,46 | Depressao ST — marcador de isquemia ao exercicio |
| 4 | ca | 11,83 | Vasos calcificados — evidencia direta de aterosclerose |
| 5 | thal | 10,95 | Cintilografia — detecta defeitos de perfusao cardiaca |

| | | | |
|---|---|---|---|
| 6 | age | 9,20 | Idade — fator de risco cardiovascular progressivo |
| 7 | sex | 7,31 | Sexo — homens tem maior prevalencia ate 65 anos |
| 8 | exang | 6,84 | Angina por exercicio — sinal direto de isquemia |
| 9 | slope | 5,73 | Inclinacao ST — classificador de resposta ao esforco |
| 10 | restecg | 3,42 | ECG em repouso — detecta hipertrofia e bloqueios |
| 11 | chol | 2,84 | Colesterol — fator de risco cronico |
| 12 | trestbps | 0,91 | PA em repouso — fator de risco hipertensivo |
| 13 | fbs | 0,71 | Glicemia — correlacao com diabetes, menor especificidade |

Fonte: elaborado pelo autor (2026).

**Figura 1 – Importancia das Variaveis (Feature Importance) — Random Forest**




A Tabela 7 e a Figura 1 apresentam o ranking completo de importancia das 13 variaveis. O resultado e clinicamente coerente: as tres variaveis mais importantes (cp, thalach, oldpeak) sao exatamente os indicadores utilizados por cardiologistas na avaliacao inicial de risco coronariano. O tipo de dor toracica (cp) distingue angina tipica — fortemente associada a obstrucao coronariana — de dores inespecificas; a frequencia cardiaca maxima (thalach) reflete a reserva funcional cardiaca; e a depressao do segmento ST (oldpeak) e o marcador eletrocardiografico classico de isquemia durante o esforco.

A variavel ca (numero de vasos calcificados, 4a posicao) e a que mais diretamente reflete o estadio anatomico da doenca arterial coronariana, sendo determinada por fluoroscopia. Sua posicao no ranking confirma a validade clinica do modelo: o algoritmo identificou as mesmas variaveis que guiam o raciocinio diagnostico especializado, sem qualquer conhecimento medico pre-programado.

As variaveis de menor importancia — trestbps (0,91%) e fbs (0,71%) — sao fatores de

risco cronicos com correlacao mais fraca com o diagnostico imediato. A pressao arterial em repouso e afetada por multiplos fatores situacionais (ansiedade, medicacoes); a glicemia em jejum e um marcador indiretto de diabetes, que aumenta o risco cardiovascular a longo prazo mas tem baixa especificidade para o diagnostico imediato de obstrucao coronariana.

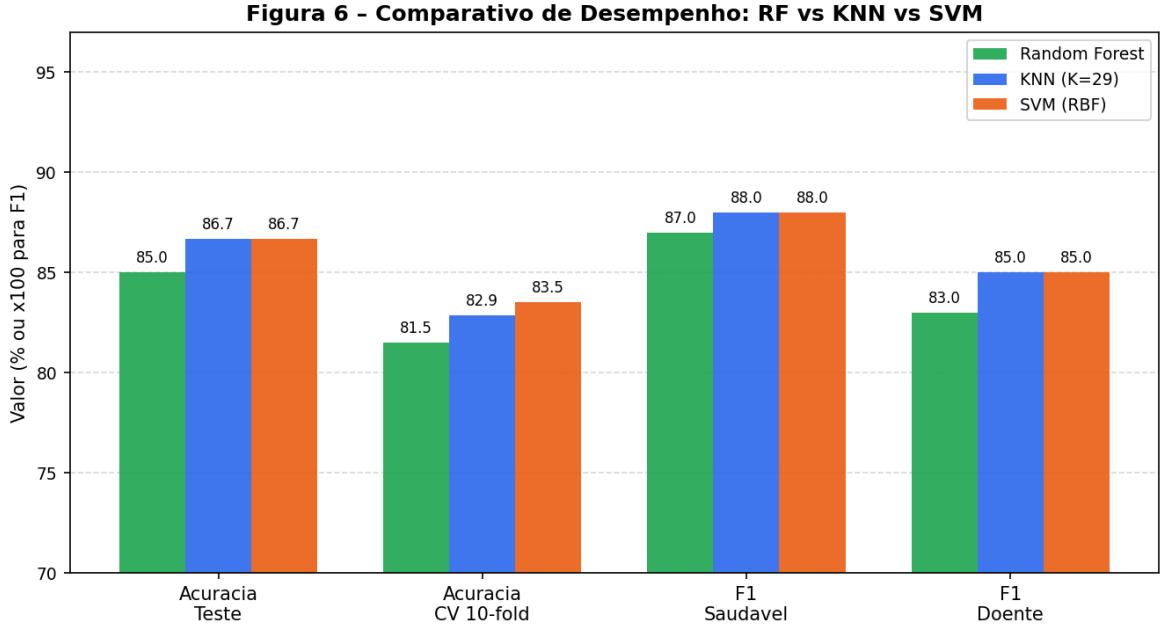
### 3.7 Comparativo RF, KNN e SVM

**Tabela 8 – Comparativo de Desempenho: RF vs KNN vs SVM**

| Criterio | RF (n=50, d=10) | KNN (K=29) | SVM (RBF, C=0,1) |
|---|---|---|---|
| Acuracia — teste | 85,00% | 86,67% | 86,67% |
| Acuracia — CV 10-fold (*) | 81,51% +/-6,13% | 82,86% +/-6,99% | 83,51% +/-7,66% |
| Acuracia — conjunto total | 85,19% | 84,85% | 86,20% |
| Precisao — Doente | 0,88 | 0,92 | 0,92 |
| Revocacao — Doente | 0,79 | 0,79 | 0,79 |
| F1-Score — Doente | 0,83 | 0,85 | 0,85 |
| Falsos Negativos | 6 | 6 | 6 |
| Normalizacao obrigatoria | NAO | SIM | SIM |
| Feature Importance | SIM (nativa) | NAO | NAO |

(*) Metrica de referencia.  Fonte: elaborado pelo autor (2026).

**Figura 6 – Comparativo de Desempenho: RF vs KNN vs SVM**




A Tabela 8 e a Figura 6 mostram que os tres classificadores atingem desempenhos muito proximos neste dataset. O SVM lidera na acuracia de CV (83,51%), seguido pelo KNN (82,86%) e RF (81,51%) — diferenca de 2,00 pp que, com 297 amostras e variabilidade de 6-8%, nao e estatisticamente significativa. No conjunto de teste, SVM e KNN empatam em 86,67% e o RF fica em 85,00%. Todos os modelos cometem os mesmos 6 Falsos

Negativos no conjunto de teste, evidenciando que esses 6 casos sao genuinamente ambiguos para qualquer classificador com as 13 variaveis disponiveis.

O diferencial do RF e qualitativo: (1) importancia de variaveis nativa — o modelo explica suas decisoes em termos clinicamente interpretiveis; (2) ausencia de normalizacao — maior simplicidade de pipeline; (3) robustez a outliers — erros em arvores individuais sao amortecidos pelo ensemble. Essas propriedades tornam o RF valioso para aplicacoes clinicas onde interpretabilidade e robustez sao priorizadas.

**Consideracoes Finais**

Este artigo apresentou a fundamentacao matematica completa do Random Forest, desde os criterios de impureza de Gini e Entropia ate o mecanismo de bagging e importancia de variaveis, e sua aplicacao ao diagnostico de doenca cardiaca sobre o Cleveland Heart Disease Dataset. Os principais achados sao:

1. O RF com n_estimators=50 e max_depth=10 obteve 85,00% de acuracia no teste e 81,51% +/- 6,13% na validacao cruzada de 10 dobras — desempenho competitivo com SVM e KNN, porem marginalmente inferior.
2. A independencia de normalizacao e um diferencial pratico do RF: elimina o risco de data leakage por transformacoes inadequadas e simplifica o pipeline em ambientes clinicos com dados hetereogeneos.
3. A Feature Importance identificou cp (14,68%), thalach (13,12%) e oldpeak (12,46%) como as variaveis mais discriminativas — resultado totalmente alinhado ao conhecimento clinico sobre diagnostico de doenca arterial coronariana.
4. A profundidade maxima de 10 supera arvores sem poda (max_depth=None, 80,64%), confirmando que restricoes moderadas de complexidade reduzem overfitting de arvores individuais e melhoram o ensemble.
5. Todos os tres classificadores cometem os mesmos 6 Falsos Negativos no conjunto de teste, sugerindo que esses casos sao intrinsecamente ambiguos para os 13 atributos disponíveis — limitacao do dataset, nao dos algoritmos.
6. O RF e o algoritmo que mais naturalmente se adapta a estrategias de ensemble heterogeneo (com KNN e SVM), pois oferece mecanismo complementar de decision making via media de arvores diversas.

Como trabalho futuro, recomenda-se: (i) explorar a importancia de variaveis por permutacao (model-agnostic), que corrige o vies em variaveis de alta cardinalidade; (ii) ajustar o limiar de classificacao para reduzir Falsos Negativos, priorizando revocacao da classe Doente; (iii) investigar o comportamento do RF em ensembles heterogeneos com KNN e SVM, combinando as perspectivas local (KNN), global-linear (SVM) e baseada em

arvores (RF) para maior robustez diagnostica.

**Referencias**

GERON, A. Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow: Concepts, Tools and Techniques to Build Intelligent Systems. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

GIRALDI, G. A. Machine Learning and Pattern Recognition. Lecture Notes – Graduate Program in Nanobiosystems. Petropolis, RJ: UFRJ/FIOCRUZ/INMETRO/LNCC, 2021.

HOPGOOD, A. A. Intelligent Systems for Engineers and Scientists: A Practical Guide to Artificial Intelligence. 4. ed. Boca Raton, FL: CRC Press, 2022. DOI: 10.1201/9781003226277.

MIENYE, I. D.; SUN, Y. A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

THOMAS, G. Mathematics for Machine Learning. Berkeley: Department of Electrical Engineering and Computer Sciences, UC Berkeley, 2018.

UDDIN, S.; HAQUE, I.; LU, H.; MONI, M. A.; GIDE, E. Comparative performance analysis of K-nearest neighbour (KNN) algorithm and its different variants for disease prediction. Scientific Reports, v. 12, 2022. DOI: 10.1038/s41598-022-10358-x.