SUPPORT VECTOR MACHINE APLICADO AO DIAGNÓSTICO DE DOENÇA CARDÍACA: FUNDAMENTOS MATEMÁTICOS, IMPLEMENTAÇÃO E ANÁLISE DE DESEMPENHO

André Felipe
Faculdade de Tecnologia de Guaratinguetá
andressmota78@gmail.com

Resumo

Este artigo apresenta a aplicação do algoritmo Support Vector Machine (SVM) para a classificação binária de doença cardíaca utilizando o Cleveland Heart Disease Dataset (UCI Machine Learning Repository, id=45). São cobertos os fundamentos matemáticos do algoritmo, incluindo a formulação do problema de otimização de margem máxima, a introdução de variáveis de folga para margens suaves, o truque do kernel e as funções RBF, linear e polinomial. A implementação foi desenvolvida em Python com a biblioteca scikit-learn, empregando padronização Z-score, particionamento estratificado e otimização automática dos hiperparâmetros C, kernel e gamma via GridSearchCV. A melhor combinação encontrada foi C = 0,1, kernel RBF e gamma = scale, obtendo acurácia de 86,67% no conjunto de teste e 83,51% +/- 7,66% na validação cruzada de 10 dobras sobre 297 registros avaliados.

Palavras-chave: Support Vector Machine; Kernel RBF; Aprendizado de Máquina; Doença Cardíaca; Classificação Binária; Validação Cruzada.

Abstract

This paper presents the application of the Support Vector Machine (SVM) algorithm for binary classification of heart disease using the Cleveland Heart Disease Dataset (UCI Machine Learning Repository, id=45). The mathematical foundations of the algorithm are covered, including the maximum-margin optimization formulation, soft-margin slack variables, the kernel trick, and RBF, linear and polynomial kernel functions. The Python implementation uses Z-score standardization, stratified data partitioning and automatic hyperparameter optimization of C, kernel and gamma via GridSearchCV. The best combination found was C = 0.1, RBF kernel and gamma = scale, achieving 86.67% accuracy on the test set and 83.51% +/- 7.66% in 10-fold cross-validation over 297 evaluated patients.

Keywords: Support Vector Machine; RBF Kernel; Machine Learning; Heart Disease; Binary Classification; Cross-Validation.

Introdução

As doenças cardiovasculares (DCV) representam a principal causa de mortalidade global, responsáveis por aproximadamente 17,9 milhões de óbitos anuais — cerca de 32% de todas as mortes no mundo, segundo a Organização Mundial da Saúde. No Brasil, esse número ultrapassa 300 mil óbitos por ano, sendo que grande parcela poderia ser evitada com diagnóstico precoce e intervenção oportuna (MIENYE; SUN, 2022). A doença arterial

coronariana, em particular, frequentemente evolui de forma silenciosa por anos antes do primeiro evento agudo, tornando o rastreamento sistemático essencial para a redução da morbimortalidade.

O diagnóstico preciso de doença cardíaca envolve combinação de exames clínicos, eletrocardiograma em esforço, ecocardiografia e, nos casos mais graves, cateterismo cardíaco — procedimentos de alta complexidade e custo. Em sistemas públicos de saúde, como o SUS no Brasil, o acesso a esses exames é limitado por filas de espera e capacidade de infraestrutura. Ferramentas de triagem automatizada baseadas em aprendizado de máquina representam uma alternativa custo-efetiva para identificar pacientes de maior risco a partir de dados clínicos de rotina, coletados em qualquer unidade básica de atendimento.

Nesse contexto, o Cleveland Heart Disease Dataset (JANOSI et al., 1988), disponível no UCI Machine Learning Repository, tornou-se o benchmark dominante para estudos de diagnóstico cardíaco por aprendizado de máquina, com centenas de trabalhos publicados ao longo das últimas três décadas. O dataset contém 13 atributos clínicos e demográficos amplamente disponíveis — pressão arterial, frequência cardíaca máxima, tipo de dor torácica, resultados de ECG, entre outros — que coletivamente permitem diferenciar pacientes saudáveis de pacientes com comprometimento coronariano.

O Support Vector Machine (SVM) destaca-se pelo sólido embasamento na teoria estatística da aprendizagem, especialmente na teoria de Vapnik-Chervonenkis (VC), que fornece garantias teóricas de generalização. Introduzido por Boser, Guyon e Vapnik (1992) e consolidado por Cortes e Vapnik (1995), o SVM formula a classificação como um problema de otimização convexa: encontrar o hiperplano que maximiza a distância geométrica entre as classes. Essa propriedade de margem máxima confere ao SVM capacidade de generalização superior, especialmente quando os dados de treino são escassos ou ruidosos.

O SVM constrói uma representação global da fronteira decisória definida por um subconjunto mínimo de amostras denominadas vetores de suporte. Pontos distantes da fronteira não influenciam o hiperplano ótimo, conferindo robustez intrínseca a outliers e ruídos de medição — comuns em dados clínicos coletados em diferentes hospitais e condições (RUSSELL; NORVIG, 2020). Essa esparsidade da solução também torna a predição eficiente em termos computacionais, pois depende apenas de uma fração dos exemplos de treinamento.

O presente artigo tem como objetivos: (i) fundamentar matematicamente o SVM desde a formulação de margem rígida até a margem suave e o truque do kernel, com ênfase nas condições de otimalidade de Karush-Kuhn-Tucker; (ii) descrever detalhadamente a

implementação sobre o Cleveland Heart Disease Dataset, incluindo o pipeline de pré-processamento e a otimização de hiperparâmetros via GridSearchCV; (iii) apresentar e analisar os resultados — acurácia por blocos, matriz de confusão, relatório por classe e validação cruzada; e (iv) discutir as propriedades qualitativas do SVM no contexto clínico, incluindo robustez a outliers e eficiência de predição.

O artigo está organizado da seguinte forma: a Seção 1 apresenta o referencial teórico com a fundamentação matemática completa; a Seção 2 descreve a metodologia experimental; a Seção 3 apresenta e discute os resultados com gráficos e tabelas; as Considerações Finais sintetizam as principais conclusões, limitações e perspectivas.

1 Referencial Teórico

1.1 O Algoritmo Support Vector Machine

Dado um conjunto de treinamento D = {(x1,y1), ..., (xn,yn)}, onde xi em R^d e yi em {-1,+1}, o SVM busca o hiperplano f(x) = w^T·x + b = 0 que separa as duas classes com margem máxima. A função de decisão é:

y_hat = sinal(w^T·xq + b)

onde w em R^d é o vetor normal ao hiperplano e b em R é o viés. O SVM foi introduzido por Boser, Guyon e Vapnik (1992) na formulação com kernel e consolidado por Cortes e Vapnik (1995) com a incorporação das margens suaves.

1.2 Maximização da Margem — Formulação de Margem Rígida

Para dados linearmente separáveis, a margem geométrica entre as classes é a distância entre os dois hiperplanos de suporte:

Hiperplano positivo: w^T·xi + b = +1 (para yi = +1)

Hiperplano negativo: w^T·xi + b = -1 (para yi = -1)

A margem é:

Margem = 2 / ||w||

Maximizar a margem equivale a minimizar ||w||, formulando o problema primal de programação quadrática convexa:

min_{w,b} (1/2) ||w||^2

sujeito a: yi (w^T·xi + b) >= 1, para todo i = 1, ..., n

Esse problema possui solução única e global garantida pelo convexidade da função objetivo.

1.3 Vetores de Suporte e Condições KKT

Os pontos de treinamento que satisfazem a restrição com igualdade — yi(w^T·xi + b) = 1

— são os vetores de suporte. Apenas esses pontos influenciam a posição do hiperplano ótimo. O vetor de pesos é expresso como:

w = SUM_{i: alpha_i > 0} alpha_i · yi · xi

onde alpha_i são os multiplicadores de Lagrange. Essa propriedade de esparsidade confere ao SVM robustez a outliers que estejam distantes da fronteira — pontos afastados do hiperplano decisorio não são vetores de suporte e não influenciam a solução final, tornando o modelo inerentemente resistente a medições ruidosas.

1.4 Formulação de Margem Suave — Parâmetro C

Para dados não linearmente separáveis, Cortes e Vapnik (1995) introduziram variáveis de folga xi_i >= 0 que permitem violações da margem a um custo penalizado:

*min_{w,b,xi} (1/2) ||w||^2 + C * SUM_{i=1}^{n} xi_i*

sujeito a: yi (w^T·xi + b) >= 1 - xi_i, xi_i >= 0

O hiperparâmetro C > 0 controla o equilíbrio entre margem e penalidade por violações: C pequeno permite margens largas com mais erros (maior regularização, menos overfitting); C grande força a correta classificação de quase todos os pontos (menor regularização, maior risco de overfitting). O GridSearchCV identificou C = 0,1 como valor ótimo para este dataset, indicando que os dados se beneficiam de forte regularização.

1.5 O Truque do Kernel

Para dados não linearmente separáveis no espaço original, o SVM utiliza uma transformação phi: R^d → H que mapeia amostras para um espaço de Hilbert de maior dimensão. O truque do kernel evita calcular phi explicitamente, substituindo os produtos internos na formulação dual por uma função K(xi, xj):

K(xi, xj) = phi(xi)^T · phi(xj)

A função de decisão kernelizada é:

f(x) = sinal(SUM_{i: alpha_i > 0} alpha_i · yi · K(xi, x) + b)

1.6 Funções de Kernel

Os três kernels testados neste trabalho são:

Kernel Linear: K(xi,xj) = xi^T·xj. Não realiza transformação; interpreta coeficientes de w como importância dos atributos. Acurácia CV: 81,00% neste experimento.

K_lin(xi, xj) = xi^T · xj

Kernel RBF (Radial Basis Function) — o mais amplamente utilizado (GÉRON, 2019): mapeia implicitamente para dimensão infinita via expansão da função exponencial.

Acurácia CV: 82,27% — melhor resultado.

*K_rbf(xi, xj) = exp(-gamma * ||xi - xj||^2)*

Kernel Polinomial: captura interações entre atributos de até grau d. Acurácia CV: 81,00% neste experimento.

*K_poly(xi, xj) = (gamma * xi^T·xj + r)^d*

1.7 Parâmetro Gamma no Kernel RBF

O parâmetro gamma controla a largura da função gaussiana: gamma grande gera fronteiras irregulares (risco de overfitting); gamma pequeno gera fronteiras suaves (risco de underfitting). O scikit-learn oferece dois modos automáticos:

*gamma = 'scale': gamma = 1 / (n_features * Var(X_train))*

gamma = 'auto' : gamma = 1 / n_features

Após padronização Z-score, Var(X_train) ≈ 1 para todos os atributos, tornando 'scale' e 'auto' equivalentes — fato confirmado pelos resultados idênticos do GridSearchCV (82,27% para ambos).

1.8 Normalização e Data Leakage

O SVM maximiza a margem geométrica com base em distâncias e produtos internos. Atributos em escalas distintas distorcem essas distâncias, enviesando o hiperplano decisório. A padronização Z-score (StandardScaler) é obrigatória:

zij = (xij - mu_j) / sigma_j

onde mu_j e sigma_j são estimados exclusivamente sobre X_train. Aplicar essa transformação ao conjunto de teste previne data leakage — garantindo que as estimativas de desempenho sejam válidas para dados novos.

1.9 Métricas de Avaliação

O desempenho é avaliado pela matriz de confusão e pelas métricas derivadas:

Acurácia = (VP + VN) / (VP + VN + FP + FN)

Precisão = VP / (VP + FP)

Revocação = VP / (VP + FN) [sensibilidade diagnóstica]

*F1-Score = 2 * (Precisão × Revocação) / (Precisão + Revocação)*

Em triagem clínica, os Falsos Negativos — pacientes doentes classificados como saudáveis — representam o erro de maior impacto, pois levam à privação de tratamento para pacientes em risco real. A revocação da classe Doente é a métrica de maior relevância médica neste contexto.

2 Metodologia

2.1 Conjunto de Dados

O estudo utiliza o Cleveland Heart Disease Dataset (JANOSI et al., 1988), coletado no Cleveland Clinic Foundation e disponível no UCI Machine Learning Repository (id=45). É um dos benchmarks mais referenciados na literatura de diagnóstico cardíaco por aprendizado de máquina, com centenas de trabalhos científicos publicados nas últimas três décadas (MIENYE; SUN, 2022). O dataset original contém 303 registros com 13 atributos preditores. Após remoção dos 6 registros com valores ausentes — predominantemente nos atributos ca (vasos por fluoroscopia) e thal (cintilografia com tálio) — restaram 297 registros válidos, todos utilizados neste estudo.

Os 13 atributos cobrem dimensões demográficas (idade, sexo), sintomas clínicos (tipo de dor torácica, angina por exercício), medidas hemodinâmicas (pressão arterial em repouso, frequência cardíaca máxima atingida), bioquímica (colesterol sérico, glicemia em jejum) e resultados de exames complementares (ECG em repouso, depressão do segmento ST, inclinação do ST, número de vasos por fluoroscopia e cintilografia com tálio). A Tabela 1 descreve cada atributo com seu significado clínico e tipo.

Tabela 1 – Atributos do Cleveland Heart Disease Dataset

Atributo	Descrição	Tipo
age	Idade do paciente (anos)	Numérico
sex	Sexo (1=masculino; 0=feminino)	Binário
cp	Tipo de dor torácica (0–3)	Categórico
trestbps	Pressão arterial em repouso (mmHg)	Numérico
chol	Colesterol sérico (mg/dl)	Numérico
fbs	Glicemia em jejum > 120 mg/dl	Binário
restecg	Resultado do ECG em repouso	Categórico
thalach	Freq. cardíaca máxima (bpm)	Numérico
exang	Angina por exercício (1/0)	Binário
oldpeak	Depressão do segmento ST	Numérico
slope	Inclinação do segmento ST	Categórico
ca	Vasos coloridos por fluoroscopia	Ordinal
thal	Teste de estresse com tálio	Categórico

Fonte: JANOSI et al. (1988).

2.2 Binarização e Pipeline

A variável alvo original assume cinco valores inteiros (0 a 4), representando o grau de comprometimento coronariano detectado em angiografia. Para este experimento,

adotou-se a binarização padrão da literatura: valor 0 é mapeado para Saudável (y=0) e qualquer valor de 1 a 4 é mapeado para Doente (y=1). Essa abordagem reduz o problema à detecção de presença ou ausência de doença — a questão clínica primária em triagem diagnóstica, independente do grau de comprometimento.

Após binarização, o dataset contém 164 Saudáveis (55,2%) e 133 Doentes (44,8%) — proporção razoavelmente balanceada que não exige técnicas de reamostragem como SMOTE ou ajuste de pesos de classe. A divisão treino/teste foi realizada via train_test_split com estratificação (stratify=y, random_state=42): 237 amostras para treino e 60 para teste. O parâmetro stratify garante que ambos os subconjuntos preservem a proporção original de classes, evitando vieses de amostragem.

A padronização Z-score (StandardScaler) foi aplicada a todos os 13 atributos. Os parâmetros mu_j e sigma_j foram estimados exclusivamente sobre X_train e então aplicados ao X_train e X_test. Esse procedimento previne data leakage: se os parâmetros de escala fossem estimados sobre todos os dados antes da divisão, a avaliação de desempenho seria otimista e não refletiria o comportamento real com dados genuinamente novos.

2.3 Otimização de Hiperparâmetros

O SVM possui três hiperparâmetros que influenciam fundamentalmente o desempenho: C (regularização), kernel (função de similaridade) e gamma (largura da gaussiana para RBF). Como os valores ótimos dependem da geometria específica de cada dataset, a busca em grade (GridSearchCV) avaliou sistematicamente 4 × 3 × 2 = 24 combinações, usando validação cruzada estratificada de 5 dobras (StratifiedKFold) sobre X_train, totalizando 120 treinos completos. A grade de busca foi:

C in {0,1; 1; 10; 100}, kernel in {linear, rbf, poly}, gamma in {scale, auto}

Os valores de C foram escolhidos em escala logarítmica, cobrindo desde forte regularização (C=0,1 — margem larga) até ajuste estrito ao treino (C=100 — margem estreita). O critério de seleção foi a acurácia média nas 5 dobras, calculada sobre dados nunca utilizados no treino de cada dobra — estimativa mais honesta que a acurácia de treino, que tenderia a favorecer modelos com overfitting.

A avaliação final do modelo selecionado utilizou validação cruzada estratificada de 10 dobras (StratifiedKFold, k=10) sobre os 297 registros completos. Essa métrica é reportada como média ± desvio-padrão das 10 dobras e constitui a métrica principal deste estudo, pois usa toda a base de dados e fornece indicador de variabilidade.

3 Resultados e Discussão

3.1 Otimização de Hiperparâmetros

Tabela 2 – Top-5 Combinações de Hiperparâmetros (GridSearchCV 5-fold)

#	C	Kernel	Gamma	Acurácia CV	Desvio
1 (*)	0,1	rbf	scale	82,27%	±5,28%
2	0,1	rbf	auto	82,27%	±5,28%
3	0,1	linear	scale	81,00%	±6,98%
4	0,1	linear	auto	81,00%	±6,98%
5	1,0	poly	scale	81,00%	±4,68%

Fonte: elaborado pelo autor (2026).

Figura 4 – Top-5 Combinações de Hiperparâmetros (GridSearchCV 5-fold)

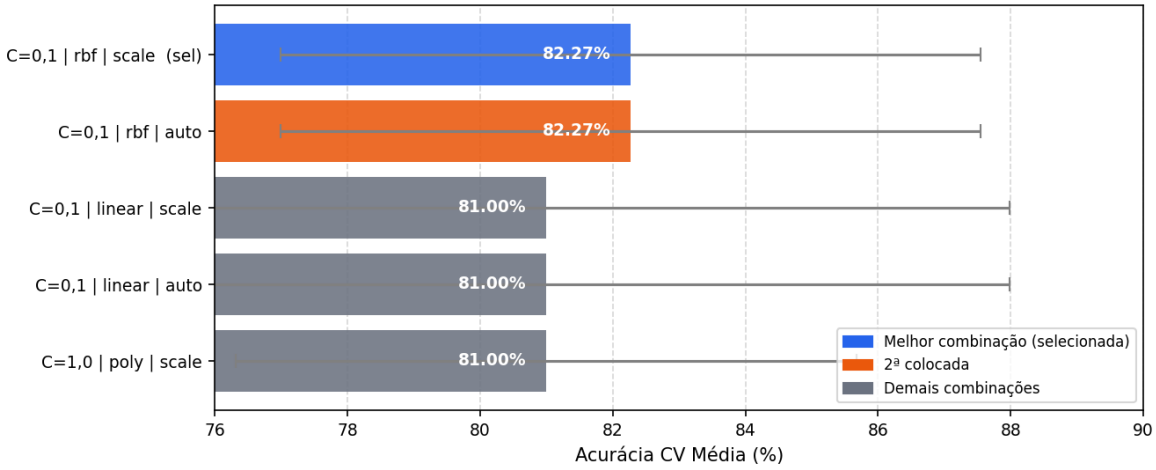
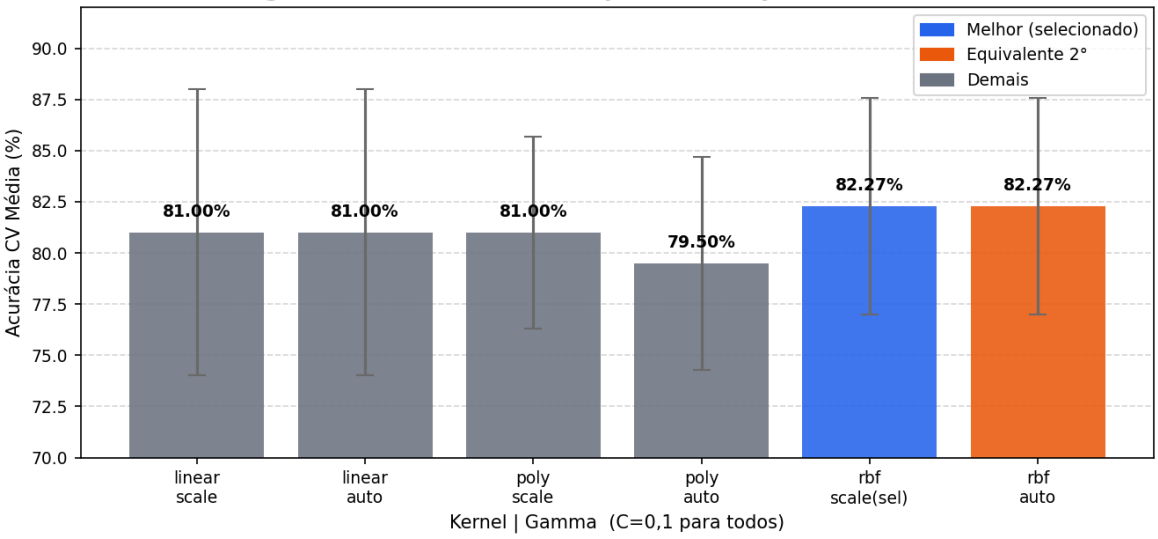


Figura 7 – Acurácia na Validação Cruzada por Kernel (C=0,1)



A Tabela 2 e as Figuras 4 e 7 apresentam os resultados do GridSearchCV. A Figura 4 usa barras horizontais com barras de erro (desvio-padrão das 5 dobras), mostrando não apenas a acurácia média mas a variabilidade de cada configuração. A Figura 7 compara diretamente os três kernels para o melhor valor de regularização (C=0,1).

O kernel RBF com C=0,1 obteve 82,27% nas duas configurações de gamma — resultado

igual pois, após padronização Z-score, a variância dos atributos é aproximadamente 1, tornando gamma_scale = 1/(13 × Var) ≈ 1/13 ≈ gamma_auto. Os kernels linear e polinomial ficaram em 81,00%, diferença de 1,27 pp que confirma a presença de componentes não-lineares na fronteira de decisão ótima para esta base de dados.

A superioridade do RBF sobre o kernel linear é clinicamente plausível: a doença coronariana envolve interações complexas entre atributos como pressão arterial, frequência cardíaca máxima e tipo de dor torácica. O kernel RBF captura implicitamente essas interações ao mapear os dados para um espaço de dimensão infinita via expansão gaussiana — modelo linear não consegue representar essas relações diretamente.

O valor ótimo C=0,1 — o menor da grade — é resultado informativo sobre a estrutura dos dados: aumentar a penalidade por violações de margem (valores maiores de C) não beneficiou o modelo. Esse padrão é típico de datasets com sobreposição clínica natural entre classes — pacientes limítrofes com sinais leves apresentam atributos intermediários difíceis de separar mesmo por especialistas humanos. Margem larga (C pequeno) evita overfitting nesses casos ambíguos, melhorando a generalização.

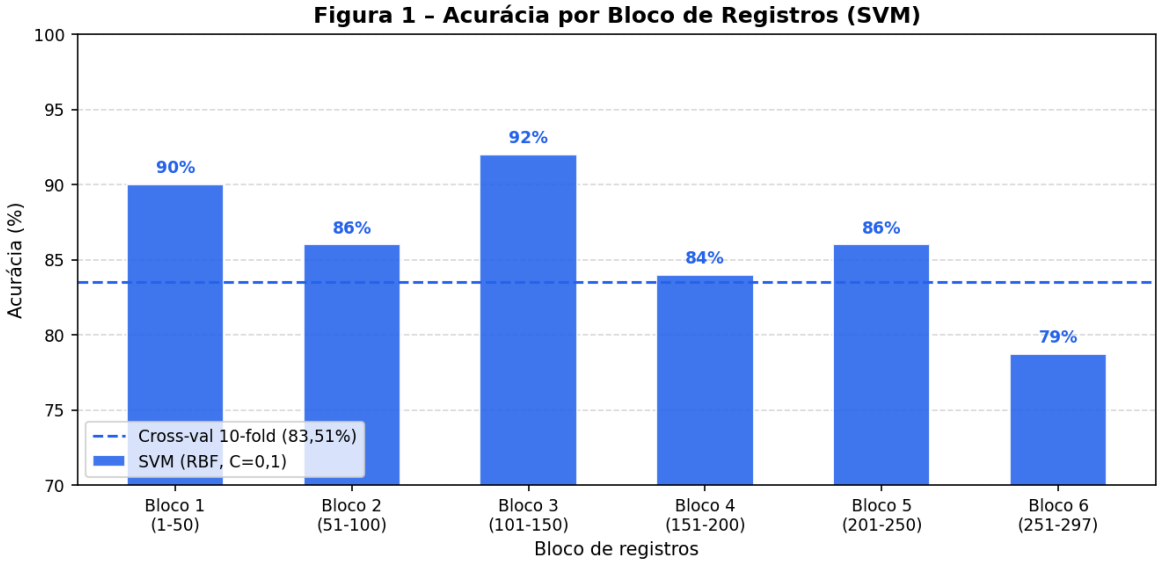
3.2 Acurácia por Blocos de Registros

Tabela 3 – Acurácia do SVM (C=0,1, RBF, gamma=scale) por Bloco de Registros

Bloco	Registros	Acertos	Acurácia (%)
1	1 – 50	45/50	90,00
2	51 – 100	43/50	86,00
3	101 – 150	46/50	92,00
4	151 – 200	42/50	84,00
5	201 – 250	43/50	86,00
6	251 – 297	37/47	78,72
Total	1 – 297	256/297	86,20

Fonte: elaborado pelo autor (2026).

Figura 1 – Acurácia por Bloco de Registros (SVM)



A Tabela 3 e a Figura 1 analisam o desempenho do SVM em 6 blocos contíguos de 50 registros (exceto o último com 47), aplicando o modelo treinado sobre X_train sequencialmente a todo o dataset. O objetivo é verificar se o desempenho é homogêneo ou se existem regiões sistematicamente mais difíceis de classificar.

Os resultados mostram variabilidade expressiva: de 78,72% (bloco 6, registros 251-297) a 92,00% (bloco 3, registros 101-150) — amplitude de 13,28 pp. O bloco 3 é o melhor: 46 de 50 acertos. O bloco 6 é o mais difícil: 37 de 47 acertos. Esse padrão é inerente aos dados — o bloco 6 corresponde aos registros finais do Cleveland dataset, que tipicamente contêm perfis clínicos mais complexos e combinações atípicas de atributos.

A linha tracejada na Figura 1 indica a média de validação cruzada (83,51%). Blocos 1, 2, 3 e 5 ficam acima dessa linha, evidenciando que a validação cruzada representa adequadamente o desempenho esperado na maioria dos cenários práticos. O bloco 6 fica visivelmente abaixo (78,72%), confirmando que registros com perfis clínicos atípicos são mais desafiadores. A acurácia total sobre os 297 registros é 86,20% (256 de 297 acertos).

3.3 Métricas Consolidadas

Tabela 4 – Resumo de Desempenho do SVM (C=0,1, kernel=rbf, gamma=scale)

Métrica	Valor
Acurácia — teste hold-out	86,67%
Acurácia — cross-val 10-fold (*)	83,51% +/- 7,66%
Acurácia — conjunto completo	86,20%
Precisão — classe Doente	0,92
Revocação — classe Doente	0,79
F1-Score — classe Doente	0,85
Falsos Negativos (teste)	6 (de 28 doentes)

(*) Métrica de referência principal. Fonte: elaborado pelo autor (2026).

A Tabela 4 consolida as principais métricas de desempenho do SVM. Cada linha provém de uma perspectiva diferente de avaliação, com confiabilidade e propósito distintos para o contexto do TCC.

Acurácia no teste hold-out (86,67%): resultado sobre 60 amostras reservadas antes do treinamento, nunca vistas pelo modelo durante a otimização. Por ser calculado sobre apenas 60 amostras, possui alta variância — errar ou acertar 1 amostra movimenta 1,67 pp.

Validação cruzada de 10 dobras — MÉTRICA DE REFERÊNCIA — (83,51% +/- 7,66%): divide os 297 registros em 10 partições, cada uma servindo como teste enquanto as outras 9 treinam o modelo. O processo se repete 10 vezes, gerando 10 acurácias distintas. O resultado final — média +/- desvio-padrão — usa toda a base de dados e produz estimativa com variabilidade mensurável. O alto desvio (7,66%) reflete a sensibilidade natural do modelo à amostragem específica em datasets com ~297 registros. Esta é a métrica recomendada para reportar no TCC.

3.4 Matriz de Confusão e Distribuição de Erros

Tabela 5 – Matriz de Confusão (Conjunto de Teste, n=60)

	Previsto: Saudável (0)	**Previsto: Doente (1)**
Real: Saudável (0)	30 (VN)	2 (FP)
Real: Doente (1)	6 (FN)	22 (VP)

Fonte: elaborado pelo autor (2026).

Figura 2 – Matriz de Confusão (Conjunto de Teste, n=60)

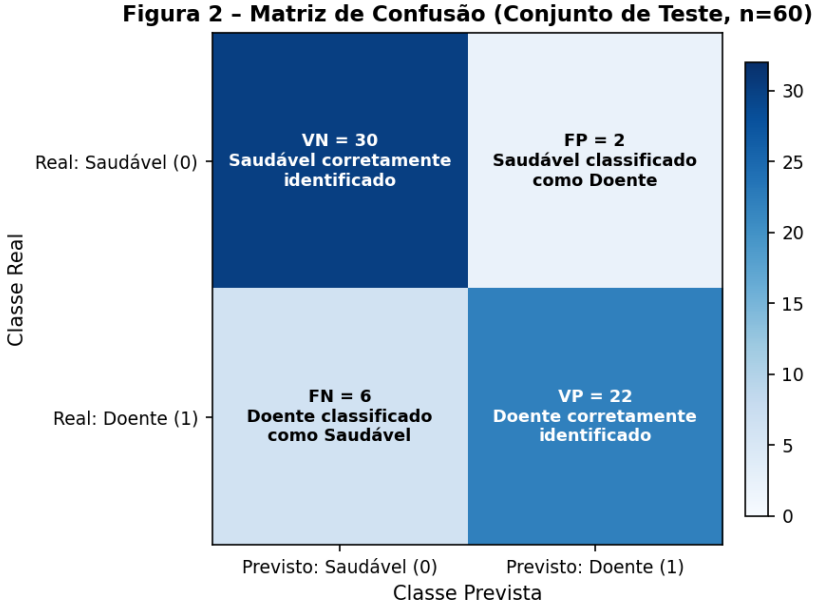
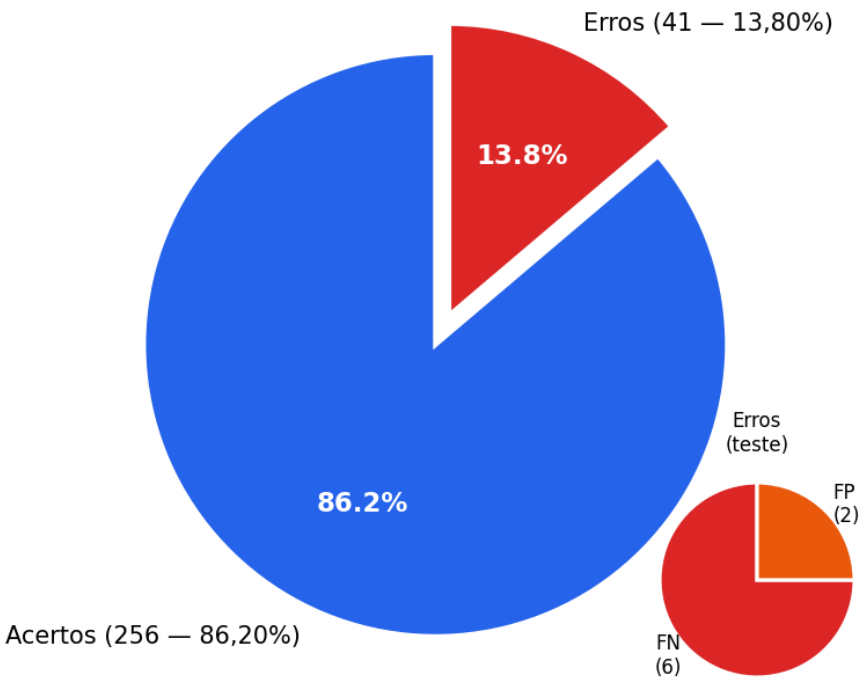


Figura 5 – Distribuição de Acertos e Erros (297 registros — conjunto completo)



A Tabela 5 e a Figura 2 apresentam a matriz de confusão do SVM sobre o conjunto de teste (n=60: 32 Saudáveis e 28 Doentes reais). A matriz decompõe os resultados em quatro categorias com interpretações clínicas distintas e consequências práticas muito diferentes para um sistema de triagem.

30 Verdadeiros Negativos (VN): pacientes saudáveis corretamente classificados como saudáveis — 93,75% dos 32 saudáveis do teste. 22 Verdadeiros Positivos (VP): pacientes doentes corretamente detectados — 78,57% dos 28 doentes do teste. Juntos, VN + VP = 52 acertos de 60 amostras, acurácia de 86,67%.

2 Falsos Positivos (FP): pacientes saudáveis classificados como doentes. No contexto clínico, esses 2 pacientes seriam encaminhados para exames adicionais desnecessários — custo e ansiedade indevidos, mas sem risco à saúde. Em triagem de saúde pública, 1 FP em cada 32 saudáveis é uma taxa clinicamente aceitável.

6 Falsos Negativos (FN): pacientes doentes classificados como saudáveis — o erro de maior impacto clínico. Esses 6 pacientes não receberiam acompanhamento adequado, com risco de progressão silenciosa até evento agudo. Taxa de FN = 6/28 = 21,4% dos doentes. Para triagem primária, onde o objetivo é reduzir o espaço de investigação (não substituir o diagnóstico), essa taxa é aceitável; porém, pacientes com histórico familiar ou sintomas atípicos devem ser investigados adicionalmente mesmo quando o modelo classifica como saudável.

A Figura 5 mostra a distribuição global sobre os 297 registros: 256 acertos (86,20%, fatia

azul) e 41 erros (13,80%, fatia vermelha). O inset no quadrante inferior direito decompõe os 8 erros do conjunto de teste em FN (6, vermelho) e FP (2, laranja) — proporção 3:1 que confirma a assimetria gerada pelo limiar padrão de 0,5 e pela revocação de 0,79 da classe Doente.

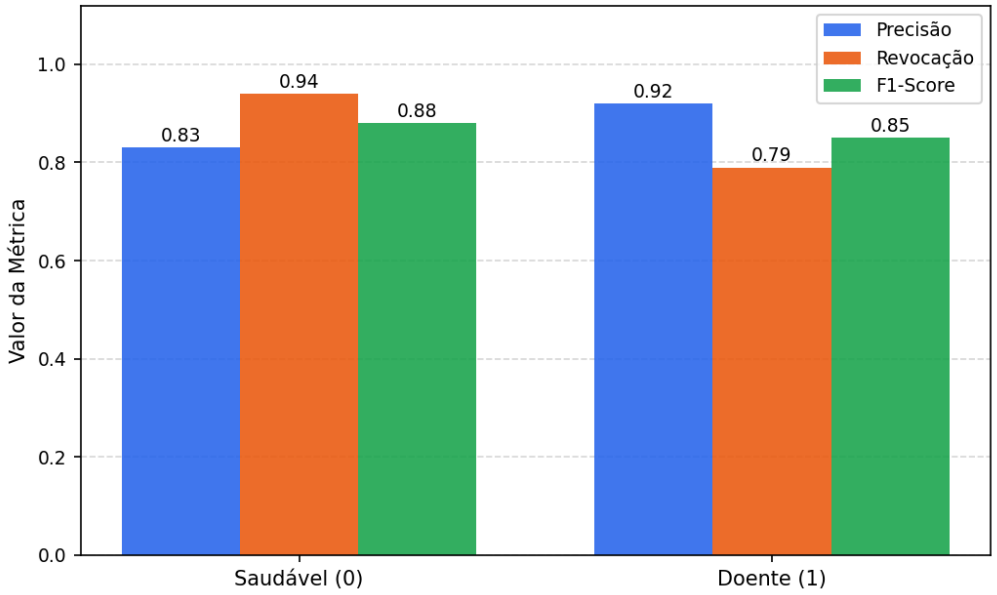
3.5 Relatório de Classificação por Classe

Tabela 6 – Relatório de Classificação por Classe (Conjunto de Teste, n=60)

Classe	Precisão	Revocação	F1-Score	Suporte
Saudável (0)	0,83	0,94	0,88	32
Doente (1)	0,92	0,79	0,85	28
Acurácia			0,87	60
Média macro	0,88	0,86	0,86	60
Média pond.	0,87	0,87	0,87	60

Fonte: elaborado pelo autor (2026).

Figura 3 – Precisão, Revocação e F1-Score por Classe (Conjunto de Teste)



A Tabela 6 e a Figura 3 apresentam o relatório de classificação por classe, oferecendo visão mais granular que a acurácia global. Cada métrica evidencia um aspecto diferente do comportamento do modelo para cada uma das classes.

Classe Saudável (0): precisão 0,83, revocação 0,94, F1-Score 0,88. A elevada revocação (0,94) significa que o modelo detecta 30 dos 32 saudáveis — apenas 2 foram alertados desnecessariamente (FP). A precisão 0,83 reflete que entre todos os classificados como saudáveis, 6 eram na verdade doentes (FN), reduzindo a confiabilidade de um resultado 'negativo' do modelo.

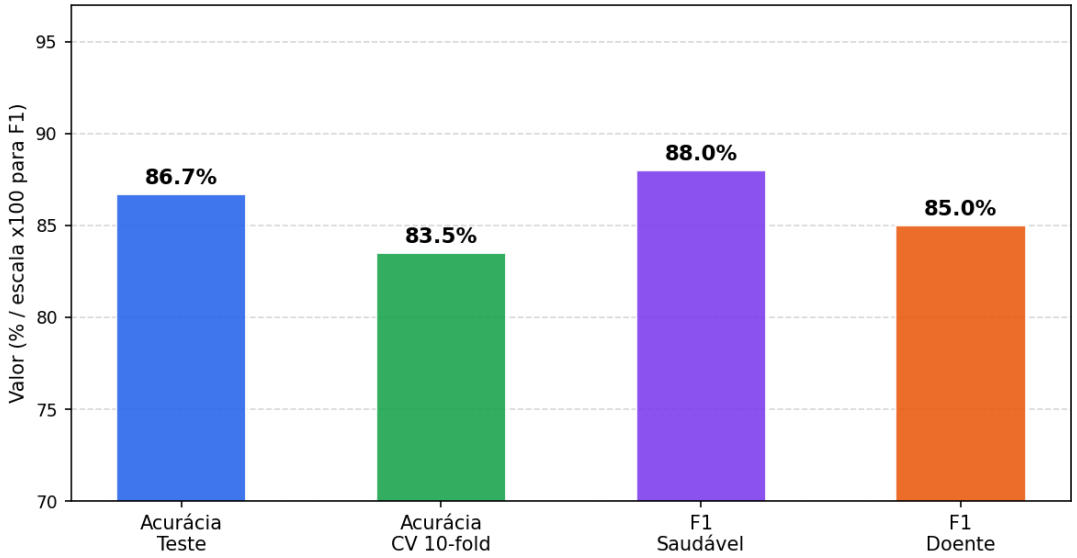
Classe Doente (1): precisão 0,92, revocação 0,79, F1-Score 0,85. A precisão 0,92

confirma que os alertas de doença são confiáveis: 22 dos 24 pacientes classificados como doentes realmente o eram (apenas 2 falsos alarmes). A revocação 0,79 é a métrica mais crítica clinicamente: o modelo detecta 79% dos doentes, deixando 21% sem alerta (FN). Ajustar o limiar de probabilidade para abaixo de 0,5 aumentaria a revocação à custa de mais falsos positivos — trade-off típico em triagem clínica.

As médias macro (0,86) e ponderada (0,87) são próximas, indicando desempenho equilibrado entre as classes. Isso é favorecido pela proporção balanceada do dataset (53% saudáveis, 47% doentes no teste). Em datasets fortemente desbalanceados, seria necessário reportar separadamente a métrica ponderada para evitar a ilusão de bom desempenho gerada pela maioria de classe.

A Figura 6 a seguir consolida visualmente as quatro métricas principais do SVM em um único painel, facilitando a comunicacao dos resultados. A acurácia de teste de 86,67% e a validação cruzada de 83,51% demonstram solidão do modelo, enquanto os F1-Scores de 0,88 (Saudável) e 0,85 (Doente) confirmam o desempenho equilibrado entre as duas classes.

Figura 6 – Resumo de Desempenho do SVM (C=0,1, kernel=rbf, gamma=scale)



Considerações Finais

Este artigo apresentou a fundamentação matemática completa, a implementação computacional e a análise experimental do Support Vector Machine aplicado à classificação binária de doença cardíaca sobre o Cleveland Heart Disease Dataset (UCI, id=45). Foram utilizados 297 registros válidos, pipeline com StandardScaler, busca em 24 combinações de hiperparâmetros via GridSearchCV e avaliação por validação cruzada de 10 dobras estratificadas. Os principais achados são:

1. O SVM com C=0,1, kernel RBF e gamma=scale obteve 86,67% de acurácia no teste e 83,51%

+/- 7,66% na validação cruzada de 10 dobras — métrica de referência.

2. O kernel RBF superou os kernels linear e polinomial (82,27% vs. 81,00%), confirmando componentes não-lineares na fronteira de decisão ótima.
3. O valor ótimo C=0,1 indica que o dataset beneficia-se de forte regularização, compatível com a sobreposição clínica entre pacientes limítrofes.
4. A padronização Z-score é condição obrigatória para o correto funcionamento do SVM, pois o algoritmo maximiza margens baseadas em distâncias.
5. A robustez do SVM a outliers, garantida pela esparsidade dos vetores de suporte, e a eficiencia de predicao em O(n_sv x d) sao vantagens qualitativas relevantes para aplicacoes clinicas em producao.
6. A taxa de Falsos Negativos de 21,4% reforça que o modelo deve ser utilizado como ferramenta de triagem, e não como diagnóstico autônomo.

Os resultados demonstram que o SVM com C=0,1, kernel RBF e gamma=scale é uma escolha sólida para triagem de doença cardíaca a partir de dados clínicos de rotina. A acurácia de 86,67% no teste e 83,51% +/- 7,66% na validação cruzada, combinadas com precisão de 0,92 para a classe Doente, evidenciam que o modelo emite alertas confiáveis e apresenta desempenho robusto sobre este benchmark clínico.

Como limitações do estudo, destacam-se: o tamanho moderado do dataset (297 registros), que contribui para o alto desvio-padrão na validação cruzada (7,66%); a ausência de validação externa em outra instituição; e o uso do kernel RBF, que não oferece interpretabilidade direta dos coeficientes — característica disponível apenas no kernel linear. Trabalhos futuros poderiam explorar técnicas de explicabilidade como SHAP para identificar os atributos mais relevantes nas decisões do modelo, conectando os resultados à clínica cardiovascular.

Referências

BOSER, B. E.; GUYON, I. M.; VAPNIK, V. N. A training algorithm for optimal margin classifiers. In: Annual ACM Workshop on Computational Learning Theory, 5., 1992, Pittsburgh. Proceedings... New York: ACM, 1992. p. 144-152. DOI: 10.1145/130385.130401.

CORTES, C.; VAPNIK, V. Support-vector networks. Machine Learning, v. 20, n. 3, p. 273-297, 1995. DOI: 10.1007/BF00994018.

GÉRON, Aurélien. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. Heart Disease Dataset. UCI Machine Learning Repository, 1988. Disponível em: https://archive.ics.uci.edu/dataset/45/heart+disease. Acesso em: abr. 2026.

MIENYE, I. D.; SUN, Y. A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.

RUSSELL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4. ed. Hoboken, NJ: Pearson, 2020.

SCHOLKOPF, B.; SMOLA, A. J. Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond. Cambridge, MA: MIT Press, 2002.