# BASE TEORICA SOBRE PROCESSO E TREINAMENTO DE DADOS EM APRENDIZADO DE MAQUINA APLICADO AO DIAGNOSTICO DE DOENCAS CARDIACAS

*Andre Felipe de Oliveira*
Faculdade de Tecnologia de Guaratingueta - FATEC Guaratingueta
andressmota78@gmail.com

**Resumo**
Este trabalho apresenta a fundamentacao teorica dos processos de tratamento de dados e treinamento de modelos em aprendizado de maquina supervisionado, com foco em aplicacoes de classificacao clinica. Sao abordados os fundamentos matematicos do processo de aprendizado a partir de exemplos, as etapas do pipeline de dados — coleta, limpeza, normalizacao e particao —, os mecanismos de treinamento por otimizacao, os algoritmos K-Nearest Neighbors, Support Vector Machine e Ensemble Learning, e os protocolos de avaliacao por validacao cruzada e metricas de desempenho. Toda a fundamentacao e referenciada exclusivamente nas obras disponiveis: Giraldi (2021), Geron (2019), Mienye e Sun (2022) e Uddin et al. (2022).
*Palavras-chave: Aprendizado de Maquina; Treinamento de Modelos; Processamento de Dados; KNN; SVM; Ensemble Learning; Validacao Cruzada.*

## 1 INTRODUCAO

O aprendizado de maquina e a area da inteligencia artificial dedicada ao desenvolvimento de algoritmos que aprendem padroes a partir de dados empiricos, sem que suas regras sejam explicitamente programadas (GERON, 2019). A aplicacao desses algoritmos ao diagnostico medico tem crescido significativamente, especialmente em doencas cardiovasculares — principal causa de mortalidade global — onde a identificacao precoce de padroes clinicos de risco pode fundamentar intervencoes terapeuticas mais oportunas.

O desempenho de qualquer modelo de aprendizado de maquina e diretamente condicionado pela qualidade do processo que antecede o treinamento: a coleta, a limpeza, a normalizacao e a particao adequada dos dados. Giraldi (2021, p. 96) define o processo de aprendizado a partir de tres elementos fundamentais: o conjunto de dados D, a maquina de aprendizado M e o estagio de treinamento. A negligencia em qualquer dessas etapas compromete a capacidade de generalizacao do modelo resultante.

Este documento apresenta a base teorica que sustenta o pipeline completo de aprendizado de maquina supervisionado, desde o tratamento dos dados brutos ate a avaliacao final do modelo treinado. O objetivo nao e apresentar resultados experimentais,

mas sim consolidar o embasamento conceitual necessario para compreender, reproduzir e criticar as escolhas metodologicas adotadas no projeto de diagnostico de doencas cardiacas.

## 2 FUNDAMENTOS DO APRENDIZADO DE MAQUINA

### 2.1 Categorias de Aprendizado de Maquina

O aprendizado de maquina classifica-se em quatro categorias principais, conforme a natureza dos dados disponiveis e o objetivo do processo (GIRALDI, 2021, p. 99):

(i) Aprendizado supervisionado: o algoritmo recebe um conjunto de amostras rotuladas e o objetivo e aprender um mapeamento das amostras para os seus respectivos rotulos. E a categoria mais adotada em classificacao clinica, onde cada paciente e associado a um diagnostico conhecido (GIRALDI, 2021, p. 99).

(ii) Aprendizado nao supervisionado: o conjunto de dados nao contem rotulos; o algoritmo descobre estruturas intrinsecas nos dados — agrupamentos, representacoes comprimidas ou distribuicoes de probabilidade — sem orientacao externa (GIRALDI, 2021, p. 99).

(iii) Aprendizado semi-supervisionado: combina um conjunto pequeno de amostras rotuladas com grande quantidade de amostras nao rotuladas. E util quando a rotulacao manual e custosa, como em imagens medicas (GIRALDI, 2021, p. 99).

(iv) Aprendizado por reforco: o algoritmo aprende por tentativa e erro, recebendo sinais de recompensa ou penalidade do ambiente, sem instrucao direta sobre a acao correta (GIRALDI, 2021, p. 100).

No contexto do diagnostico de doencas cardiacas, o aprendizado supervisionado e o paradigma adequado: cada registro clinico do dataset ja possui rotulo diagnostico determinado por especialistas, configurando um problema de classificacao binaria — saudavel ou doente.

### 2.2 O Problema de Aprendizado a partir de Exemplos

Giraldi (2021, p. 96) formaliza o problema de aprendizado a partir de exemplos em tres elementos fundamentais: o conjunto de dados D, que representa as amostras empiricas do fenomeno; a maquina de aprendizado M, que encapsula um espaco funcional por meio de seus parametros internos; e o estagio de treinamento, que e o processo pelo qual M ajusta seus parametros com base em D. Matematicamente, o espaco de dados e representado por D contido em R^m, onde m e o numero de atributos de cada amostra.

Para o problema de reconhecimento de padroes — no qual a maquina deve ser capaz de classificar corretamente amostras fora do conjunto de treinamento — o processo de

aprendizado e formalizado como a minimizacao de uma funcao de erro sobre os dados de treinamento (GIRALDI, 2021, p. 97):

$$Err(z; D) = (1/|D|) SOMA_{i=1}^{|D|} L(M(x_i; z) - d_i)$$

onde z e o vetor de parametros da maquina, d_i e a saida desejada para a amostra x_i, e L e uma metrica de similaridade ou funcao de perda adequada ao problema. A minimizacao dessa funcional define o chamado problema de minimizacao do risco empirico, que orienta o processo de treinamento de praticamente todos os algoritmos de aprendizado supervisionado (GIRALDI, 2021, p. 97).

### 2.3 O que as Maquinas Aprendem

Giraldi (2021, p. 99) sistematiza quatro problemas fundamentais de aprendizado de maquina que decorrem da minimizacao do funcional de perda:

1. Sintese de Dados (modelo generativo): encontrar uma funcao que reproduza a distribuicao dos dados observados, possibilitando a geracao de novas amostras sinteticas coerentes com o fenomeno estudado.

2. Reconhecimento de Padroes: apos o treinamento, a maquina deve classificar corretamente amostras que nao fazem parte do conjunto de treinamento D, generalizando o conhecimento extraido dos dados rotulados.

3. Estimacao de Regressao: estimar a dependencia funcional baseada nos dados empiricos, ou seja, aprender uma funcao f: R^m -> R tal que f(x_i) = y_i para as amostras de treinamento (GIRALDI, 2021, p. 99).

4. Estimacao de Densidade: aprender a distribuicao de probabilidade que gerou os dados observados, sem necessariamente associar rotulos as amostras.

O diagnostico de doencas cardiacas enquadra-se no problema de Reconhecimento de Padroes: o modelo treinado deve classificar corretamente novos pacientes que nao estavam presentes no conjunto de treinamento, generalizando os padroes clinicos aprendidos a partir dos dados historicos.

## 3 PIPELINE DE PROCESSAMENTO DE DADOS

### 3.1 Coleta e Qualidade dos Dados

O ponto de partida de qualquer projeto de aprendizado de maquina e a obtencao de dados de qualidade adequada. Uddin et al. (2022) enfatizam que a representatividade do conjunto de dados e a ausencia de vieses de coleta sao pre-requisitos para que o modelo treinado seja valido clinicamente. No contexto de diagnostico cardiaco, o Cleveland Heart Disease Dataset — repositorio UCI Machine Learning — e amplamente adotado como benchmark justamente pela sua procedencia clinica controlada e ampla validacao na

literatura especializada (UDDIN et al., 2022).

Dados reais apresentam imperfeicoes sistematicas que precisam ser tratadas antes do treinamento: valores ausentes (missing values), outliers, inconsistencias de codificacao e desbalanceamento de classes. Cada um desses problemas afeta diretamente a qualidade do modelo resultante. Giraldi (2021, p. 149) lista as etapas basicas de preparacao de dados: identificacao de excecoes e informacoes ausentes; limpeza por remocao de amostras incorretas ou inconsistentes; e normalizacao dos dados antes do treinamento.

### 3.2 Limpeza de Dados

A limpeza de dados compreende a identificacao e o tratamento de registros incompletos ou incorretos. Registros com valores faltantes podem ser tratados por tres estrategias principais: (i) remocao do registro, adequada quando a proporcao de dados ausentes e pequena e a remocao nao introduz vies; (ii) imputacao pela media ou mediana do atributo; (iii) imputacao por modelos preditivos que estimam o valor ausente com base nos demais atributos (GERON, 2019). A escolha entre essas estrategias deve considerar o percentual de dados ausentes, o mecanismo que gerou a ausencia (aleatoria ou sistematica) e o impacto potencial no balanceamento das classes.

No dataset Cleveland, os 6 registros com valores ausentes (de um total de 303) representam apenas 1,98% do dataset, justificando a remocao direta sem risco significativo de vies. Apos a limpeza, restam 297 registros validos para treinamento e avaliacao dos modelos.

### 3.3 Normalizacao de Dados

A normalizacao e uma etapa critica quando os atributos do dataset possuem escalas numericas heterogeneas. Sem normalizacao, atributos com magnitude elevada dominam o calculo de distancias, tornando os demais atributos irrelevantes para o processo de aprendizado — problema especialmente critico para algoritmos baseados em distancia como o KNN (GERON, 2019).

Giraldi (2021, p. 149) descreve o procedimento de normalizacao min-max, que transforma cada atributo u para o intervalo [0, 1] por meio da operacao:

$$x_til_uv = (x_uv - x_u,min) / (x_u,max - x_u,min)$$

onde x_u,min e x_u,max sao, respectivamente, o valor minimo e maximo do atributo u no conjunto de treinamento. Alternativamente, a normalizacao Z-score (ou padronizacao) transforma cada atributo j para media zero e desvio padrao unitario:

$$z_ij = (x_ij - media_j) / sigma_j$$

onde media_j e sigma_j sao a media e o desvio padrao do atributo j calculados exclusivamente sobre o conjunto de treinamento (GERON, 2019). E fundamental que os

parametros de normalizacao sejam calculados apenas no conjunto de treinamento e depois aplicados ao conjunto de teste, pois calcular esses parametros sobre o dataset completo constitui data leakage — vazamento de informacao que produz estimativas de desempenho artificialmente otimistas.

### 3.4 Particao dos Dados: Treino, Validacao e Teste

Antes do treinamento, o conjunto de dados D deve ser dividido em subconjuntos disjuntos com finalidades distintas. Giraldi (2021, p. 109) define formalmente essa divisao em tres partes: conjunto de treinamento D_tr, conjunto de validacao D_val e conjunto de teste D_te. Proporcoes tipicas sao 50:25:25 ou 60:20:20 para treinamento, validacao e teste, respectivamente.

O conjunto de treinamento D_tr e usado para ajustar os parametros do modelo por meio da minimizacao da funcao de perda. O conjunto de validacao D_val e utilizado para a selecao de hiperparametros e para monitorar o processo de treinamento, evitando overfitting. O conjunto de teste D_te e reservado para a avaliacao final e imparcial do modelo treinado — deve ser utilizado apenas uma vez, apos a conclusao de todas as decisoes de projeto (GIRALDI, 2021, p. 109).

Em datasets de tamanho moderado, a simples divisao treino/teste e sujeita a alta variancia em funcao da particao aleatoria escolhida. Nesse caso, Giraldi (2021, p. 110) recomenda o protocolo de validacao cruzada k-fold como alternativa estatisticamente mais robusta, detalhada na Secao 5.1 deste documento.

### 3.5 Codificacao da Variavel Alvo

A variavel alvo do dataset Cleveland possui originalmente cinco niveis de gravidade (0 a 4). Para o problema de classificacao binaria — que distingue pacientes saudaveis de pacientes com algum grau de doenca cardiaca — e necessaria a binarizacao: y=0 (saudavel) quando o valor original e 0, e y=1 (doente) para qualquer valor entre 1 e 4 (UDDIN et al., 2022). Essa transformacao simplifica o espaco de saida do classificador e e consistente com a aplicacao clinica de triagem, na qual o objetivo principal e distinguir casos que requerem investigacao adicional daqueles que nao requerem.

## 4 PROCESSO DE TREINAMENTO DE MODELOS

### 4.1 Fundamentos Matematicos do Treinamento

O processo de treinamento de um modelo de aprendizado de maquina e formalmente definido como a busca pelo vetor de parametros otimos z* que minimiza a funcao de perda sobre o conjunto de treinamento (GIRALDI, 2021, p. 97). Para algoritmos parametricos — como o SVM e a Regressao Logistica —, esse processo envolve a

resolucao de um problema de otimizacao:

$$z^* = \text{argmin}_{z} \, Err(z; D_{tr})$$

A solucao desse problema pode ser obtida por metodos analiticos (solucao de forma fechada, quando existe) ou por metodos numericos iterativos, como o gradiente descendente estocastico (SGD). Giraldi (2021, p. 106) descreve o procedimento SGD por minibatch, no qual, a cada iteracao t, um subconjunto B do conjunto de treinamento e amostrado aleatoriamente e o gradiente da funcao de perda e calculado sobre esse subconjunto para atualizar os parametros:

$$z_{t+1} = z_t - \eta \cdot \nabla_z L(z_t; B)$$

onde eta e a taxa de aprendizado, que controla o tamanho do passo na direcao oposta ao gradiente. A escolha de eta e um hiperparametro critico: valores muito altos causam instabilidade e divergencia; valores muito baixos resultam em convergencia lenta e risco de ficar preso em minimos locais (GIRALDI, 2021, p. 107).

### 4.2 Overfitting, Underfitting e o Trade-off Vies-Variancia

O principal desafio do processo de treinamento e garantir que o modelo aprenda os padroes genuinos dos dados, sem memorizar os ruidos especificos do conjunto de treinamento. Giraldi (2021, p. 112) define overfitting como o fenomeno no qual os parametros calculados durante o treinamento adaptam-se a detalhes irrelevantes das amostras de treinamento, comprometendo a capacidade de generalizacao para novos dados. O fenomeno oposto, underfitting, ocorre quando o modelo e excessivamente simplista para capturar a estrutura real dos dados.

Matematicamente, o erro esperado de um classificador sobre novos dados decompoe-se em tres componentes: vies, variancia e ruido irredutivel (GERON, 2019):

$$Erro(x) = Vies^2 + Variancia + epsilon$$

Modelos com alto vies (underfitting) ignoram estruturas relevantes dos dados; modelos com alta variancia (overfitting) ajustam-se excessivamente aos dados de treinamento. O objetivo do processo de treinamento e encontrar o ponto de equilibrio entre esses dois extremos — o chamado trade-off vies-variancia (GERON, 2019). Tecnicas de regularizacao — como o parametro C no SVM e o parametro K no KNN — controlam explicitamente esse trade-off.

### 4.3 Regularizacao e Hiperparametros

A regularizacao e um conjunto de tecnicas que reduzem a complexidade efetiva do modelo, penalizando parametros de grande magnitude e favorecendo solucoes mais generalizaveis. Giraldi (2021, p. 97) inclui termos de regularizacao R na funcao de perda:

$$L(z; D) = (1/|D|) \, \text{SOMA} \, L(M(x_i; z) - d_i) + \text{SOMA}_{\tau} \, \varsigma_\tau \cdot R_\tau(z; D)$$

onde varsigma_tau controla o peso da penalizacao sobre os parametros. Hiperparametros — como K no KNN, o parametro C e o tipo de kernel no SVM, ou o numero de dobras na validacao cruzada — nao sao aprendidos durante o treinamento, mas definidos a priori pelo projetista do sistema. A selecao sistematica de hiperparametros, por meio de busca em grade (grid search) ou validacao cruzada, e etapa indispensavel para maximizar a capacidade de generalizacao do modelo (GERON, 2019).

## 5 ALGORITMOS DE CLASSIFICACAO

### 5.1 K-Nearest Neighbors (KNN)

O K-Nearest Neighbors e um algoritmo de aprendizado supervisionado nao-parametrico e nao-generativo, classificado como lazy learner (aprendiz pregucoso): nao constroi um modelo parametrico durante o treinamento, armazenando todo o conjunto de treinamento na memoria e adiando o calculo para o momento da predicao (GERON, 2019). Sua premissa fundamental e que amostras com atributos similares tendem a pertencer a mesma classe.

O mecanismo de classificacao opera da seguinte forma: dado um novo ponto x_q a ser classificado, o algoritmo calcula a distancia entre x_q e todas as amostras do conjunto de treinamento; identifica os K vizinhos mais proximos N_K(x_q); e atribui a x_q a classe mais frequente entre esses K vizinhos — voto majoritario. Formalmente (GERON, 2019):

$$y'_q = argmax_c \sum_{i \in N_K(x_q)} Indicadora[y_i = c]$$

A medida de distancia mais comum e a distancia Euclidiana, definida entre dois pontos x e y em R^m por (GIRALDI, 2021, p. 97-98):

$$d_e(x, y) = raiz\left( \sum_{j=1}^{m} (x_j - y_j)^2 \right)$$

A sensibilidade do KNN a escala dos atributos decorre diretamente dessa formula: atributos com magnitude numerica elevada dominam o calculo, tornando os demais irrelevantes. Essa e a razao pela qual a normalizacao Z-score e condicao obrigatoria antes da aplicacao do KNN (GERON, 2019).

O parametro K e o principal hiperparametro do KNN e controla o trade-off vies-variancia diretamente: valores pequenos de K (ex.: K=1) produzem fronteiras de decisao altamente irregulares, suscetiveis a overfitting; valores grandes de K suavizam as fronteiras, mas introduzem vies (underfitting). A determinacao empirica do K otimo via validacao cruzada e o metodo recomendado (GERON, 2019).

### 5.2 Support Vector Machine (SVM)

O Support Vector Machine e um classificador supervisionado parametrico que busca o

hiperplano de maxima margem no espaco de features — o plano que separa as duas classes com a maior distancia possivel em relacao aos pontos mais proximos de cada classe (GIRALDI, 2021, p. 161). Dado um conjunto de treinamento S = {(x_i, y_i), x_i pertence R^n, y_i pertence {-1, +1}}, o SVM busca o vetor psi e o limiar b que satisfazem:

*<x_i, psi> + b >= 1, para y_i = +1*

*<x_j, psi> + b <= -1, para y_j = -1*

Os pontos de treinamento que se encontram exatamente sobre os planos de margem sao denominados vetores de suporte (support vectors) — sao os pontos mais proximos ao hiperplano otimo e determinam completamente a solucao (GIRALDI, 2021, p. 166). A distancia entre os planos de margem e a quantidade a ser maximizada, o que equivale a minimizar |psi|.

Na pratica, dados reais raramente sao linearmente separaveis. O SVM com variaveis de folga (slack variables) xi_i — tambem chamado C-SVM — relaxa a separabilidade perfeita ao permitir que algumas amostras violem a margem, penalizando cada violacao com um custo C (GIRALDI, 2021, p. 169-170):

*min |psi|^2 / 2 + C * SOMA xi_i*

O parametro C e o principal hiperparametro do C-SVM: valores altos de C privilegiam a classificacao correta de todos os pontos de treinamento (baixo vies, alta variancia); valores baixos de C admitem mais erros de treinamento em troca de margens maiores e maior capacidade de generalizacao (GIRALDI, 2021, p. 170). A escolha C=0,1 adotada neste projeto reflete forte regularizacao, adequada para datasets medicos com ruido.

Para dados nao linearmente separaveis no espaco original, o SVM emprega o truque do kernel (kernel trick): substitui o produto interno entre amostras por uma funcao kernel k(x_i, x_j) que computa implicitamente o produto interno em um espaco de features de alta dimensao (GIRALDI, 2021, p. 166-167). O kernel RBF (Radial Basis Function), dado por k(x_i, x_j) = exp(-gamma * |x_i - x_j|^2), e amplamente adotado por sua capacidade de modelar fronteiras de decisao nao lineares complexas sem especificar explicitamente o mapeamento para o espaco de alta dimensao (GERON, 2019).

### 5.3 Ensemble Learning

Metodos de ensemble combinam as previsoes de multiplos classificadores para obter desempenho superior ao de qualquer modelo individual. Mienye e Sun (2022) revisaram extensivamente essa familia de metodos, demonstrando que o ganho do ensemble e teoricamente garantido quando os erros dos classificadores base sao suficientemente descorrelacionados.

O fundamento matematico do ensemble e a reducao da variancia por agregacao. Para M

classificadores com erro medio epsilon e correlacao media rho entre seus erros, o erro esperado do ensemble e dado por (MIENYE; SUN, 2022):

$$E_ensemble = rho * epsilon + (1 - rho) * epsilon / M$$

Quando rho = 0 (erros completamente independentes), E_ensemble = epsilon/M, ou seja, o erro decresce linearmente com o numero de modelos. Na pratica, alguma correlacao sempre existe, mas o ganho e mensuravel desde que os classificadores base difiram em seus vieses de aprendizado (MIENYE; SUN, 2022).

As tres principais estrategias de ensemble sao (MIENYE; SUN, 2022): (i) Hard Voting — cada classificador emite um voto para a classe predita e a classe majoritaria vence; (ii) Soft Voting — cada classificador fornece um vetor de probabilidades por classe e as probabilidades sao agregadas (media simples ou ponderada); (iii) Stacking — as saidas dos classificadores base sao usadas como atributos de entrada para um meta-modelo (meta-learner) que aprende a combinar as previsoes de forma otima. O Stacking e o metodo mais expressivo dos tres, pois o meta-modelo pode aprender pesos assimetricos para diferentes regioes do espaco de features.

A eficacia do ensemble depende criticamente da heterogeneidade dos classificadores base. Mienye e Sun (2022) documentam que a combinacao de algoritmos com hipoteses distintas — como o KNN (baseado em vizinhanca local) e o SVM (baseado em hiperplano global de maxima margem) — produz erros parcialmente descorrelacionados, criando as condicoes necessarias para ganho real na combinacao.

## 6 AVALIACAO DE MODELOS

### 6.1 Validacao Cruzada Estratificada

A validacao cruzada k-fold e o protocolo estatisticamente mais robusto para avaliar a capacidade de generalizacao de classificadores em datasets de tamanho moderado (GIRALDI, 2021, p. 110). O conjunto D e particionado em K subconjuntos disjuntos; para cada particao i (i=1,...,K), um modelo e treinado sobre a uniao dos demais K-1 subconjuntos (D \ D_i) e avaliado sobre D_i. A estimativa final da metrica de desempenho e a media das K avaliacoes independentes.

A variante estratificada (StratifiedKFold) garante que cada dobra mantenha a mesma proporcao de classes do dataset completo — propriedade essencial em problemas com desbalanceamento de classes, comuns em aplicacoes medicas (GERON, 2019). Isso evita que uma dobra contenha amostras predominantemente de uma classe, o que produziria estimativas de desempenho enganosas.

As principais vantagens da validacao cruzada em relacao a simples divisao treino/teste

sao (GIRALDI, 2021, p. 110; GERON, 2019): (i) aproveitamento de todas as amostras disponsiveis tanto para treinamento quanto para avaliacao; (ii) reducao da variancia da estimativa de desempenho em relacao a uma unica particao aleatoria; (iii) menor sensibilidade a particoes desfavoraveis que poderiam produzir estimativas otimistas ou pessimistas.

### 6.2 Metricas de Desempenho

A avaliacao de classificadores binarios e realizada por meio de um conjunto de metricas derivadas da matriz de confusao. Giraldi (2021, p. 111) define formalmente as quantidades basicas para problemas de N classes, que no caso binario se reduzem a quatro valores:

Verdadeiro Positivo (VP): numero de amostras doentes corretamente classificadas como doentes.

Falso Negativo (FN): numero de amostras doentes incorretamente classificadas como saudaveis — erro de maior custo clinico, pois representa doentes que nao receberiam tratamento.

Falso Positivo (FP): numero de amostras saudaveis incorretamente classificadas como doentes.

Verdadeiro Negativo (VN): numero de amostras saudaveis corretamente classificadas como saudaveis.

A partir dessas quantidades, Giraldi (2021, p. 112) define a acuracia como a fracao de classificacoes corretas sobre o total de amostras:

$$Acuracia = (VP + VN) / (VP + VN + FP + FN)$$

A acuracia e uma metrica intuitiva, porem pode ser enganosa em datasets desbalanceados. Por isso, metricas complementares sao essenciais (GERON, 2019):

Precisao = VP / (VP + FP): das predicoes positivas, qual fracao e realmente positiva (minimiza falsos alarmes).

Recall (Sensibilidade) = VP / (VP + FN): dos casos positivos reais, qual fracao foi detectada (minimiza casos nao detectados).

F1-Score = 2 * Precisao * Recall / (Precisao + Recall): media harmonica entre precisao e recall, util quando ambas as metricas sao igualmente importantes.

A curva ROC (Receiver Operating Characteristic) e a area sob ela (AUC-ROC) fornecem uma avaliacao do poder discriminativo do classificador independente do limiar de decisao. Um AUC-ROC de 1,0 indica discriminacao perfeita; 0,5 equivale a uma classificacao aleatoria (GERON, 2019). Em contexto clinico, onde o limiar de decisao pode ser ajustado conforme a sensibilidade desejada, o AUC-ROC e especialmente informativo e

complementa a acuracia na avaliacao de classificadores medicos (UDDIN et al., 2022).

## 7 CONSIDERACOES FINAIS

Este documento consolidou a base teorica dos processos de tratamento de dados e treinamento de modelos em aprendizado de maquina supervisionado, com foco nos algoritmos e protocolos adotados no projeto de diagnostico de doencas cardiacas.

Os conceitos fundamentais abordados formam uma cadeia logica: o processo de aprendizado e formalmente definido como a minimizacao de uma funcao de perda sobre dados empiricos (GIRALDI, 2021, p. 97); a qualidade desse processo depende criticamente do pre-processamento adequado dos dados — limpeza, normalizacao e particao correta —, sem o qual qualquer algoritmo produziria resultados comprometidos; o trade-off vies-variancia governa a selecao de hiperparametros em todos os algoritmos estudados, e sua compreensao e pre-requisito para a interpretacao correta dos resultados experimentais (GIRALDI, 2021, p. 112; GERON, 2019).

Os tres algoritmos abordados — KNN, SVM e Ensemble Learning — representam paradigmas distintos de classificacao: o KNN opera por similaridade local sem construir modelo parametrico; o SVM busca estrutura global de maxima margem no espaco de features transformado; os metodos de ensemble combinam multiplos modelos para reduzir a variancia agregada (MIENYE; SUN, 2022). A diversidade de hipoteses entre esses paradigmas e exatamente o que possibilita ganhos no ensemble: erros descorrelacionados se cancelam parcialmente na combinacao.

A escolha do protocolo de avaliacao — validacao cruzada estratificada de 10-dobras — e sustentada tanto pela limitacao do tamanho do dataset quanto pela necessidade de estimativas de desempenho com menor variancia (GIRALDI, 2021, p. 110). As metricas complementares — AUC-ROC, recall e F1-score — sao indispensaveis em diagnostico clinico, onde os custos de falso negativo (doente nao detectado) superam os de falso positivo (UDDIN et al., 2022).

## REFERENCIAS

**GERON, Aurelien.** Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

**GIRALDI, Gilson Antonio.** Machine Learning and Pattern Recognition. Lecture Notes — Graduate Course. Graduate Program in Nanobiosystems 2021. Petropolis, RJ: UFRJ-Fiocruz-INMETRO-LNCC, 2021.

**MIENYE, I. D.; SUN, Y.** A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and

Prospects. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

**UDDIN, S.; HAQUE, I.; LU, H.; MONI, M. A.; GIDE, E.** Comparative performance analysis of K-nearest neighbour (KNN) algorithm and its different variants for disease prediction. Scientific Reports, v. 12, n. 6256, 2022. DOI: 10.1038/s41598-022-10358-x.