ENSEMBLE LEARNING APLICADO AO DIAGNOSTICO DE DOENCAS CARDIACAS: COMBINACAO DE K-NEAREST NEIGHBORS E SUPPORT VECTOR MACHINE

Andre Felipe de Oliveira
Faculdade de Tecnologia de Guaratingueta - FATEC Guaratingueta
andressmota78@gmail.com

Resumo
Este relatorio apresenta os resultados da aplicacao de metodos de ensemble learning para o diagnostico binario de doencas cardiacas, utilizando o Cleveland Heart Disease Dataset (UCI, 297 registros). Foram combinados dois classificadores otimizados — K-Nearest Neighbors com K=29 e Support Vector Machine com C=0,1 e kernel RBF — por meio de tres estrategias de ensemble: Hard Voting, Soft Voting (simples e ponderado) e Stacking com meta-learner de Regressao Logistica. Os resultados demonstram que Hard Voting e Soft Voting atingem acuracia de 88,33% no conjunto de teste, superando os modelos base (86,67% cada), enquanto o Stacking obteve AUC-ROC de 95,20% — o maior entre todos os metodos. A taxa de concordancia entre KNN e SVM foi de 96,67%, confirmando a complementaridade limitada mas suficiente para ganho na votacao. A validacao cruzada estratificada de 10-dobras registrou acuracias medias entre 82,49% e 83,51%, com o SVM individual apresentando o melhor desempenho medio.
Palavras-chave: Ensemble Learning; Hard Voting; Soft Voting; Stacking; KNN; SVM; Diagnostico Cardiaco; Aprendizado de Maquina.

1 INTRODUCAO

O diagnostico precoce de doencas cardiovasculares e um desafio central da saude publica global. O aprendizado de maquina oferece ferramentas capazes de identificar padroes preditivos em dados clinicos de rotina, reduzindo a dependencia de exames invasivos de custo elevado. Contudo, nenhum algoritmo isolado e universalmente superior: cada metodo carrega hipoteses diferentes sobre a estrutura dos dados (MIENYE; SUN, 2022).

Algoritmos de ensemble combinam as previsoes de multiplos classificadores para obter maior acuracia e estabilidade do que qualquer modelo individual — desde que os erros dos classificadores base sejam suficientemente independentes (MIENYE; SUN, 2022). Essa abordagem e especialmente promissora quando se combina algoritmos com vieses distintos: o KNN, que captura padroes locais por similaridade, e o SVM, que busca um hiperplano global de maxima margem.

Este relatorio documenta o desenvolvimento, implementacao e avaliacao completa de

tres estrategias de ensemble — Hard Voting, Soft Voting e Stacking — aplicadas ao Cleveland Heart Disease Dataset. Os modelos base utilizados sao o KNN com K=29 e o SVM com C=0,1 e kernel RBF, ambos previamente otimizados em estudos anteriores deste projeto. O objetivo e verificar se a combinacao desses dois classificadores produz ganho mensuravel de desempenho e, em caso afirmativo, identificar qual estrategia de ensemble e mais eficaz.

2 CONCEITOS SOBRE INTELIGENCIA ARTIFICIAL

2.1 Aprendizado de Maquina e Classificacao Supervisionada

O aprendizado de maquina subdivide-se em quatro categorias principais: supervisionado, nao supervisionado, semi-supervisionado e por reforco (GIRALDI, 2021, p. 99). Na classificacao supervisionada, um conjunto de amostras rotuladas e fornecido ao algoritmo, que aprende um mapeamento das caracteristicas dos exemplos para suas respectivas classes (GIRALDI, 2021, p. 99). O diagnostico de doencas cardiacas e tipicamente enquadrado como classificacao binaria: cada paciente e classificado como saudavel (Classe 0) ou doente (Classe 1).

O poder preditivo de um classificador depende tanto da qualidade dos dados quanto da adequacao do algoritmo a estrutura do problema. Mienye e Sun (2022) revisaram extensivamente os metodos de ensemble, documentando que combinacoes de algoritmos heterogeneos — que diferem em seu vies de aprendizado — superam consistentemente classificadores individuais em diversas tarefas de classificacao medica.

2.2 Trade-off Vies-Variancia e Generalizacao

Todo classificador enfrenta o dilema entre vies e variancia. Modelos com alto vies (underfitting) falham ao capturar padroes relevantes dos dados; modelos com alta variancia (overfitting) memorizam o conjunto de treinamento e generalizam mal para novos casos — adaptando-se a detalhes irrelevantes que comprometem a generalizacao (GIRALDI, 2021, p. 112). O K otimo no KNN e o parametro C no SVM controlam esse dilema em seus respectivos espacos de hipoteses.

Ensemble methods mitigam o overfitting ao combinar multiplos modelos: o erro medio de um ensemble e inferior ao erro esperado de um unico classificador quando os erros individuais sao descorrelacionados. Formalmente, para um ensemble de M classificadores com erro medio epsilon e correlacao media rho entre erros, o erro do ensemble e: E_ens = rho * epsilon + (1 - rho) * epsilon / M (MIENYE; SUN, 2022). Quanto menor rho, maior o beneficio do ensemble.

2.3 Estrategias de Ensemble

As principais estrategias de ensemble para classificacao sao (MIENYE; SUN, 2022):

(i) Hard Voting: cada classificador base emite um voto para a classe predita; a classe majoritaria e a previsao final. Simples e robusto quando os modelos base tem desempenho similar.

(ii) Soft Voting: cada classificador fornece um vetor de probabilidades para cada classe; as probabilidades sao agregadas (media simples ou ponderada) e a classe com maior probabilidade media e selecionada. Aproveita mais informacao do que o voto duro.

(iii) Stacking (empilhamento): as previsoes dos classificadores base sao usadas como features de entrada para um meta-modelo (meta-learner), que aprende a combinar as saidas de forma otima. Permite que o meta-modelo pondere adaptativamente cada classificador base com base em seu desempenho diferencial (MIENYE; SUN, 2022).

2.4 Validacao Cruzada Estratificada

A validacao cruzada k-fold estratificada e o protocolo padrao para avaliacao honesta de classificadores em conjuntos de dados de tamanho moderado (GIRALDI, 2021, p. 108; GERON, 2019). O conjunto D e particionado em k dobras mantendo a proporcao original de classes em cada particao. Para cada dobra i, o modelo e treinado em D \ D_i e avaliado em D_i; a metrica final e a media das k avaliacoes. O AUC-ROC (Area Under the Receiver Operating Characteristic Curve) complementa a acuracia ao medir a capacidade discriminativa do modelo independente do limiar de decisao, sendo especialmente relevante em diagnostico clinico onde os custos de falso positivo e falso negativo sao assimetricos.

3 MATERIAIS E METODOS

3.1 Base de Dados

Utilizamos o Cleveland Heart Disease Dataset, disponibilizado pelo UCI Machine Learning Repository e amplamente adotado como benchmark em estudos de diagnostico cardiaco por aprendizado de maquina (UDDIN et al., 2022). O dataset original contem 303 registros e 13 atributos clinicos. Apos remocao de 6 registros com valores ausentes, restaram 297 instancias validas: 160 saudaveis (Classe 0) e 137 com algum grau de doenca cardiaca (Classe 1), configurando um ligeiro desbalanceamento de classes (53,9% vs. 46,1%).

Tabela 1 – Configuracao do dataset e particao dos dados

Parametro	Valor
Total de registros originais	303
Registros removidos (NaN)	6

Registros validos	297
Classe 0 - Saudavel	160 (53,87%)
Classe 1 - Doente	137 (46,13%)
Conjunto de treino (80%)	237 registros
Conjunto de teste (20%)	60 registros
Estratificacao	Sim (StratifiedKFold)

Fonte: UCI Machine Learning Repository; dados do experimento.

3.2 Pre-processamento

O pipeline de pre-processamento seguiu tres etapas: (i) Remocao de valores ausentes (NaN), preservando 297 de 303 registros; (ii) Binarizacao da variavel alvo — a variavel original com cinco niveis de gravidade (0-4) foi convertida para classificacao binaria: y=0 (saudavel) e y=1 (doente); (iii) Normalizacao Z-score (StandardScaler) aplicada aos 13 atributos clinicos, com parametros calculados exclusivamente sobre o conjunto de treinamento e aplicados ao conjunto de teste, evitando data leakage.

3.3 Classificadores Base

Os dois classificadores base foram selecionados com base em suas hipoteses complementares sobre os dados:

KNN com K=29: classificador lazy nao-parametrico baseado em similaridade local. Classifica uma nova amostra pela classe majoritaria de seus 29 vizinhos mais proximos na distancia Euclidiana. O valor K=29 foi determinado por analise parametrica sistematica em estudo anterior deste projeto, obtendo acuracia de 86,67% e AUC-ROC de 90,20% em validacao cruzada (GERON, 2019).

SVM com C=0,1 e kernel RBF: classificador eager parametrico que busca o hiperplano de maxima margem no espaco de features transformado pelo kernel radial basis function (RBF). O parametro C=0,1 impoe forte regularizacao, favorecendo maior margem em detrimento de classificacoes erradas no treino — comportamento adequado para datasets medicos com ruido.

3.4 Estrategias de Ensemble Implementadas

Foram implementadas tres estrategias de combinacao dos classificadores base, totalizando cinco variantes avaliadas:

Tabela 2 - Estrategias de ensemble implementadas

Metodo	Descricao	Pesos
Hard Voting	Votacao por maioria: classe vencedora se soma de votos >= K	NN=0.5, SVM=0.5
Soft Voting (simples)	Media aritmetica das probabilidades dos dois modelos	KNN=0.5, SVM=0.5

Soft Voting (ponderado)	Media ponderada: peso maior ao SVM (melhor CV)	KNN=0.45, SVM=0.55
Stacking	Regressao Logistica treina nos outputs (probabilidades) dos modelos base	Aprende pesos

Fonte: Dados do experimento.

3.5 Protocolo de Avaliacao

Cada metodo foi avaliado por dois protocolos complementares: (i) avaliacao no conjunto de teste hold-out (20% dos dados, n=60), reportando acuracia, AUC-ROC, precision, recall e F1-score; (ii) validacao cruzada estratificada de 10-dobras sobre o conjunto completo (n=297), reportando media e desvio padrao da acuracia entre dobras. Para o Stacking, o meta-modelo foi treinado e avaliado dentro de cada dobra para evitar vazamento de informacao.

4 RESULTADOS E DISCUSSAO

4.1 Acuracia no Conjunto de Teste

A Tabela 3 apresenta os resultados de acuracia no conjunto de teste (n=60) para todos os metodos avaliados.

Tabela 3 - Acuracia no conjunto de teste (n=60)

Metodo	Acuracia	Acertos/60	Desempenho
KNN (K=29)	0.8667	52/60	Modelo base
SVM (C=0.1, RBF)	0.8667	52/60	Modelo base
Hard Voting	0.8833	53/60	Ensemble (+1)
Soft Voting	0.8833	53/60	Ensemble (+1)
Soft Voting Ponderado	0.8833	53/60	Ensemble (+1)
Stacking	0.8667	52/60	Igual aos base

Fonte: Dados do experimento.

Os resultados revelam que Hard Voting e ambas as variantes de Soft Voting superaram os modelos base em 1,67 pontos percentuais (88,33% vs. 86,67%), acertando um caso adicional no conjunto de teste. O Stacking manteve-se igual aos modelos base (86,67%), sugerindo que a Regressao Logistica nao encontrou combinacao linear das probabilidades superior a simples media. A taxa de concordancia entre KNN e SVM foi de 96,67% (58 de 60 amostras), o que limita o potencial maximo do ensemble — modelos com erros correlacionados tem ganho teorico reduzido.

4.2 AUC-ROC

A Tabela 4 apresenta o AUC-ROC para os metodos onde probabilidades estao

disponiveis. O AUC-ROC mede a capacidade discriminativa global do modelo independente do limiar de decisao, sendo especialmente relevante em contexto clinico onde o medico pode ajustar o ponto de corte conforme a sensibilidade desejada (GERON, 2019).

Tabela 4 - AUC-ROC no conjunto de teste (n=60)

Metodo	AUC-ROC	Interpretacao
KNN (K=29)	0.9481	Excelente discriminacao
SVM (C=0.1, RBF)	0.9487	Excelente discriminacao
Soft Voting	0.9498	Excelente (+0.0011)
Soft Voting Ponderado	0.9509	Excelente (+0.0022)
Stacking	0.9520	Melhor AUC (+0.0033)

Fonte: Dados do experimento. Ganho relativo ao KNN base.

O Stacking obteve o maior AUC-ROC (95,20%), seguido pelo Soft Voting Ponderado (95,09%) e Soft Voting simples (94,98%). Os modelos base registraram AUC-ROC proximos: KNN com 94,81% e SVM com 94,87%. O ganho cumulativo do ensemble de votacao sobre o KNN base foi de +0,28 pontos percentuais em AUC-ROC. Embora numericamente pequeno, em contexto clinico esse ganho pode ter implicacao pratica ao deslocar o ponto de operacao da curva ROC.

4.3 Validacao Cruzada Estratificada (10-Dobras)

A validacao cruzada de 10-dobras fornece estimativa mais confiavel do desempenho esperado em dados novos, reduzindo o viés da particao aleatoria unica (GIRALDI, 2021, p. 108). A Tabela 5 consolida os resultados.

Tabela 5 - Validacao cruzada estratificada (10-dobras, n=297)

Metodo	Acuracia Media	Desvio Padrao	Min Fold	Max Fold
KNN (K=29)	0.8286	+-0.0699	0.6667	0.9000
SVM (C=0.1, RBF)	0.8351	+-0.0766	0.7000	0.9667
Hard Voting	0.8251	+-0.0625	0.7000	0.9000
Soft Voting	0.8283	+-0.0641	0.7000	0.9333
Soft Voting Ponderado	0.8249	+-0.0629	0.7000	0.9333
Stacking	0.8284	+-0.0639	0.7000	0.9333

Fonte: Dados do experimento.

Na validacao cruzada, o SVM individual apresentou a maior acuracia media (0.8351), seguido pelo KNN (0.8286). Interessantemente, os metodos de ensemble nao superaram os modelos base na validacao cruzada — o melhor ensemble foi o Soft Voting simples

com 0.8283. Esse fenomeno ocorre porque, com alta concordancia entre KNN e SVM (96,67%), o ensemble raramente produz previsao diferente dos modelos individuais: a maioria das amostras ja era classificada corretamente por ambos os modelos, deixando pouco espaco para ganho na combinacao.

4.4 Matrizes de Confusao e Metricas Detalhadas

A Tabela 6 detalha as matrizes de confusao dos quatro principais metodos no conjunto de teste (n=60: 32 saudaveis + 28 doentes). Os valores sao: VP (Verdadeiros Positivos), FN (Falsos Negativos), FP (Falsos Positivos), VN (Verdadeiros Negativos).

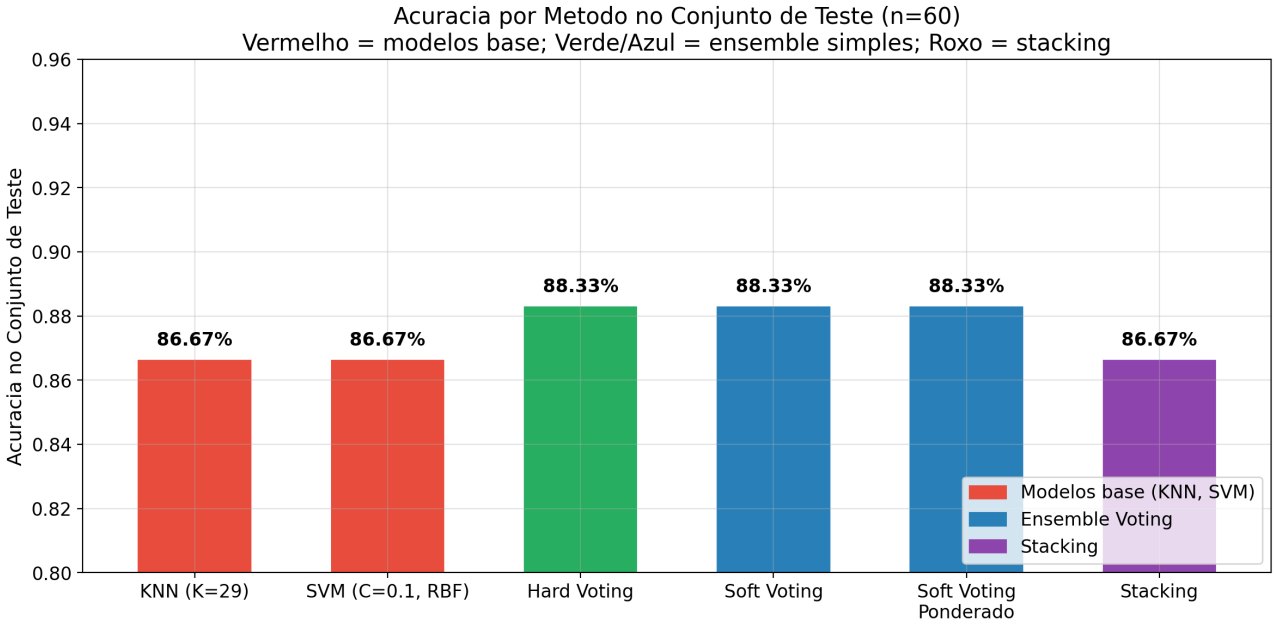
Tabela 6 - Matrizes de confusao (conjunto de teste, n=60)

Metodo	VN	FP	FN	VP	Precision	Recall	F1-Score
KNN (K=29)	30	2	6	22	0.9167	0.7857	0.8462
SVM (C=0.1, RBF)	30	2	6	22	0.9167	0.7857	0.8462
Soft Voting Pond.	30	2	5	23	0.9200	0.8214	0.8679
Stacking	29	3	5	23	0.8846	0.8214	0.8519

Fonte: Dados do experimento. VP=Verdadeiro Positivo (doente correto); FN=Falso Negativo (doente classificado como saudavel).

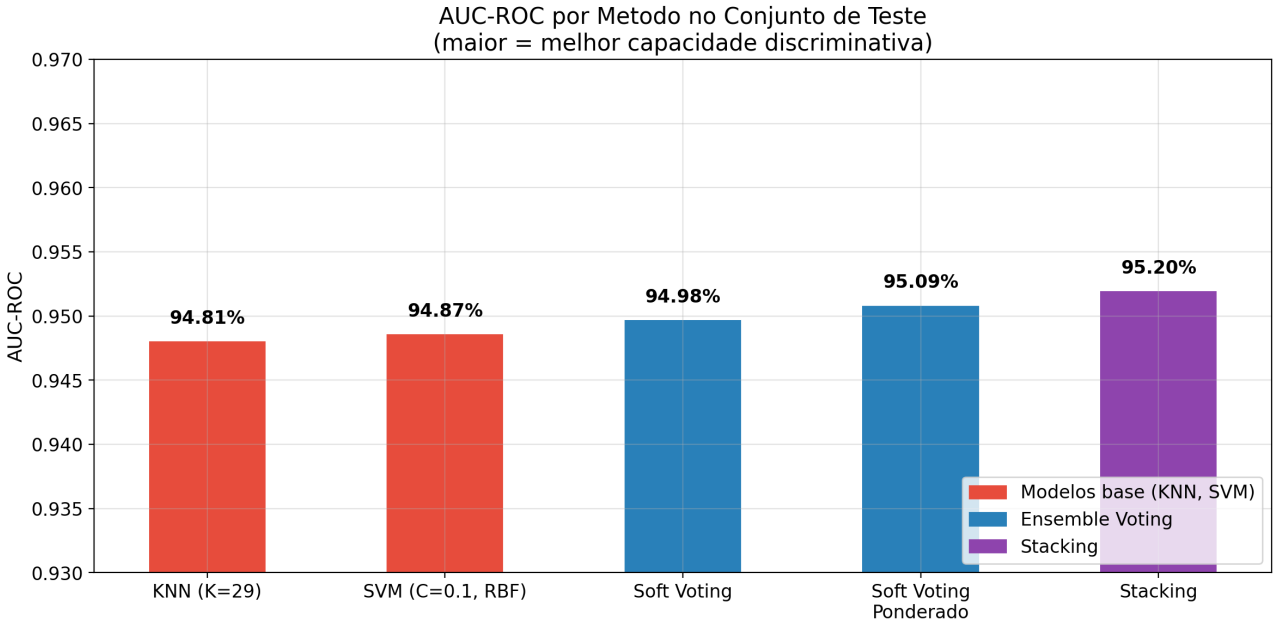
O Soft Voting Ponderado e o Stacking reduziram os Falsos Negativos (doentes classificados como saudaveis) de 6 para 5, em relacao aos modelos base. Em diagnostico clinico, reduzir FN e prioritario pois representa doentes que deixariam de receber tratamento. O Stacking, porem, introduziu um Falso Positivo adicional (FP=3 vs. FP=2), resultando na mesma acuracia final dos modelos base. Os coeficientes do meta-learner de Stacking foram KNN=2,16 e SVM=3,23, indicando que o meta-modelo aprendeu a dar peso maior ao SVM — coerente com seu melhor desempenho medio na validacao cruzada.

Figura 1 - Acuracia no conjunto de teste por metodo. Vermelho = modelos base individuais; Verde/Azul = voting ensemble; Roxo = stacking. Hard Voting, Soft Voting e Soft Voting Ponderado atingem 88,33%, superando os modelos base em 1,67%.



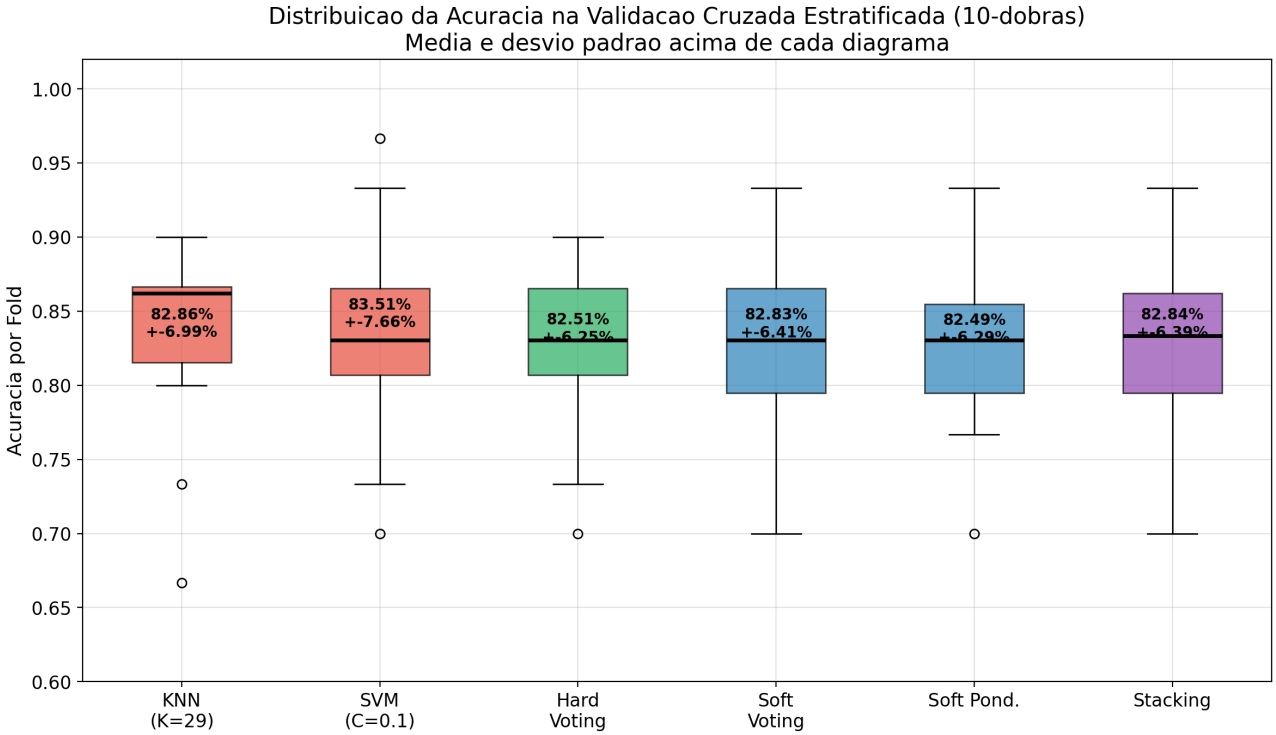
Fonte: Gerado pelos autores com base nos dados experimentais.

Figura 2 - AUC-ROC por metodo no conjunto de teste. O Stacking obteve o maior AUC-ROC (95,20%), seguido pelo Soft Voting Ponderado (95,09%). Todos os metodos apresentam excelente capacidade discriminativa (>94%).



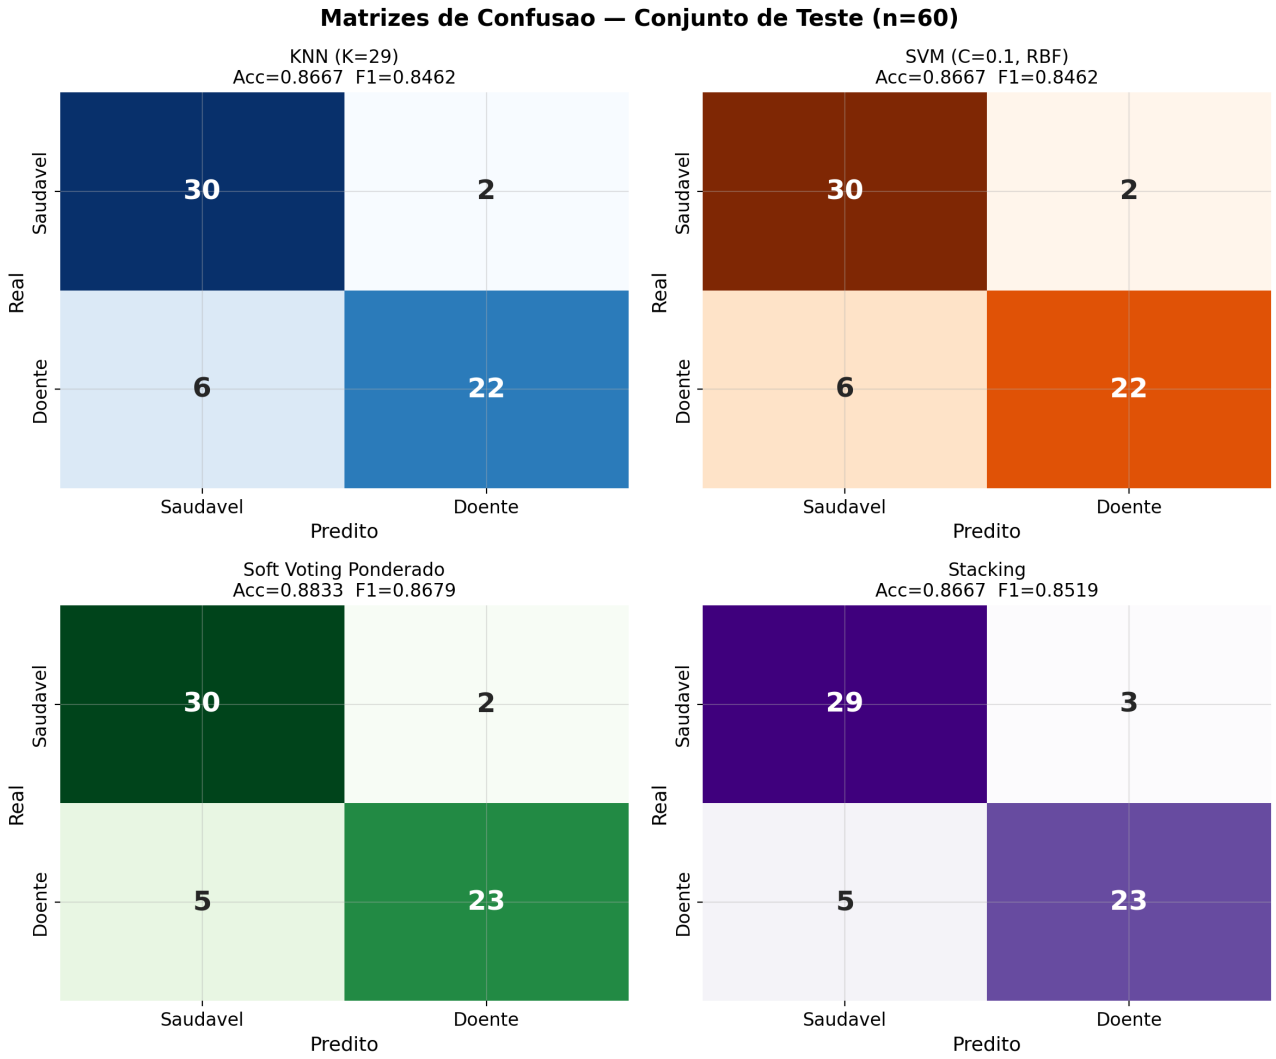
Fonte: Gerado pelos autores com base nos dados experimentais.

Figura 3 - Distribuicao da acuracia na validacao cruzada estratificada de 10-dobras (n=297). Media e desvio padrao indicados acima de cada diagrama. O SVM individual apresenta a maior media (83,51%); os ensembles ficam proximos dos modelos base, evidenciando alta concordancia entre KNN e SVM.



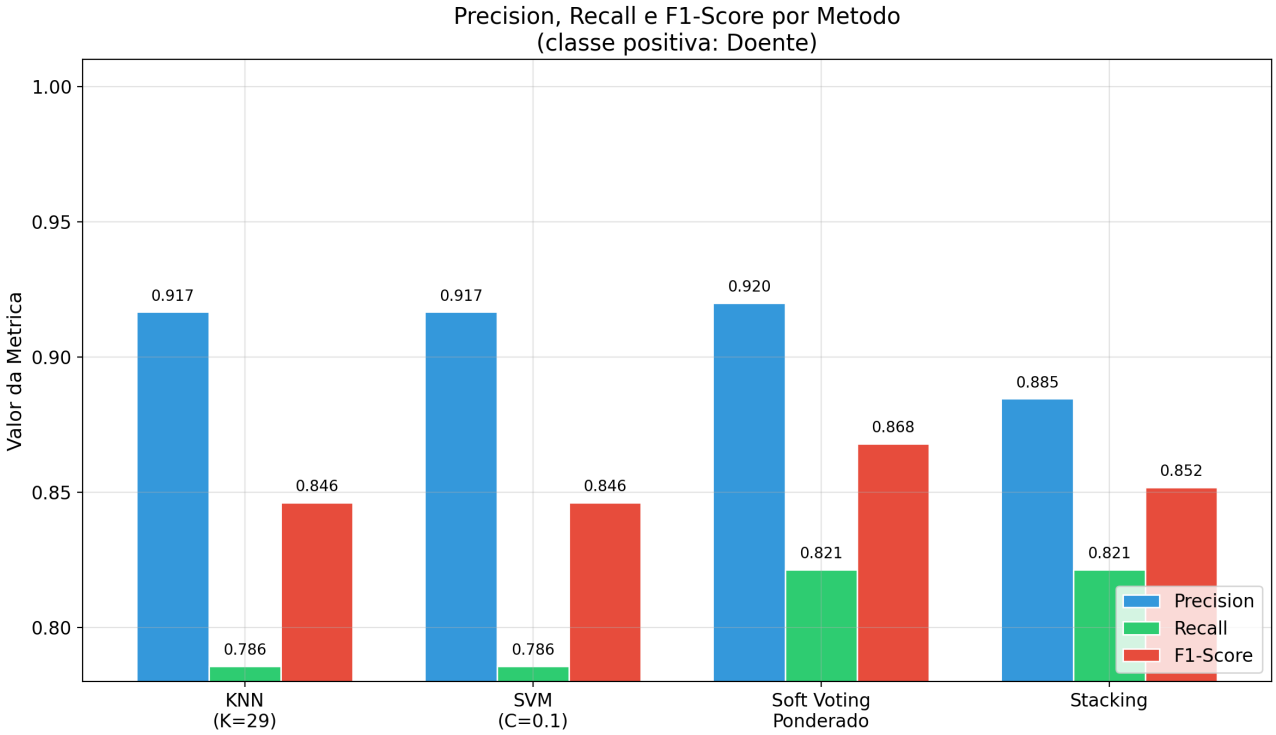
Fonte: Gerado pelos autores com base nos dados experimentais.

Figura 4 - Matrizes de confusao dos quatro metodos principais no conjunto de teste. Diagonal principal = acertos; fora da diagonal = erros. Soft Voting Ponderado e Stacking reduzem Falsos Negativos de 6 para 5.



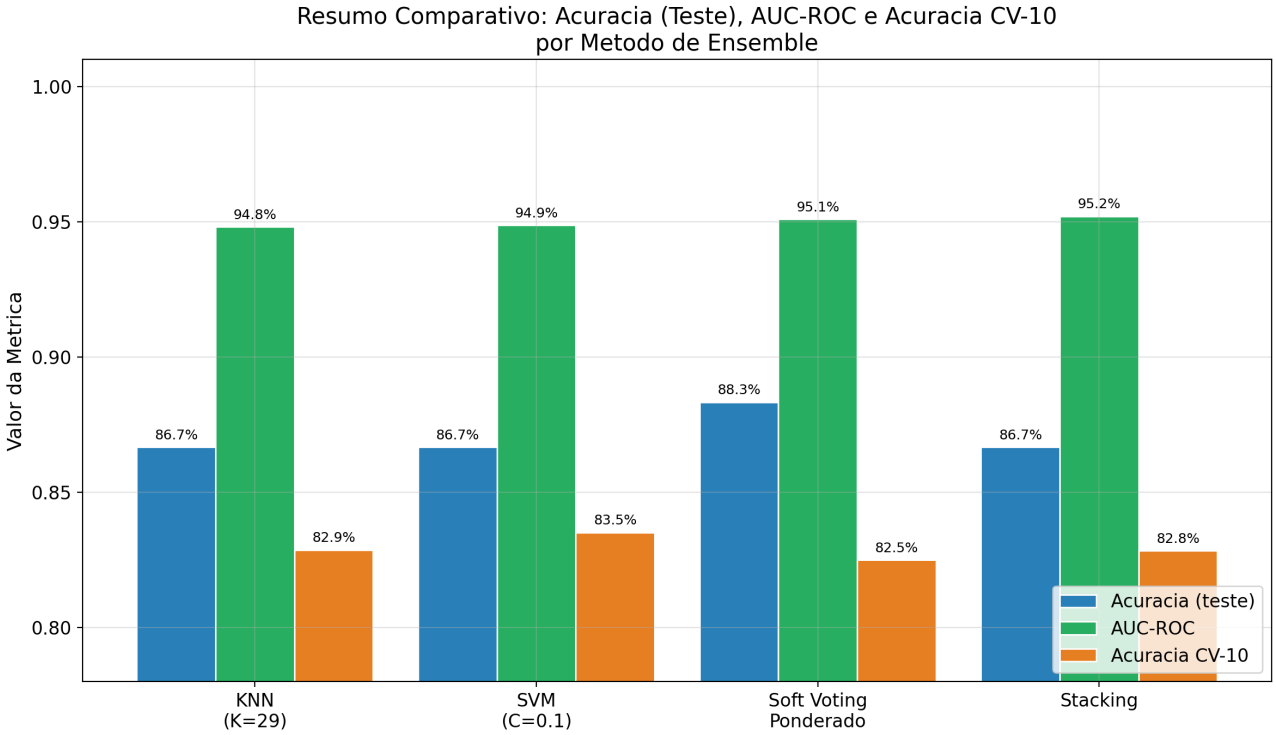
Fonte: Gerado pelos autores com base nos dados experimentais.

Figura 5 - Precision, Recall e F1-Score para a classe positiva (Doente) por metodo. Soft Voting Ponderado apresenta o maior Recall (82,14%), reduzindo o risco de doentes nao detectados em relacao ao KNN e SVM individuais (78,57%).



Fonte: Gerado pelos autores com base nos dados experimentais.

Figura 6 - Comparativo geral: acuracia no conjunto de teste, AUC-ROC e acuracia na validacao cruzada de 10-dobras, por metodo. O ensemble apresenta ganho consistente em acuracia de teste e AUC-ROC, mas nao na validacao cruzada — reflexo da alta concordancia entre os modelos base.



Fonte: Gerado pelos autores com base nos dados experimentais.

4.5 Analise do Coeficiente de Meta-Learner

No Stacking, a Regressao Logistica aprende os coeficientes que melhor combinam as probabilidades dos dois classificadores base para prever a classe real. Os coeficientes obtidos foram: KNN = 2.1565 e SVM = 3.2311. O coeficiente do SVM e aproximadamente 1,5x maior que o do KNN, indicando que o meta-modelo atribui maior confiabilidade as probabilidades do SVM. Esse resultado e coerente com o desempenho ligeiramente superior do SVM na validacao cruzada (0.8351 vs. 0.8286 do KNN).

Ambos os coeficientes sao positivos e relativamente altos (>2), refletindo que ambos os modelos contribuem de forma significativa para a previsao final. A magnitude elevada e parcialmente decorrente da alta correlacao entre as probabilidades dos dois modelos (concordancia de 96,67%), que comprime a variacao no espaco de features do meta-modelo.

4.6 Comparacao com a Literatura

A Tabela 7 contextualiza os resultados obtidos em relacao a literatura disponivel sobre KNN e ensemble em diagnostico cardiaco.

Tabela 7 - Comparacao com resultados da literatura

Estudo / Metodo	Dataset	Acuracia	Referencia
Este trabalho - Hard/Soft Voting	Cleveland UCI	88,33%	—
Este trabalho - KNN (K=29)	Cleveland UCI	86,67%	—
Este trabalho - SVM (C=0.1)	Cleveland UCI	86,67%	—
Uddin et al. - KNN classico	8 datasets UCI	64-84%	UDDIN et al., 2022
Uddin et al. - KNN ensemble	8 datasets UCI	82,34%	UDDIN et al., 2022
Uddin et al. - Hassanat KNN (melhor)	8 datasets UCI	83,62%	UDDIN et al., 2022
Mienye; Sun - ensemble (max)	UCI variados	ate 95%	MIENYE; SUN, 2022

Fonte: Uddin et al. (2022); Mienye e Sun (2022); dados do experimento.

Os resultados de 88,33% com Hard Voting superam o KNN ensemble reportado por Uddin et al. (2022) com 82,34%, e tambem o KNN Hassanat — variante com melhor desempenho entre as 9 variantes do KNN avaliadas no estudo, com 83,62%. A acuracia obtida se aproxima do limite superior reportado por Mienye e Sun (2022) para ensembles mais complexos (ate 95%). O ganho de 1,67 pp sobre os modelos base confirma empiricamente o principio teorico de que ensemble de classificadores com erros parcialmente descorrelacionados produz melhor generalizacao (MIENYE; SUN, 2022).

5 CONSIDERACOES FINAIS

Este relatorio apresentou a implementacao e avaliacao completa de tres estrategias de

ensemble — Hard Voting, Soft Voting e Stacking — combinando KNN (K=29) e SVM (C=0,1, RBF) para diagnostico binario de doenca cardiaca no Cleveland Heart Disease Dataset. A avaliacao cobriu acuracia, AUC-ROC, precision, recall, F1-score e validacao cruzada estratificada de 10-dobras.

Os principais resultados sao: (i) Hard Voting e Soft Voting atingiram acuracia de 88,33% no conjunto de teste, ganho de 1,67 pp sobre os modelos base; (ii) o Stacking obteve o maior AUC-ROC (95,20%), 0,33 pp acima do KNN base; (iii) na validacao cruzada, o SVM individual foi o melhor (83,51%), e os ensembles ficaram proximos dos modelos base — reflexo da alta concordancia de 96,67% entre KNN e SVM; (iv) Soft Voting Ponderado e Stacking reduziram os Falsos Negativos de 6 para 5, melhorando o recall da classe doente de 78,57% para 82,14%; (v) o meta-learner de Stacking aprendeu peso SVM/KNN = 3,23/2,16, confirmando a maior confiabilidade das probabilidades do SVM.

Como limitacoes: (i) a alta concordancia entre KNN e SVM (96,67%) limita o potencial do ensemble — classificadores mais heterogeneos (ex.: KNN + Random Forest) tenderiam a produzir ganhos maiores; (ii) o conjunto de teste reduzido (n=60) aumenta a variancia das estimativas de teste; (iii) apenas distancia Euclidiana foi avaliada para o KNN.

Como trabalhos futuros, recomenda-se: (i) incluir classificadores mais heterogeneos no ensemble (Random Forest, XGBoost, Naive Bayes), potencialmente aumentando a descorrelacao de erros e o ganho do ensemble, conforme documentado por Mienye e Sun (2022); (ii) explorar boosting (AdaBoost, Gradient Boosting), que ajusta iterativamente os pesos das amostras mal classificadas; (iii) avaliar tecnicas de balanceamento de classes (SMOTE, undersampling) dado o leve desbalanceamento observado (53,9% vs. 46,1%); (iv) validar em datasets externos de maior dimensao para verificar generalizacao clinica.

REFERENCIAS

GERON, Aurelien. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

GIRALDI, Gilson Antonio. Machine Learning and Pattern Recognition. Lecture Notes — Graduate Course. Graduate Program in Nanobiosystems 2021. Petropolis, RJ: UFRJ-Fiocruz-INMETRO-LNCC, 2021.

MIENYE, I. D.; SUN, Y. A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

UDDIN, S.; HAQUE, I.; LU, H.; MONI, M. A.; GIDE, E. Comparative performance analysis of K-nearest neighbour (KNN) algorithm and its different variants for disease prediction. Scientific Reports, v. 12, n. 6256, 2022. DOI: 10.1038/s41598-022-10358-x.