K-NEAREST NEIGHBORS APLICADO AO DIAGNÃ“STICO DE DOENÃ‡A CARDÃACA: FUNDAMENTOS MATEMÃTICOS, IMPLEMENTAÃ‡Ãƒ O E ANÃLISE DE DESEMPENHO

AndrÃ© Felipe
Faculdade de Tecnologia de GuaratinguetÃ¡
andressmota78@gmail.com

Resumo
Este relatÃ³rio apresenta a aplicaÃ§Ã£o do algoritmo K-Nearest Neighbors (KNN) para a classificaÃ§Ã£o binÃ¡ria de doenÃ§a cardÃaca utilizando o Cleveland Heart Disease Dataset (UCI Machine Learning Repository). SÃ£o cobertos os fundamentos matemÃ¡ticos do algoritmo, incluindo mÃ©tricas de distÃ¢ncia, regra de votaÃ§Ã£o majoritÃ¡ria e seleÃ§Ã£o do hiperparÃ¢metro K por validaÃ§Ã£o cruzada estratificada. A implementaÃ§Ã£o foi desenvolvida em Python com scikit-learn, empregando padronizaÃ§Ã£o Z-score, particionamento estratificado e otimizaÃ§Ã£o automÃ¡tica de K via GridSearchCV. O melhor valor encontrado foi K = 29, obtendo acurÃ¡cia de 86,67% no conjunto de teste e 82,86% +/- 6,99% na validaÃ§Ã£o cruzada de 10 dobras sobre 297 registros avaliados.

Palavras-chave: K-Nearest Neighbors; Aprendizado de MÃ¡quina; DoenÃ§a CardÃaca; ClassificaÃ§Ã£o BinÃ¡ria; ValidaÃ§Ã£o Cruzada.

IntroduÃ§Ã£o

As doenÃ§as cardiovasculares representam a principal causa de mortalidade global segundo a OrganizaÃ§Ã£o Mundial da SaÃºde. O diagnÃ³stico precoce Ã© essencial para reduzir Ã³bitos e custos hospitalares, mas exames como eletrocardiogramas avanÃ§ados e cineangiocoronariografias possuem alto custo e disponibilidade limitada, especialmente em paÃses em desenvolvimento (MIENYE; SUN, 2022).

O aprendizado de mÃ¡quina (AM) tem se consolidado como ferramenta de suporte Ã decisÃ£o clÃnica, sendo aplicado ao diagnÃ³stico de diabetes, hipertensÃ£o, cÃ¢ncer e doenÃ§as renais. GÃ©ron (2019, p. 4) destaca que algoritmos de classificaÃ§Ã£o podem identificar padrÃµes em dados clÃnicos com acurÃ¡cia comparÃ¡vel Ã de especialistas, democratizando o acesso Ã triagem mÃ©dica.

Dentre os algoritmos de classificaÃ§Ã£o supervisionada, o K-Nearest Neighbors (KNN) se destaca pela simplicidade conceitual, transparÃªncia matemÃ¡tica e facilidade de implementaÃ§Ã£o. Por nÃ£o construir um modelo explÃcito durante o treinamento, Ã© classificado como algoritmo de aprendizado lazy (preguiÃ§oso) e baseado em instÃ¢ncias (GÃ‰RON, 2019). Essa caracterÃstica o torna especialmente adequado para aplicaÃ§Ãµes clÃnicas onde a interpretabilidade Ã© relevante.

Este relatÃ³rio tem como objetivos: (i) fundamentar matematicamente o algoritmo KNN; (ii) descrever a metodologia de implementaÃ§Ã£o sobre o Cleveland Heart Disease Dataset; (iii) apresentar e analisar os resultados experimentais; e (iv) discutir o comportamento do modelo, suas potencialidades e suas limitaÃ§Ãµes no contexto do diagnÃ³stico cardÃaco.

1 Referencial Teórico

1.1 O Algoritmo K-Nearest Neighbors

O algoritmo KNN foi proposto por Fix e Hodges (1951) e formalizado por Cover e Hart (1967). Sua premissa central e que amostras semelhantes tendem a pertencer a mesma classe: um ponto de consulta e classificado pela maioria de seus K vizinhos mais proximos no espaco de caracteristicas.

Formalmente, dado um conjunto de treinamento D = {(x1,y1),...,(xn,yn)}, onde xi representa o vetor de atributos do i-esimo registro e yi o respectivo rotulo de classe, a predicao para uma nova amostra xq e definida por:

y_hat = argmax_c SUM_{i em N_K(xq)} 1[yi = c]

onde N_K(xq) representa o conjunto dos K indices cujos vetores de atributos estao mais proximos de xq segundo uma metrica de distancia, e 1[.] e a funcao indicadora. Na classificacao binaria adotada (c em {0,1}), a regra de decisao se reduz a:

y_hat = 1 se SUM_{i em N_K(xq)} yi > K/2;   y_hat = 0 caso contrario

O modelo nao ajusta nenhum parametro durante o treinamento: toda a computacao ocorre no momento da previsao, justificando sua classificacao como algoritmo lazy. O custo de predicao cresce linearmente com o tamanho do conjunto de treinamento.

1.2 Metricas de Distancia

A qualidade das vizinhancas depende diretamente da metrica de distancia utilizada. A familia de metricas de Minkowski oferece uma generalizacao unificada das distancias mais empregadas em aprendizado de maquina:

d_p(x,z) = (SUM_{j=1}^{d} |xj - zj|^p)^(1/p)

Os tres casos especiais mais relevantes sao:

Euclidiana (p=2):

d_E(x,z) = SQRT(SUM_{j=1}^{d} (xj-zj)^2)

metrica padrao do KNeighborsClassifier do scikit-learn; equivale a linha reta entre dois pontos no espaco d-dimensional. Adotada neste trabalho.

Manhattan (p=1):

d_M(x,z) = SUM_{j=1}^{d} |xj - zj|

soma diferencas absolutas atributo a atributo; menos sensivel a valores extremos.

Chebyshev (p->inf):

d_inf(x,z) = max_j |xj - zj|

considera apenas o atributo com maior diferenca absoluta entre os pontos.

1.3 Necessidade de Normalizacao dos Atributos

Por basear toda a decisao em distancias, o KNN e altamente sensivel a escala dos atributos. Sem normalizacao, um atributo com amplitude numerica elevada — como pressao arterial (80-200 mmHg) — dominaria o calculo em relacao a atributos binarios (0 ou 1), distorcendo as vizinhancas. Geron (2019) ressalta que a normalizacao e etapa obrigatoria para algoritmos baseados em distancia.

A Padronizacao Z-score (StandardScaler) transforma cada atributo j de modo que a distribuicao resultante tenha media zero e desvio padrao unitario:

zij = (xij - x_bar_j) / sigma_j

Os parametros x_bar_j e sigma_j sao calculados exclusivamente sobre o conjunto de treinamento. Ao aplica-los ao conjunto de teste, garante-se que nenhuma informacao do teste contamine o pre-processamento — pratica essencial conhecida como prevencao de data leakage.

1.4 Hiperparametro K e o Trade-off Vies-Variancia

O valor de K controla o tamanho da vizinhanca considerada para cada predicao. Sua escolha envolve o trade-off vies-variancia:

K pequeno: cada predicao depende de pouquissimas amostras — alta variancia, overfitting. O modelo memoriza os dados de treinamento e generaliza mal.

K grande: a vizinhanca abrange grande parte do dataset — alto vies, underfitting. O modelo perde capacidade de discriminacao local.

O erro esperado de generalizacao pode ser decomposto formalmente como:

Erro(xq) = Vies^2 + Variancia + epsilon (ruido irredutivel)

O objetivo e encontrar o K que minimiza a soma dos dois primeiros termos sobre dados nao vistos. Para isso, emprega-se a busca em grade com validacao cruzada estratificada (GridSearchCV + StratifiedKFold):

K = argmax_{k em {1,...,Kmax}} (1/v) * SUM_{i=1}^{v} Acc(k, dobra_i)*

1.5 Validacao Cruzada Estratificada

A validacao cruzada k-fold estratificada (StratifiedKFold) particiona o conjunto D em v dobras mutuamente exclusivas, mantendo em cada dobra a mesma proporcao de classes

do conjunto original. Para cada dobra i, um modelo treinado em D \ Di e avaliado sobre Di:

*Acc_CV = (1/v) * SUM_{i=1}^{v} Acc(M_{D\Di}, Di)*

Segundo Geron (2019), a validacao cruzada e preferivel a simples divisao treino/teste porque: (i) aproveita todos os dados disponíveis para treinamento e avaliacao; (ii) reduz a variancia da estimativa de desempenho; e (iii) e menos dependente de uma unica particao aleatoria. Esta e a metrica de referencia principal deste trabalho.

1.6 Metricas de Avaliacao de Classificadores Binarios

Para classificacao binaria, as predicoes se enquadram em quatro categorias, organizadas na matriz de confusao:

Tabela 1 - Estrutura da Matriz de Confusao

	Previsto: Saudavel (0)	**Previsto: Doente (1)**
Real: Saudavel (0)	VN - Verdadeiro Negativo	FP - Falso Positivo
Real: Doente (1)	FN - Falso Negativo	VP - Verdadeiro Positivo

Fonte: elaborada pelo autor (2026).

As metricas derivadas da matriz de confusao sao:

Acuracia:

Acc = (VP + VN) / (VP + VN + FP + FN)

Precisao:

Prec = VP / (VP + FP)

Revocacao (Sensibilidade):

Rec = VP / (VP + FN)

F1-Score:

*F1 = 2 * (Prec * Rec) / (Prec + Rec)*

Em triagem clinica, a Revocacao da classe Doente e a metrica de maior relevancia medica: os Falsos Negativos — pacientes doentes classificados como saudaveis — representam o erro com maior potencial de dano clinico.

2 Metodologia

2.1 Conjunto de Dados

O estudo utiliza o Cleveland Heart Disease Dataset, disponibilizado pelo UCI Machine Learning Repository sob o identificador id=45 (JANOSI et al., 1988). O dataset original contem 303 registros e 14 atributos — 13 preditores clinicos e 1 variavel alvo com 5 classes. Apos remocao de registros com valores ausentes, restaram 297 registros validos.

A Tabela 2 descreve os 13 atributos preditores utilizados.

Tabela 2 - Atributos do Cleveland Heart Disease Dataset

Atributo	Descricao	Tipo
age	Idade do paciente (anos)	Numerico
sex	Sexo (1=masculino; 0=feminino)	Binario
cp	Tipo de dor toracica (0-3)	Categorico
trestbps	Pressao arterial em repouso (mmHg)	Numerico
chol	Colesterol serico (mg/dl)	Numerico
fbs	Glicemia em jejum > 120 mg/dl (1/0)	Binario
restecg	Resultado do ECG em repouso (0-2)	Categorico
thalach	Frequencia cardiaca maxima atingida (bpm)	Numerico
exang	Angina induzida por exercicio (1=sim; 0=nao)	Binario
oldpeak	Depressao do segmento ST pelo exercicio	Numerico
slope	Inclinacao do segmento ST de pico (0-2)	Categorico
ca	Numero de vasos coloridos por fluoroscopia (0-3)	Ordinal
thal	Resultado do teste de estresse com talio (0-3)	Categorico

Fonte: JANOSI et al. (1988).

2.2 Binarizacao da Variavel Alvo

O dataset original apresenta 5 niveis de diagnostico, introduzindo ambiguidade entre graus intermediarios. Para focar na questao diagnostica central — o paciente possui ou nao evidencia de doenca cardiaca — adotou-se a binarizacao da variavel alvo (MIENYE; SUN, 2022):

y_bin = 0 se y_orig = 0 (Saudavel); y_bin = 1 se y_orig > 0 (Doente)

Essa reducao de 5 para 2 classes simplifica a interpretacao clinica e elimina ambiguidades entre classes intermediarias.

2.3 Pipeline de Pre-processamento

O pipeline de pre-processamento compreende tres etapas sequenciais obrigatorias:

Etapa 1 - Remocao de valores ausentes:

registros com NaN em qualquer atributo foram descartados. Dos 303 registros originais, 6 foram removidos, resultando em 297 registros validos.

Etapa 2 - Padronizacao Z-score:

os 13 atributos foram padronizados com StandardScaler. Media e desvio padrao calculados exclusivamente sobre X_train para evitar data leakage.

Etapa 3 - Particionamento estratificado:

80% treinamento (237 registros) e 20% teste (60 registros), com stratify=y e random_state=42, preservando a proporcao de classes em ambas as particoes.

2.4 Otimizacao do Hiperparametro K

A selecao do melhor K foi realizada por GridSearchCV sobre K em {1,...,30}, usando StratifiedKFold(5) aplicado exclusivamente sobre X_train, com scoring=accuracy:

K = argmax_{k em {1,...,30}} (1/5) * SUM_{i=1}^{5} Acc(k, dobra_i) => K* = 29*

2.5 Protocolo de Avaliacao Final

Com K* = 29, o modelo final foi treinado com todo X_train e avaliado em tres instancias complementares:

1. Conjunto de teste hold-out (60 registros, 20%): avalia desempenho em dados completamente nao vistos durante nenhuma etapa do treinamento ou selecao de K.

2. Validacao cruzada 10-fold sobre os 297 registros completos: metrica de referencia mais robusta, obtida com StratifiedKFold(10) e cross_val_score.

3. Predicao sobre o conjunto completo (297 registros): analise granular dos acertos e erros em blocos consecutivos de 50 registros.

3 Resultados e Discussao

3.1 Otimizacao do Hiperparametro K

A Tabela 3 apresenta os 5 melhores valores de K identificados pelo GridSearchCV na validacao cruzada de 5 dobras sobre o conjunto de treinamento:

Tabela 3 - Top-5 valores de K (5-fold CV, conjunto de treino)

K	Acuracia CV Media
29	83,97%
27	83,55%
17	83,55%
30	83,55%
26	83,55%

Fonte: elaborada pelo autor (2026).

O agrupamento dos melhores resultados na faixa K em [17,30] indica que o dataset apresenta padroes relativamente suaves que beneficiam vizinhancas maiores. Valores de K inferiores a 10 apresentaram maior variabilidade entre dobras, evidenciando sensibilidade a ruidos locais. A margem pequena entre K=29 (83,97%) e seus vizinhos proximos (83,55%) indica que a superficie de desempenho e relativamente plana na

regiao [17,30], conferindo robustez a escolha.

3.2 Acuracia por Blocos de Registros

A Tabela 4 apresenta a distribuicao de acuracia por blocos consecutivos de 50 registros sobre os 297 pacientes:

Tabela 4 - Acuracia do KNN (K=29) por bloco de registros

Bloco	Registros	Acertos	Acuracia
1	1 - 50	45/50	90,00%
2	51 - 100	42/50	84,00%
3	101 - 150	45/50	90,00%
4	151 - 200	40/50	80,00%
5	201 - 250	43/50	86,00%
6	251 - 297	37/47	78,72%
Total	1 - 297	252/297	84,85%

Fonte: elaborada pelo autor (2026).

A variacao entre blocos (78,72% a 90,00%) reflete a heterogeneidade das amostras. O bloco 6 apresentou o menor desempenho (78,72%), possivelmente por conter maior proporcao de casos ambiguos. Os blocos 1 e 3 atingiram 90,00%, sugerindo regioes do espaco de caracteristicas com fronteiras de decisao mais nitidas.

3.3 Metricas Consolidadas do Modelo

A Tabela 5 apresenta o resumo completo do desempenho do classificador KNN com K=29:

Tabela 5 - Resumo de desempenho do classificador KNN (K=29)

Metrica	Valor
Acuracia — conjunto de teste (hold-out 20%, 60 registros)	86,67%
Acuracia — validacao cruzada 10-fold (metrica principal, n=297)	82,86% +/- 6,99%
Acuracia — conjunto completo (297 registros)	84,85%
F1-Score ponderado (conjunto de teste)	0,87
K (numero de vizinhos)	29
Tamanho do conjunto de treinamento	237 registros
Tamanho do conjunto de teste	60 registros
Total de registros avaliados	297 registros

Fonte: elaborada pelo autor (2026).

A validacao cruzada 10-fold (82,86% +/- 6,99%) e a metrica de referencia recomendada para o TCC, pois estima a capacidade de generalizacao de forma imparcial: em cada uma

das 10 iteracoes, o modelo e avaliado sobre uma dobra que nao participou do seu treinamento (GERON, 2019). O intervalo aproximado de desempenho situa-se entre 75,87% e 89,85%. A avaliacao qualitativa do modelo e classificada como BOA.

3.4 Matriz de Confusao

A Tabela 6 apresenta a matriz de confusao sobre os 60 registros do conjunto de teste, detalhando cada tipo de predicao:

Tabela 6 - Matriz de confusao (conjunto de teste, n=60)

	Previsto: Saudavel (0)	Previsto: Doente (1)
Real: Saudavel (0)	30 (VN)	2 (FP)
Real: Doente (1)	6 (FN)	22 (VP)

Fonte: elaborada pelo autor (2026).

Os 6 Falsos Negativos sao o erro mais critico: pacientes doentes que receberiam diagnostico negativo. Com 28 pacientes doentes no teste, isso equivale a uma taxa de falsos negativos de 21,4% — aceitavel para um modelo de triagem automatizada, mas insuficiente para uso clinico autonomo sem supervisao medica.

3.5 Relatorio de Classificacao por Classe

A Tabela 7 detalha as metricas por classe, revelando o comportamento assimetrico do modelo:

Tabela 7 - Relatorio de classificacao por classe (conjunto de teste, n=60)

Classe	Precisao	Revocacao	F1-Score	Suporte
Saudavel (0)	0,83	0,94	0,88	32
Doente (1)	0,92	0,79	0,85	28
Acuracia			0,87	60
Media macro	0,88	0,86	0,86	60
Media ponder.	0,87	0,87	0,87	60

Fonte: elaborada pelo autor (2026).

Precisao da classe Doente = 0,92: quando o modelo preve Doente, esta correto em 92% dos casos. Revocacao da classe Doente = 0,79: detecta 79% dos pacientes efetivamente doentes. F1-Score equilibrado (0,85 e 0,88): sem desvio marcante para nenhuma das classes. F1-Score macro medio = 0,86: confirma desempenho consistente e equilibrado.

3.6 Analise dos Erros de Classificacao

Os 45 erros identificados nos 297 registros (15,15% do total) se dividem em dois tipos com causas e implicacoes distintas:

Falsos Negativos — doente classificado como saudavel:

ocorrem quando um paciente doente possui combinacao de atributos que se assemelha, no espaco padronizado de 13 dimensoes, ao perfil de pacientes saudaveis na vizinhanca de K=29. Exemplos observados: registros 17, 23, 34, 45, 52, 53, 58, 67, 70, 75, 81, 130, 144 e 145.

Falsos Positivos — saudavel classificado como doente:

ocorrem quando um paciente saudavel apresenta perfil clinico proximo ao de pacientes doentes no espaco padronizado. Exemplos: registros 33, 52, 124, 141, 167, 171, 179, 183 e 187.

Esses erros sao explicados pela natureza do KNN: o algoritmo opera usando apenas informacao local (K=29 vizinhos), sem construir representacao global da distribuicao das classes. Regioes do espaco de caracteristicas onde as duas classes se sobrepoem representam casos inerentemente dificeis para o classificador.

Consideracoes Finais

Este relatório apresentou a fundamentacao matematica, a implementacao computacional e a analise experimental do algoritmo K-Nearest Neighbors para classificacao binaria de doenca cardiaca sobre o Cleveland Heart Disease Dataset.

Os principais resultados e conclusoes sao:

1. O KNN com K=29 obteve 86,67% de acuracia no conjunto de teste e 82,86% +/- 6,99% na validacao cruzada de 10 dobras — metrica de referencia recomendada por ser a estimativa de generalizacao mais honesta disponivel.

2. A binarizacao da variavel alvo (5 classes -> 2 classes: Saudavel/Doente) foi decisao metodologica fundamental: eliminou ambiguidades entre graus intermediarios e alinhou o problema a pergunta diagnostica clinicamente relevante.

3. A padronizacao Z-score e condicao obrigatoria para o correto funcionamento do KNN sobre dados clinicos com atributos de escalas heterogeneas. Sua aplicacao estrita com parametros calculados apenas sobre X_train e essencial para evitar data leakage.

4. O valor otimo K=29 situa-se na regiao de vizinhanca larga, equilibrando adequadamente vies e variancia para as caracteristicas deste dataset. A busca automatizada por GridSearchCV e preferivel a escolha manual.

5. A matriz de confusao revela alta precisao para a classe Doente (0,92) e alta revocacao para a classe Saudavel (0,94). Os 6 Falsos Negativos (21,4%) representam a principal limitacao clinica, reforçando que o KNN deve ser utilizado como ferramenta de apoio a decisao medica, nao como sistema diagnostico autonomo.

6. Como trabalho futuro, recomenda-se: investigar metricas de distancia alternativas (Manhattan, Minkowski com p != 2); avaliar KNN ponderado com peso inversamente proporcional a distancia; aplicar SMOTE para melhorar a revocacao da classe Doente; e explorar selecao de atributos para identificar o subconjunto mais informativo dentre os 13 preditores.

Referencias

COVER, T. M.; HART, P. E. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, v. 13, n. 1, p. 21-27, 1967. DOI: 10.1109/TIT.1967.1053964.

FIX, E.; HODGES, J. L. Discriminatory Analysis: Nonparametric Discrimination, Consistency Properties. USAF School of Aviation Medicine, Randolph Field, Texas. Technical Report n. 4, 1951.

GERON, Aurelien. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. Heart Disease Dataset. UCI Machine Learning Repository, 1988. Disponivel em: https://archive.ics.uci.edu/dataset/45/heart+disease. Acesso em: mar. 2026.

MIENYE, I. D.; SUN, Y. A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011. Disponivel em: https://jmlr.org/papers/v12/pedregosa11a.html. Acesso em: mar. 2026.

RUSSELL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4. ed. Hoboken, NJ: Pearson, 2020.