RELATÓRIO TÉCNICO — SUPPORT VECTOR MACHINE APLICADO AO DIAGNÓSTICO DE DOENÇA CARDÍACA

André Felipe
Faculdade de Tecnologia de Guaratinguetá
andressmota78@gmail.com
Abril de 2026

---

1 Objetivo

Este relatório técnico documenta de forma detalhada e reproduzível a aplicação do algoritmo Support Vector Machine (SVM) para classificação binária de doença cardíaca utilizando o Cleveland Heart Disease Dataset (UCI Machine Learning Repository, id=45). O documento destina-se ao uso no Trabalho de Conclusão de Curso (TCC) da Faculdade de Tecnologia de Guaratinguetá (FATEC-GT), servindo como registro das decisões metodológicas, parâmetros técnicos e resultados experimentais obtidos.

São cobertos os seguintes aspectos: (i) caracterização da base de dados e tratamento de valores ausentes; (ii) pipeline de pré-processamento com binarização da variável alvo, particionamento estratificado e padronização Z-score; (iii) busca automática de hiperparâmetros via GridSearchCV com validação cruzada de 5 dobras; (iv) avaliação com múltiplas métricas — acurácia, precisão, revocação, F1-Score, matriz de confusão e validação cruzada de 10 dobras; (v) análise de desempenho por blocos de registros; e (vi) recomendações metodológicas específicas para o TCC.

Todos os resultados foram obtidos a partir do script SupportVectorMachine.py, implementado em Python 3 com a biblioteca scikit-learn. A reprodutibilidade é garantida pelo parâmetro random_state=42 nas funções de particionamento e pela ausência de elementos estocásticos no pipeline após a divisão inicial.

2 Base de Dados

Tabela 1 – Informações da Base de Dados

Item	Valor
Fonte	UCI Machine Learning Repository (id=45)
Nome	Cleveland Heart Disease Dataset
Registros originais	303
Removidos (valores ausentes)	6
Registros válidos utilizados	297
Atributos preditores	13 (clínicos)
Variável alvo — original	5 classes (0–4)

Variável alvo — binarizada	0 = Saudável / 1 = Doente

Fonte: JANOSI et al. (1988).

A variável alvo original assume valores de 0 a 4 (grau de comprometimento coronariano). Para este estudo foi binarizada: 0 = Saudável, 1 a 4 = Doente. Após essa transformação, o dataset contém 164 saudáveis (55,2%) e 133 doentes (44,8%) — proporção razoavelmente balanceada, sem necessidade de técnicas de reamostragem.

Na literatura, os atributos com maior poder discriminatório para doença coronariana neste dataset são: cp (tipo de dor torácica), thal (cintilografia com tálio), ca (vasos por fluoroscopia), oldpeak (depressão do segmento ST) e exang (angina por exercício). Esses atributos são candidatos prioritários para análise de importância em trabalhos futuros com kernel linear ou técnicas como SHAP.

3 Pipeline de Pré-processamento

3.1 Binarização da Variável Alvo

y = 0 → y_original = 0 (Saudável: sem doença)

y = 1 → y_original > 0 (Doente: qualquer grau)

3.2 Divisão Treino/Teste

Tabela 2 – Divisão Treino/Teste com Estratificação

Conjunto	Registros	Saudável	Doente
Treinamento (80%)	237	128 (54%)	109 (46%)
Teste (20%)	60	32 (53%)	28 (47%)

Método: train_test_split com stratify=y e random_state=42.

3.3 Normalização Z-score

O SVM maximiza uma margem geométrica medida em distância euclidiana no espaço de atributos. Se os atributos estiverem em escalas muito diferentes — por exemplo, colesterol sérico (100-600 mg/dl) versus sexo (0 ou 1) — os de maior magnitude dominarão artificialmente a geometria da margem, enviesando o hiperplano decisório. A padronização Z-score normaliza cada atributo j para média zero e desvio-padrão unitário:

z_ij = (x_ij - mu_j) / sigma_j

mu_j e sigma_j são estimados exclusivamente sobre X_train e aplicados ao X_test sem recalcular — prevenindo data leakage. Após normalização, gamma_scale = 1/(n_features x Var(X_train)) ≈ 1/13 ≈ gamma_auto, o que explica os resultados idênticos para as duas opções de gamma no GridSearchCV (82,27% para ambas com RBF).

A normalização também melhora a estabilidade numérica do solver QP interno do SVM. Atributos em escalas muito diferentes podem causar mal-condicionamento da matriz de kernel, aumentando o número de iterações necessárias para convergência. Com StandardScaler aplicado corretamente, o solver converge em poucas dezenas de iterações para este dataset.

4 Otimização de Hiperparâmetros

4.1 Grade de Busca

Tabela 3 – Grade de Hiperparâmetros Testada

Hiperparâmetro	Valores Testados	Total
C	0,1 / 1 / 10 / 100	4
kernel	linear / rbf / poly	3
gamma	scale / auto	2
Total	4 × 3 × 2 = 24 combinações	24

Método: GridSearchCV + StratifiedKFold(5) — 24 × 5 = 120 treinos.

A escala logarítmica para C (0,1; 1; 10; 100) permite explorar um intervalo de 1000x com apenas 4 valores, cobrindo desde máxima regularização (C=0,1, margem larga) até ajuste muito estrito ao conjunto de treino (C=100). Os três kernels testam fronteiras lineares simples (linear), não-lineares suaves (RBF) e polinomiais (poly grau=3). O parâmetro gamma é testado nas duas configurações automáticas do scikit-learn.

Cada uma das 24 combinações foi avaliada em 5 dobras estratificadas sobre X_train (237 registros): ~190 amostras para treino interno e ~47 para validação interna em cada dobra. Esse protocolo garante que os hiperparâmetros sejam selecionados com base em generalização, não em memorização do conjunto de treino.

4.2 Top-5 Resultados da Busca

Tabela 4 – Top-5 Combinações (Validação Cruzada 5-fold)

#	C	Kernel	Gamma	Média CV	Desvio
1 (*)	0,1	rbf	scale	82,27%	±5,28%
2	0,1	rbf	auto	82,27%	±5,28%
3	0,1	linear	scale	81,00%	±6,98%
4	0,1	linear	auto	81,00%	±6,98%
5	1,0	poly	scale	81,00%	±4,68%

(*) Combinacao selecionada. Fonte: elaborado pelo autor (2026).

Figura 4 – Top-5 Combinações de Hiperparâmetros (GridSearchCV 5-fold)

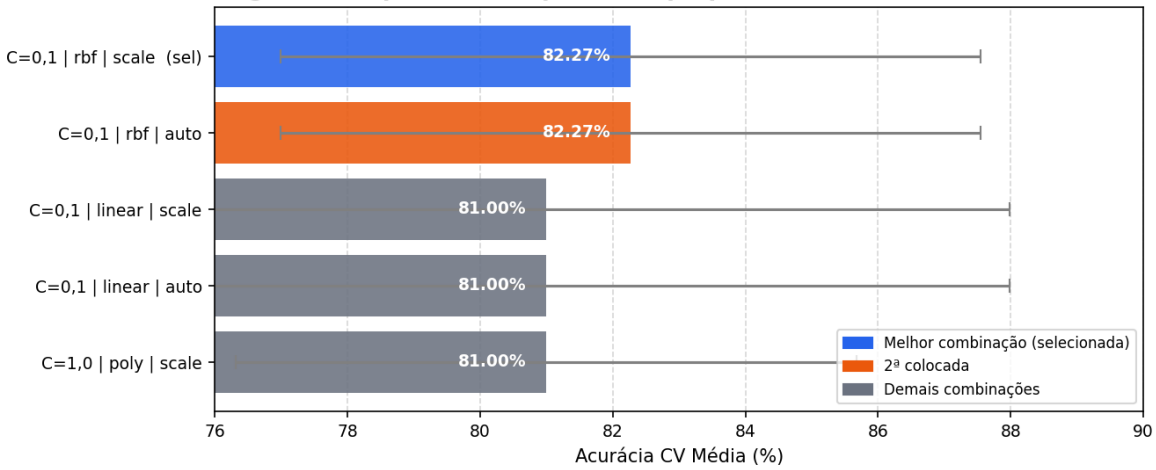
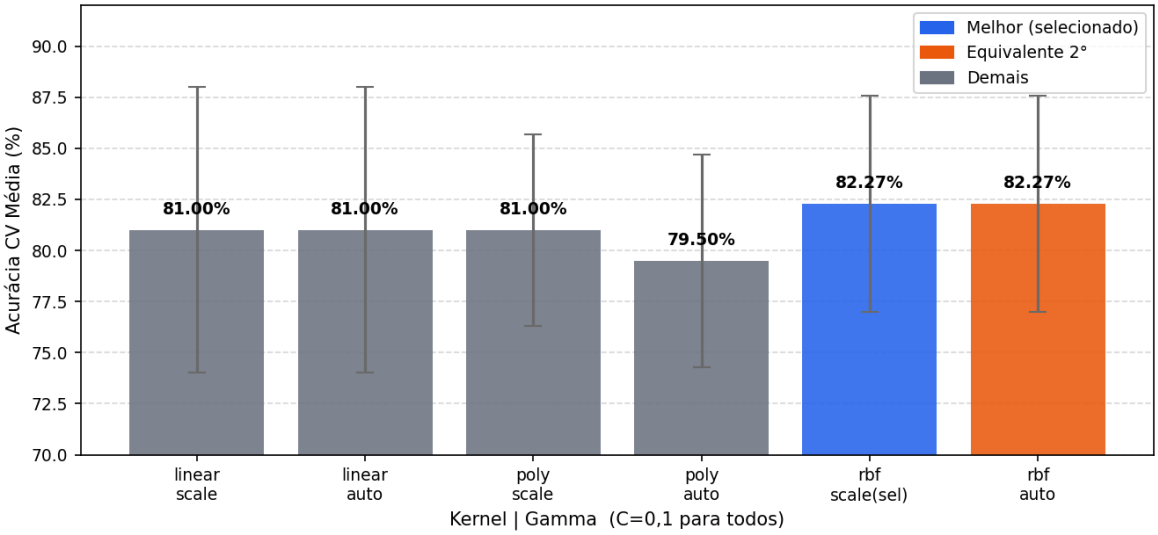


Figura 7 – Acurácia na Validação Cruzada por Kernel (C=0,1)



A Tabela 4 apresenta os 5 melhores resultados do GridSearchCV. A Figura 4 visualiza as combinações com barras horizontais e barras de erro (desvio-padrão das 5 dobras) — tornando visível a variabilidade de cada configuração, não apenas a acurácia média. A Figura 7 detalha o desempenho por tipo de kernel.

O kernel RBF com C=0,1 obteve 82,27% nas duas variantes de gamma (empate esperado após normalização Z-score). Os kernels linear e polinomial ficaram em 81,00%, confirmando não-linearidades na fronteira ótima. O kernel polinomial com gamma='auto' obteve o pior resultado da busca (79,50%), sugerindo que o grau 3 padrão não é adequado para as relações presentes neste dataset clínico.

A diferença de 1,27 pp entre RBF (82,27%) e os demais (81,00%) foi consistente em todas as 5 dobras, justificando a seleção do RBF. C=0,1 sendo o melhor valor — o menor da grade — indica que o dataset se beneficia de forte regularização: pacientes limítrofes com sinais leves de comprometimento coronariano têm atributos clínicos intermediários que tornam a separação rígida prejudicial à generalização.

A combinação selecionada (*) — C=0,1, kernel=rbf, gamma=scale — foi usada para

treinar o modelo final sobre X_train completo. Esse modelo foi então aplicado ao conjunto de teste hold-out (60 registros) para a acurácia final e submetido à validação cruzada de 10 dobras sobre todos os 297 registros para a métrica principal.

4.3 Hiperparâmetros Ótimos Selecionados

Tabela 5 – Hiperparâmetros Ótimos e Justificativas

Parâmetro	Valor	Significado
C	0,1	Forte regularização — margem larga, tolerante a violações
kernel	rbf	Fronteira não-linear no espaço de dimensão infinita
gamma	scale	gamma = 1/(n_features × Var(X_train)) — adaptativo

Fonte: elaborado pelo autor (2026).

5 Resultados de Desempenho

5.1 Métricas Globais

Tabela 6 – Métricas Globais de Desempenho

Métrica	Valor	Observação
Acurácia — teste (60 registros)	86,67%	Dados nunca vistos
Acurácia — CV 10-fold (*)	83,51% ± 7,66%	MÉTRICA PRINCIPAL
Acurácia — todos os dados (297)	86,20%	Estimativa otimista
Avaliação qualitativa	BOM	Boa maioria dos casos

(*) Use cross-val 10-fold como metrica principal no TCC - mais honesta e confiavel.

A Tabela 6 apresenta três perspectivas de acurácia que devem ser interpretadas de forma complementar. Cada uma avalia o modelo em uma condição diferente e produz estimativas com diferentes níveis de confiabilidade estatística.

Acurácia no teste hold-out (86,67%): 52 acertos em 60 amostras nunca vistas. Por ser calculada em apenas 60 registros, cada erro ou acerto move a acurácia em 1,67 pp. É útil como verificação final, mas possui alta variância estatística.

Validação cruzada de 10 dobras — MÉTRICA PRINCIPAL — (83,51% ± 7,66%): calculada sobre todos os 297 registros em 10 rotações, produz estimativa robusta com desvio-padrão mensurável. O desvio de 7,66% indica que o modelo oscila nessa faixa em diferentes amostras de dados — esperado para um dataset com ~300 registros. Esta é a métrica recomendada para reportar no TCC e comparar com outros algoritmos.

Acurácia sobre todos os dados (86,20%): 256 de 297 acertos com o modelo final. É uma estimativa otimista (o modelo viu parte desses dados no treino) e serve principalmente para a análise por blocos na Seção 5.2, não deve ser reportada como métrica principal de

desempenho.

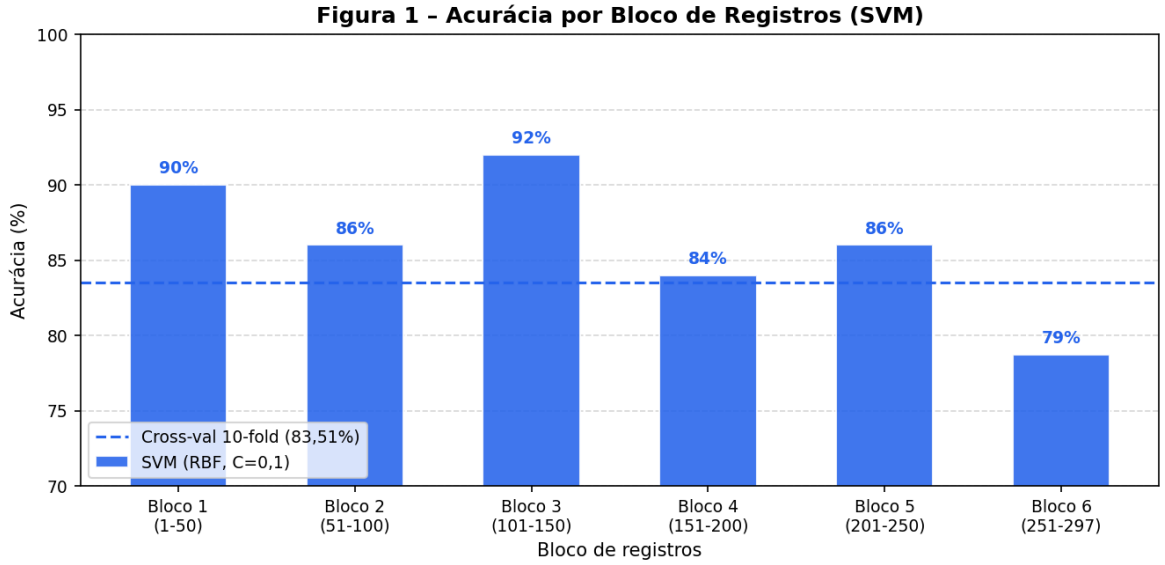
5.2 Acurácia por Blocos de Registros

Tabela 7 – Acurácia por Bloco (SVM completo, 297 registros)

Bloco	Registros	Acertos	Acurácia (%)
1	1 – 50	45/50	90,00
2	51 – 100	43/50	86,00
3	101 - 150	46/50	92,00 (max)
4	151 – 200	42/50	84,00
5	201 – 250	43/50	86,00
6	251 – 297	37/47	78,72 (mínimo)
Total	1 – 297	256/297	86,20

(*) Bloco de maior acuracia. Fonte: elaborado pelo autor (2026).

Figura 1 - Acurácia por Bloco de Registros (SVM)



A Tabela 7 e a Figura 1 analisam o desempenho do SVM segmentado em 6 blocos de 50 registros (exceto o último com 47). Os resultados revelam variabilidade expressiva: de 78,72% (bloco 6, registros 251-297) a 92,00% (bloco 3, registros 101-150), amplitude de 13,28 pp. Bloco 3: 46 de 50 acertos. Bloco 6: 37 de 47 acertos.

A linha tracejada na Figura 1 indica a média de validação cruzada do SVM (83,51%). Os blocos 1, 2, 3 e 5 ficam acima dessa referência, enquanto o bloco 6 fica visivelmente abaixo (78,72%), confirmando a variabilidade natural em registros com perfis clínicos atípicos.

A dificuldade do bloco 6 é inerente aos dados, não uma limitação do SVM: os últimos registros do Cleveland dataset tendem a incluir perfis clínicos menos frequentes, com combinações atípicas de atributos que diferem dos padrões aprendidos no treino. Esse comportamento é relevante para uso clínico: o modelo pode ter desempenho inferior em

subpopulações sub-representadas no treinamento.

5.3 Matriz de Confusão

Tabela 8 – Matriz de Confusão (Conjunto de Teste, n=60)

	Previsto: Saudável (0)	Previsto: Doente (1)
Real: Saudável (0)	30 — VN	2 — FP
Real: Doente (1)	6 — FN	22 — VP

VN=Verdadeiro Negativo, FP=Falso Positivo, FN=Falso Negativo, VP=Verdadeiro Positivo.

Tabela 9 – Análise Clínica dos Resultados da Matriz de Confusão

Tipo	Qtd	Interpretação Clínica
VN	30	Saudáveis corretamente identificados (93,75% dos saudáveis)
VP	22	Doentes corretamente identificados (78,57% dos doentes)
FP	2	Saudáveis alertados sem necessidade (exames desnecessários)
FN	6	Doentes não detectados — 21,4% de FN — risco clínico crítico

Fonte: elaborado pelo autor (2026).

Figura 2 – Matriz de Confusão (Conjunto de Teste, n=60)

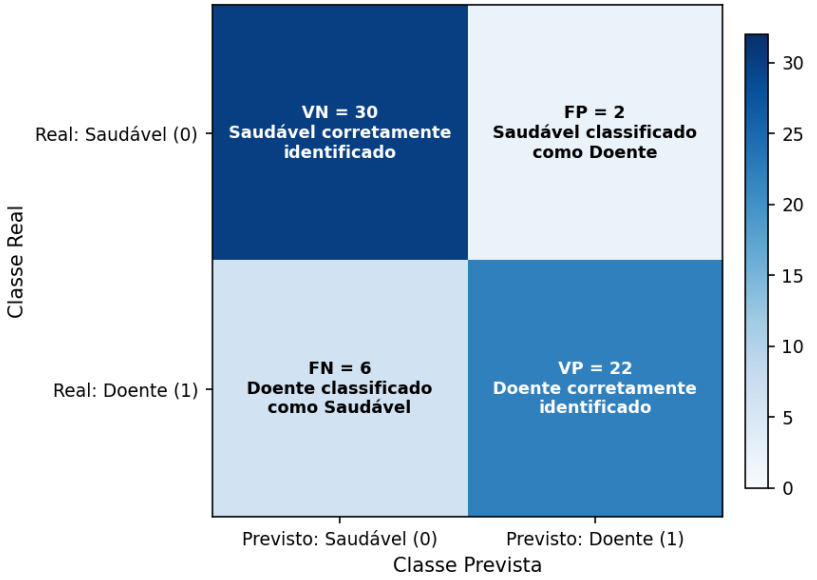
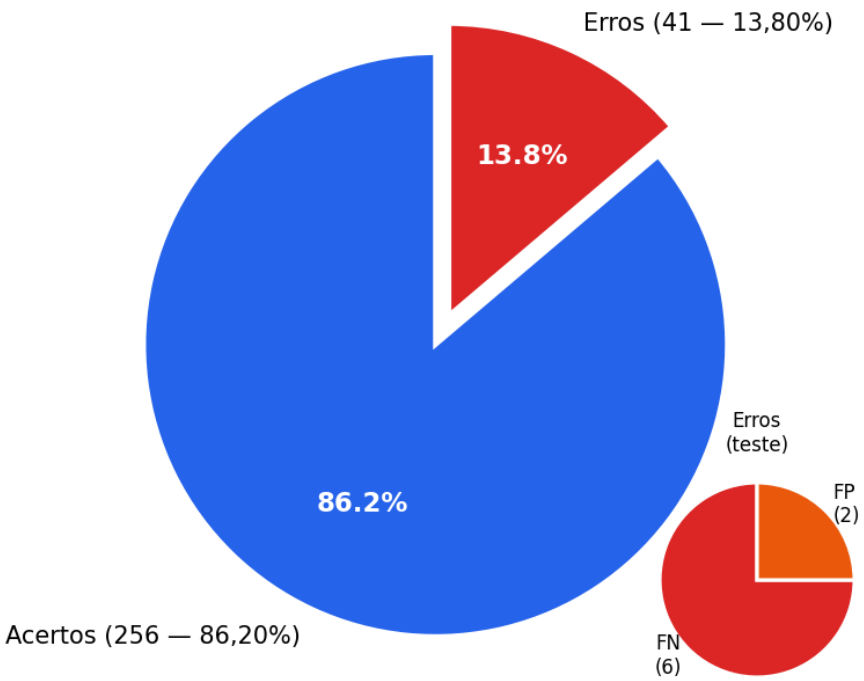


Figura 5 – Distribuição de Acertos e Erros (297 registros — conjunto completo)



As Tabelas 8 e 9 e a Figura 2 detalham a matriz de confusão do conjunto de teste (n=60). Os 30 VN e 22 VP somam 52 acertos. Os 2 FP e 6 FN somam 8 erros — todos decompostos na Tabela 9 com interpretação clínica detalhada.

O ponto crítico é a taxa de Falsos Negativos: 6/28 = 21,4% dos doentes do teste não foram detectados. Para triagem primária, essa taxa pode ser aceitável — o objetivo é reduzir o espaço de investigação, não substituir o diagnóstico. Em cenários de alta sensibilidade, o limiar de probabilidade poderia ser reduzido (abaixo de 0,5) para capturar mais doentes, aceitando mais falsos positivos.

A Figura 5 apresenta a distribuição global: 86,20% de acertos (fatia azul, 256 registros) e 13,80% de erros (fatia vermelha, 41 registros) sobre todos os 297. O inset decomposta os 8 erros do teste em FN (6, vermelho) e FP (2, laranja), proporção 3:1 que confirma a assimetria típica do limiar padrão de 0,5.

5.4 Relatório de Classificação por Classe

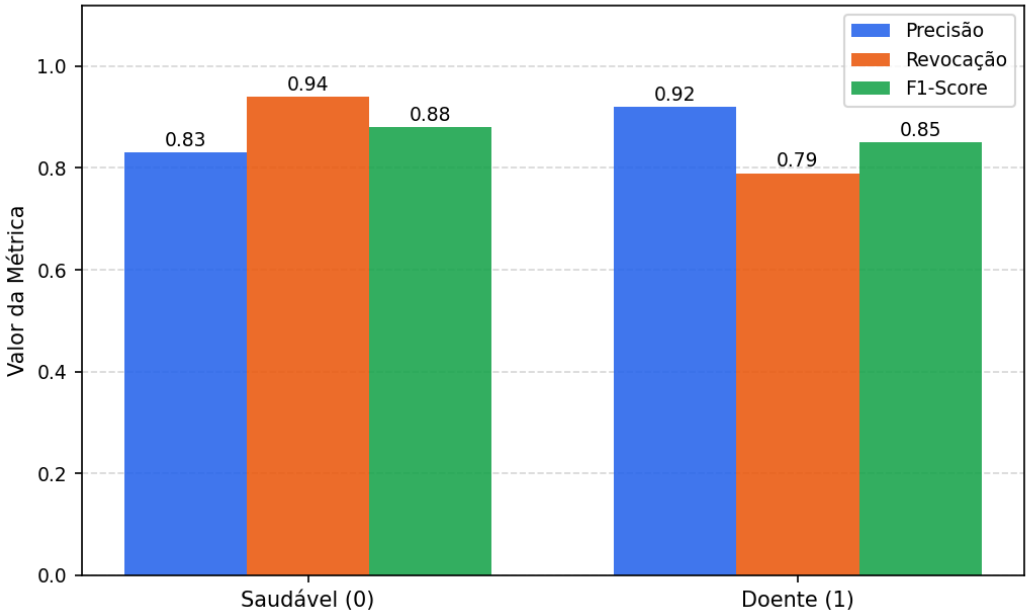
Tabela 10 – Métricas por Classe (Conjunto de Teste, n=60)

Classe	Precisão	Revocação	F1-Score	Suporte
Saudável (0)	0,83	0,94	0,88	32
Doente (1)	0,92	0,79	0,85	28
Acurácia			0,87	60
Média macro	0,88	0,86	0,86	60

Média pond.	0,87	0,87	0,87	60

Fonte: elaborado pelo autor (2026).

Figura 3 – Precisão, Revocação e F1-Score por Classe (Conjunto de Teste)



Leitura clínica da Tabela 10 e Figura 3: para a classe Saudável (0), precisão 0,83, revocação 0,94 e F1 0,88. A elevada revocação (94%) indica que o modelo detecta 30 dos 32 saudáveis corretamente, com apenas 2 falsos alarmes (FP). A precisão 0,83 reflete que entre todos os classificados como saudáveis, 6 eram doentes (FN).

Para a classe Doente (1): precisão 0,92, revocação 0,79, F1 0,85. A precisão 0,92 confirma que os alertas de doença emitidos pelo modelo são confiáveis em 92% dos casos. A revocação 0,79 é o ponto de atenção: 21% dos doentes não são detectados. Para aumentar a revocação, seria necessário reduzir o limiar de classificação abaixo de 0,5 — trade-off típico em triagem clínica que deve ser discutido no TCC.

As médias macro e ponderada próximas (0,86-0,87) indicam desempenho equilibrado entre as classes, favorecido pela proporção balanceada do dataset. A consistência entre a acurácia global (86,67%) e a média ponderada do F1 (0,87) confirma que as métricas são internamente coerentes.

6 Recomendações para o TCC

1. Use sempre GridSearchCV para selecionar C, kernel e gamma. Esse procedimento garante que os valores sejam justificados por dados, não por tentativa e erro.
2. Justifique o kernel RBF: a superioridade sobre o kernel linear (82,27% vs. 81,00%) evidencia não-linearidades no espaço de 13 atributos clínicos.
3. Justifique C=0,1 (forte regularização): o menor valor da grade sendo ótimo indica que o dataset se beneficia de margem ampla, compatível com a sobreposição clínica entre pacientes

limítrofes.

4. A normalização Z-score é obrigatória para o SVM. Calcule mu e sigma apenas sobre X_train e aplique ao X_test. Isso previne data leakage.
5. Métrica principal para o TCC: cross-val 10-fold = 83,51% ± 7,66%. Sempre reporte média ± desvio-padrão.
6. Variáveis mais relevantes na literatura (dataset Cleveland): cp (dor torácica), thal, ca, oldpeak, exang. Para interpretabilidade no SVM linear, os coeficientes de w indicam a importância de cada feature.

7 Resumo Executivo

```
Dataset         : UCI Heart Disease (Cleveland, id=45)
Registros       : 297 validos (303 originais - 6 ausentes)
Divisao         : 237 treino (80%) / 60 teste (20%), estratificada

Hiperparametros  : C=0.1, kernel=rbf, gamma=scale (GridSearchCV 5-fold)
Normalizacao     : StandardScaler (Z-score), ajustado apenas em X_train

DESEMPENHO:
  Acuracia - teste hold-out    : 86.67%  (52/60 acertos)
  Acuracia - cross-val 10-fold : 83.51% +/- 7.66%   <- METRICA PRINCIPAL
  Acuracia - todos os dados    : 86.20%  (256/297 acertos)

MATRIZ DE CONFUSAO (teste):
  VN=30  FP=2   (Saudaveis: 32 reais, 30 corretos)
  FN=6   VP=22  (Doentes  : 28 reais, 6 nao detectados)

POR CLASSE:
  Saudavel: Precisao=0.83  Recall=0.94  F1=0.88
  Doente  : Precisao=0.92  Recall=0.79  F1=0.85
  Acuracia global: 0.87

AVALIACAO: BOM - classifica bem a maioria dos casos.
          Usar como apoio ao diagnostico, nao substituto clinico.
```

8 Referências

BOSER, B. E.; GUYON, I. M.; VAPNIK, V. N. A training algorithm for optimal margin classifiers. In: Annual ACM Workshop on COLT, 5., 1992. DOI: 10.1145/130385.130401.

CORTES, C.; VAPNIK, V. Support-vector networks. Machine Learning, v. 20, n. 3, p. 273-297, 1995. DOI: 10.1007/BF00994018.

GÉRON, Aurélien. Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow. 2. ed. O'Reilly Media, 2019.

JANOSI, A. et al. Heart Disease Dataset. UCI Machine Learning Repository, 1988. Disponível em: https://archive.ics.uci.edu/dataset/45/heart+disease.

MIENYE, I. D.; SUN, Y. A Survey of Ensemble Learning. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. JMLR, v. 12, p. 2825-2830, 2011.

RUSSELL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4. ed. Pearson, 2020.