TÉCNICAS DE APRENDIZADO DE MÁQUINA: CARACTERÍSTICAS, APLICAÇÕES E ANÁLISE COMPARATIVA

André Felipe
Faculdade de Tecnologia de Guaratinguetá
andressmota78@gmail.com

Resumo

Este relatório apresenta um levantamento das principais técnicas de aprendizado de máquina supervisionado com ênfase em suas características matemáticas, aplicações documentadas na literatura e análise comparativa de pontos fortes e fracos. As técnicas abordadas incluem K-Nearest Neighbors (KNN), Regressão Logística, Support Vector Machine (SVM), Árvores de Decisão, Random Forest, métodos de Boosting (AdaBoost e XGBoost), Redes Neurais e Stacking. O referencial teórico é fundamentado em Géron (2019), Giraldi (2021) e no survey de Mienye e Sun (2022). Como estudo de caso prático, são apresentados os resultados do algoritmo KNN aplicado ao Cleveland Heart Disease Dataset: K = 29, acurácia de 86,67% no conjunto de teste e 82,86% ± 6,99% na validação cruzada de 10 dobras sobre 297 registros.

Palavras-chave: Aprendizado de Máquina; KNN; Random Forest; SVM; Ensemble Learning; Doença Cardíaca; Levantamento Bibliográfico.

Introdução

O aprendizado de máquina (AM) tornou-se uma das áreas mais prolíficas da ciência da computação, impulsionando avanços em diagnóstico médico, detecção de fraudes, processamento de linguagem natural e visão computacional. Géron (2019, p. 4) define AM como "a ciência (e a arte) de programar computadores para que eles possam aprender a partir de dados".

A relevância do AM para aplicações de saúde é notória: Mienye e Sun (2022) apresentam um panorama abrangente de aplicações de ensemble learning em diagnóstico médico, detecção de fraudes e análise de sentimentos, documentando resultados entre 93% e 100% de acurácia em datasets consagrados como o Cleveland Heart Disease Dataset.

Este relatório tem como objetivos: (i) apresentar a taxonomia do AM; (ii) caracterizar matematicamente as principais técnicas supervisionadas; (iii) levantar suas aplicações na literatura recente com base em Mienye e Sun (2022); (iv) identificar pontos fortes e fracos de cada abordagem; e (v) apresentar estudo de caso prático com o algoritmo KNN sobre o dataset de doença cardíaca de Cleveland.

1 Aprendizado de Máquina: Conceitos e Taxonomia

1.1 Definição

Arthur Samuel (1959, apud GÉRON, 2019, p. 4) definiu AM como o "campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados". Uma definição mais precisa e formal foi proposta por Tom Mitchell (1997, apud GÉRON, 2019, p. 4):

> "Um programa de computador se diz que aprende a partir da experiência E com respeito a alguma tarefa T e alguma medida de desempenho P, se sua performance em T, medida por P, melhora com a experiência E." (MITCHELL, 1997 apud GÉRON, 2019, p. 4)

No contexto de classificação de doença cardíaca: a tarefa T é classificar um paciente como saudável ou doente; a experiência E é o conjunto de treinamento com 237 registros históricos; e a medida P é a acurácia na validação cruzada 10-fold.

1.2 Taxonomia do Aprendizado de Máquina

Géron (2019) classifica os algoritmos de AM em três dimensões ortogonais. A primeira é o tipo de supervisão no treinamento: aprendizado supervisionado (o dataset inclui rótulos desejados, cobrindo classificação e regressão), não supervisionado (dados sem rótulo, cobrindo clustering e redução de dimensionalidade), semissupervisionado e por reforço (aprendizado por interação com ambiente via recompensas).

A segunda dimensão é a modalidade de aprendizado: batch learning (modelo treinado offline sobre todo o dataset de uma vez) versus online learning (atualização incremental com novos dados em pequenos lotes). A terceira dimensão é a forma de generalização: aprendizado baseado em instâncias (instance-based) versus baseado em modelos (model-based). O KNN é o exemplo canônico do primeiro tipo: generaliza memorizando exemplos de treinamento e comparando novos dados por similaridade, sem construir nenhuma função paramétrica explícita.

1.3 Pré-processamento de Dados

A qualidade do pré-processamento é determinante para o desempenho dos algoritmos de AM. Giraldi (2021) dedica o Capítulo 7 a processos essenciais: detecção de outliers (seções 7.1–7.2), agregação (7.3), amostragem (7.4), redução de dimensionalidade via PCA (7.5), seleção de atributos (7.6), discretização (7.7), medidas de similaridade (7.8) e normalização (7.9).

Na seção 7.8, Giraldi (2021, p. 88) formaliza as métricas de distância que sustentam algoritmos baseados em vizinhança como o KNN:

d_E(x,y) = SQRT(SUM_{j=1}^{d}(xj-yj)^2) [Euclidiana, eq. 7.19]

d_p(x,y) = (SUM_{j=1}^{d}|xj-yj|^p)^(1/p) [p-norm, eq. 7.20]

d_max(x,y) = max_j |xj-yj| [Chebyshev, eq. 7.21]

Na seção 7.9, Giraldi (2021, p. 90) formaliza a normalização como a transformação que mapeia o dataset D para o cubo unitário [0,1]^m, garantindo que todos os atributos operem na mesma escala métrica. O StandardScaler (padronização Z-score, media=0, sigma=1) é uma alternativa equivalente, adotada neste trabalho para os 13 atributos clínicos do Cleveland dataset.

Giraldi (2021, p. 83) alerta para a maldição da dimensionalidade: o número de amostras necessário para cobrir adequadamente o espaço de atributos cresce exponencialmente com o número de dimensões m, o que justifica seleção de atributos (seção 7.6) e redução de dimensionalidade antes de algoritmos baseados em distância.

2 Técnicas de Aprendizado de Máquina Supervisionado

2.1 K-Nearest Neighbors (KNN)

O KNN, proposto por Fix e Hodges (1951) e formalizado por Cover e Hart (1967), classifica uma nova amostra xq pela regra de votação majoritária entre seus K vizinhos mais próximos no espaço de atributos. Géron (2019, p. 10) destaca o KNN entre os algoritmos supervisionados mais importantes da AM moderna. Por não construir nenhuma função paramétrica durante o treinamento, é classificado como algoritmo lazy (instance-based).

Formalmente, dado o conjunto de treinamento D = {(x1,y1),...,(xn,yn)}, a predição é:

y_hat = argmax_c SUM_{i em N_K(xq)} 1[yi = c]

onde N_K(xq) denota os K vizinhos mais próximos de xq. Na classificação binária (c em {0,1}), a predição reduz-se a checar se a maioria dos K vizinhos pertence à classe Doente (1) ou Saudável (0).

O principal hiperparâmetro é K, que governa o equilíbrio viés-variância: K pequeno gera alta variância (overfitting); K grande aumenta o viés (underfitting). A seleção ótima é realizada via GridSearchCV + StratifiedKFold.

Pontos Fortes:

+ Interpretabilidade máxima: o raciocínio de qualquer predição é explicável.
+ Sem fase de treinamento: toda computação é diferida para a predição (lazy).
+ Fronteiras não lineares: adapta-se a distribuições complexas sem especificação.
+ Eficaz em datasets moderados com atributos bem padronizados.

Pontos Fracos:

- Custo de predição O(n*d): escala linearmente com o tamanho do dataset.
- Normalização obrigatória: atributos em escalas distintas distorcem distâncias (GIRALDI, 2021, p. 90).

- Maldição da dimensionalidade: desempenho degrada em espaços de alta dimensão.

- Algoritmo estável: bagging não melhora seu desempenho (MIENYE; SUN, 2022, p. 99136).

- Sensível a atributos irrelevantes, dados ruidosos e desbalanceamento de classes.

Estudo de Caso — Cleveland Heart Disease Dataset (este trabalho):

Com K = 29 (otimizado por GridSearchCV + StratifiedKFold 5-fold sobre K em {1,...,30}), o classificador obteve 86,67% de acurácia no conjunto de teste (hold-out 20%, 60 registros) e 82,86% ± 6,99% na validação cruzada de 10 dobras sobre 297 registros. O pré-processamento consistiu em remoção de valores ausentes (303→297 registros), binarização da variável alvo (5 classes→2) e padronização Z-score calculada exclusivamente sobre X_train para evitar data leakage.

Tabela 1 – Resultados do KNN (K=29) no Cleveland Heart Disease Dataset

Métrica	Valor
Acurácia — teste hold-out (20%, 60 registros)	86,67%
Acurácia — validação cruzada 10-fold (n=297)	82,86% ± 6,99%
Acurácia — conjunto completo (297 registros)	84,85%
F1-Score ponderado (conjunto de teste)	0,87
Verdadeiros Positivos / Falsos Negativos	22 VP / 6 FN
Verdadeiros Negativos / Falsos Positivos	30 VN / 2 FP

Fonte: elaborada pelo autor (2026).

> "k-nearest Neighbor (KNN) and naïve Bayes are examples of stable algorithms, and bagging does not perform well with these algorithms as base learners." (MIENYE; SUN, 2022, p. 99136)

2.2 Regressão Logística

A regressão logística modela a probabilidade posterior de classe por meio da função sigmoide aplicada a uma combinação linear dos atributos. Géron (2019, p. 10) a classifica entre os algoritmos supervisionados mais utilizados. Para classificação binária (c em {0,1}), o modelo estima:

$P(y=1|x) = sigma(w^T x + b) = 1 / (1 + exp(-(w^T x + b)))$

O treinamento minimiza a função de perda de entropia cruzada (log-loss) pelo gradiente descendente. A regressão logística é interpretável (coeficientes indicam o peso de cada atributo), eficiente computacionalmente e amplamente utilizada como baseline em estudos comparativos de classificação médica.

Pontos Fortes / Fracos:

+ Interpretabilidade: coeficientes indicam direção e magnitude de cada atributo.

+ Eficiência computacional: treinamento rápido, escala bem com grandes datasets.

+ Probabilidade calibrada: retorna P(y=1|x), útil para triagem clínica com limiares.

- Fronteiras lineares: não captura padrões não lineares sem engenharia de atributos.

- Sensível a outliers: amostras mal classificadas penalizam fortemente a função de perda.

- Multicolinearidade: desempenho reduzido quando atributos são correlacionados.

2.3 Support Vector Machine (SVM)

O SVM busca o hiperplano de máxima margem que separa as classes no espaço de atributos. Géron (2019, p. 10) cita o SVM entre os mais importantes algoritmos supervisionados. O problema de otimização primal para o caso linearmente separável é:

minimizar (1/2)||w||^2 sujeito a yi(w^T xi + b) >= 1, i=1,...,n

O kernel trick permite ao SVM aprender fronteiras não lineares mapeando os dados implicitamente para um espaço de alta dimensão sem calculá-lo explicitamente. Kernels comuns incluem RBF (radial basis function), polinomial e sigmoide. A versão soft-margin introduz variáveis de folga e o parâmetro C para tolerar sobreposição de classes.

Mienye e Sun (2022) documentam resultados expressivos com SVM em ensembles: Mienye e Sun (2022, p. 99138) relatam que um classificador heterogêneo combinando SVM, KNN e Random Forest com votação ponderada (WAV) alcançou 100% de acurácia no Cleveland Heart Disease Dataset, superando os três componentes individualmente.

Pontos Fortes / Fracos:

+ Margem máxima: robusto contra overfitting em espaços de alta dimensão.

+ Kernel trick: fronteiras não lineares sem aumento explícito de dimensionalidade.

+ Esparsidade: solução depende apenas dos vetores de suporte.

- Escalabilidade: custo de treinamento O(n^2)–O(n^3) limita aplicação em datasets grandes.

- Seleção de hiperparâmetros: C, gamma e tipo de kernel requerem busca por CV.

- Interpretabilidade: difícil extrair regras compreensíveis do modelo treinado.

2.4 Árvores de Decisão

Árvores de decisão particionam recursivamente o espaço de atributos em regiões homogêneas usando regras if-then-else baseadas em critérios de impureza (Índice de Gini ou Entropia de Informação). O resultado é uma estrutura hierárquica diretamente interpretável por especialistas no domínio.

Mienye e Sun (2022, p. 99136) classificam as árvores de decisão como algoritmos instáveis: pequenas perturbações nos dados de treinamento podem produzir árvores completamente diferentes. Essa propriedade é a motivação central do Random Forest:

> "An example of an unstable algorithm is the decision tree; hence, bagged decision trees usually perform better than the single decision tree." (MIENYE; SUN, 2022, p. 99136)

Pontos Fortes / Fracos:

+ Interpretabilidade: a árvore visualizada é compreensível por não especialistas.
+ Sem normalização: invariante a transformações monotônicas dos atributos.
+ Atributos heterogêneos: lida nativamente com numéricos e categóricos.
- Alta variância: instável — pequenas mudanças nos dados geram árvores muito diferentes.
- Overfitting: árvores profundas memorizam o treinamento; podas obrigatórias.
- Fronteiras angulares: partições paralelas aos eixos limitam a expressividade.

2.5 Random Forest

O Random Forest, desenvolvido por Ho (1995) e estendido por Breiman (2001), aplica bagging a múltiplas árvores de decisão treinadas em subamostras bootstrapped, combinando suas predições por votação majoritária. Adicionalmente, usa aleatoriedade de atributos (random subspace method) para reduzir a correlação entre as árvores. A predição final é dada por (MIENYE; SUN, 2022):

H_T(x) = argmax_j SUM_{k=1}^{T} 1[h_k(x) = j], j em {0,1,...,C}

O Random Forest é amplamente reconhecido como o algoritmo de escolha padrão para dados tabulares quando desempenho é o critério primário. Gao et al. (2021) obtiveram 98,6% de acurácia com Random Forest + PCA/LDA no Cleveland Heart Disease Dataset, demonstrando sua superioridade sobre KNN individual.

Pontos Fortes / Fracos:

+ Robustez a overfitting: bagging reduz variância sem aumentar o viés.
+ Importância de atributos: ranking nativo de features para análise diagnóstica.
+ Sem normalização: invariante a escala de atributos.
+ Alta acurácia: 98,6% no Cleveland dataset vs. 86,67% do KNN (GAO et al., 2021).
- Caixa-preta: conjunto de centenas de árvores é difícil de interpretar.
- Custo de memória e predição: proporcional a T (número de árvores).
- Menos eficaz com dados esparsos de alta dimensão (texto).

2.6 Métodos de Boosting: AdaBoost e XGBoost

Boosting é uma meta-técnica que combina aprendizes fracos sequencialmente, cada um corrigindo os erros do anterior. Mienye e Sun (2022) classificam o boosting entre as técnicas de ensemble de maior sucesso em aplicações reais.

AdaBoost (Adaptive Boosting):

Desenvolvido por Freund e Schapire (1995), o AdaBoost treina T classificadores sequencialmente ajustando os pesos das amostras mal classificadas. O classificador final é a combinação ponderada (MIENYE; SUN, 2022):

*H(x) = sign(SUM_{t=1}^{T} alpha_t * h_t(x))*

Mienye e Sun (2022, p. 99139) documentam que o AdaBoost atingiu 99,3% de acurácia na detecção de COVID-19, superando CNN ensemble (97,2%) no mesmo experimento. Também obteve 99,9% na classificação de hipertensão + diabetes tipo 2 (Fitriyani et al., apud MIENYE; SUN, 2022).

XGBoost (Extreme Gradient Boosting):

O XGBoost realiza gradient boosting com regularização L1/L2, tratamento eficiente de valores ausentes e otimizações computacionais que o tornam significativamente mais rápido que boosting tradicional. É o algoritmo dominante em competições de ML com dados tabulares. Mienye e Sun (2022) documentam 95,6% de acurácia com XGBoost + SMOTE-ENN + RFE no Cleveland Heart Disease Dataset.

Pontos Fortes / Fracos (Boosting):

+ Reduz viés e variância simultaneamente pela combinação sequencial.
+ Estado da arte em dados tabulares: dominante em competições como Kaggle.
+ AdaBoost: aceita qualquer algoritmo como base learner, flexibilidade máxima.
- Sensível a ruído: amostras ruidosas acumulam pesos crescentes, causando overfitting.
- Treinamento sequencial: não paralelizável como bagging (Random Forest).
- Hiperparâmetros: taxa de aprendizado, n_estimators, max_depth requerem ajuste fino.

2.7 Redes Neurais e Deep Learning

Redes neurais artificiais são modelos compostos por camadas de neurônios que aplicam transformações lineares seguidas de funções de ativação não lineares (ReLU, sigmoid, tanh). Géron (2019, p. 10) lista Neural Networks entre os principais algoritmos supervisionados. Redes profundas (deep learning) com múltiplas camadas ocultas aprendem representações hierárquicas de alta expressividade — de bordas em imagens a conceitos semânticos em texto.

Mienye e Sun (2022) documentam múltiplas aplicações de deep learning em ensemble: An et al. propuseram combinação de dois Sparse Autoencoders (SAE) para aprendizado de features com uma Deep Belief Network (DBN) como meta-classificador para detecção de Alzheimer, alcançando 4% de acurácia superior a seis algoritmos ensemble clássicos. Mohammed et al. utilizaram ensemble de CNNs (RNN + GRU + LSTM) para detecção de COVID-19 com 97,2% de acurácia.

Pontos Fortes / Fracos:

+ Expressividade universal: teoricamente aproxima qualquer função contínua.
+ Estado da arte em dados não estruturados: imagem, áudio, texto.
+ Aprendizado de representação automático: sem engenharia manual de atributos.
- Requer grandes volumes de dados para generalizar sem overfitting.
- Alto custo computacional: treinamento exige GPU/TPU e horas a dias.
- Caixa-preta: interpretabilidade muito limitada, problema crítico em aplicações médicas.
- Muitos hiperparâmetros: arquitetura, otimizador, regularização requerem expertise.

2.8 Stacking (Empilhamento)

O stacking (Wolpert, 1992) treina um meta-modelo para combinar as predições de múltiplos modelos base. Diferentemente do bagging (diversidade de dados, mesmo algoritmo) e do boosting (correção sequencial de erros), o stacking usa algoritmos distintos como base learners, explorando diversidade algorítmica (MIENYE; SUN, 2022).

O processo compreende três etapas: (1) treinamento dos modelos base com os dados de treinamento; (2) uso das predições dos base learners como features de um novo dataset; (3) treinamento do meta-modelo sobre este novo dataset. Modelos simples como regressão logística são tipicamente usados como meta-learner para evitar overfitting.

Mienye e Sun (2022) identificam o stacking como o método dominante em análise de sentimentos (NLP) por explorar diferentes capacidades de modelos de linguagem (LSTM, BERT, BiLSTM, Text-CNN), cada um capturando aspectos semânticos distintos.

Pontos Fortes / Fracos:

+ Diversidade algorítmica: combina os pontos fortes de algoritmos distintos.
+ Desempenho: frequentemente supera qualquer modelo base individualmente.
+ Generalidade: aplicável a qualquer combinação de base learners.
- Complexidade de treinamento e manutenção de múltiplos modelos.
- Custo computacional: todos os base learners treinados sobre o dataset completo.
- Risco de data leakage: requer cross-validation cuidadosa na criação do meta-dataset.

3 Levantamento de Aplicações na Literatura

Mienye e Sun (2022) apresentam um survey abrangente de 21 páginas sobre aplicações de ensemble learning na literatura recente. Esta seção sintetiza os principais resultados por domínio de aplicação.

3.1 Diagnóstico Médico

A aplicação de AM em diagnóstico médico é um dos campos mais ativos, impulsionado pela disponibilidade de bases de dados clínicas e pelo impacto direto na qualidade de

vida. A Tabela 2 resume os trabalhos documentados por Mienye e Sun (2022):

Tabela 2 – Aplicações de ML em Diagnóstico Médico (levantamento: MIENYE; SUN, 2022)

Aplicação	Técnica / Ensemble	Acurácia
Doença cardíaca (Cleveland)	SVM + KNN + RF, votação ponderada (WAV)	100%
Doença cardíaca (este trabalho)	KNN K=29, 10-fold CV	86,67% / 82,86%
Hipertensão + Diabetes tipo 2	XGBoost + SMOTE-Tomek	99,9%
COVID-19 (detecção)	AdaBoost	99,3%
COVID-19 (detecção)	Ensemble CNN: RNN + GRU + LSTM	97,2%
Alzheimer	SAE + DBN (deep ensemble)	+4% vs. baselines
Hepatite	Random Forest + RFE	95,4%
Doença cardíaca (XGBoost)	XGBoost + SMOTE-ENN + RFE	95,6%

Fonte: adaptado de MIENYE; SUN (2022, p. 99137-99140).

3.2 Detecção de Fraudes Financeiras

Mienye e Sun (2022, p. 99140-99142) documentam diversas aplicações de ensemble em detecção de fraudes em cartões de crédito e transações financeiras:

• Xie et al. propuseram sistema integrando algoritmo KNN com ensemble heterogêneo para tratar desbalanceamento de classes no European credit card dataset, obtendo excelente performance em classificação de transações fraudulentas.

• Forough e Momtazi aplicaram Deep Recurrent Neural Network (DRNN) com votação ANN-based, atingindo precisão de 92,9% no dataset de portadores de cartão europeus.

• Ileberi et al. empregaram AdaBoost com cinco base learners alternativos (Árvore de Decisão, Regressão Logística, SVM, XGBoost, Random Forest), demonstrando que o ensemble AdaBoost supera consistentemente cada algoritmo usado individualmente.

3.3 Análise de Sentimentos (NLP)

Mienye e Sun (2022, p. 99142-99145) identificam o stacking como a técnica dominante em análise de sentimentos. A diversidade algorítmica entre modelos de linguagem (LSTM, BERT, BiLSTM, Text-CNN, R-CNN, FFNN) permite que cada componente capture aspectos semânticos distintos do texto, resultando em generalização superior:

• Chen et al. aplicaram stacking sobre 6 modelos de deep learning para avaliar grau de humor em titulares de notícias (SemEval-2020), concluindo que o ensemble superou todos os modelos individuais.

• Lin et al. propuseram ensemble baseado em BERT para detecção de notícias falsas, obtendo 87,8% de acurácia com feature extraction via N-gram + stacked autoencoder seguido de SVM, Árvore de Decisão, KNN e Random Forest.

4 Análise Comparativa das Técnicas

A Tabela 3 apresenta uma síntese comparativa das técnicas de AM discutidas, consolidando informações de Géron (2019), Giraldi (2021) e Mienye e Sun (2022):

Tabela 3 – Comparativo das técnicas de AM supervisionado

Algoritmo	Treino	Predição	Normaliz.	Interpret.
KNN	O(1)	O(n*d)	Obrigatória	Alta
Reg. Logística	O(n*d*iter)	O(d)	Recomendada	Alta
SVM	O(n^2)~O(n^3)	O(sv*d)	Obrigatória	Baixa
Árvore Decisão	O(n*d*log n)	O(profun)	Não req.	Alta
Random Forest	O(T*n*d*log n)	O(T*d)	Não req.	Média
AdaBoost	O(T*n*d)	O(T*d)	Recomendada	Baixa
XGBoost	O(T*n*d)	O(T*d)	Não req.	Baixa
Redes Neurais	Muito alto	O(d*L)	Obrigatória	Mínima
Stacking	Muito alto	Médio	Depende	Mínima

Fonte: elaborado com base em GÉRON (2019), GIRALDI (2021) e MIENYE; SUN (2022). T = número de estimadores; n = amostras; d = dimensões; L = camadas.

A observação de Mienye e Sun (2022) sobre algoritmos estáveis vs. instáveis é fundamental para a seleção de técnicas de ensemble: o bagging é eficaz apenas com algoritmos de alta variância (como árvores de decisão instáveis), sendo ineficiente com KNN e Naïve Bayes. O boosting, por sua vez, é agnóstico a essa propriedade, pois reduz viés em vez de variância — funcionando bem com qualquer base learner.

A Tabela 4 apresenta os resultados comparativos das técnicas no Cleveland Heart Disease Dataset, conforme documentado na literatura:

Tabela 4 – Comparativo de desempenho no Cleveland Heart Disease Dataset

Referência / Técnica	Algoritmo	Acurácia
Este trabalho	KNN (K=29, CV-10)	82,86% / 86,67%
GAO et al. (2021)	Random Forest + PCA/LDA	98,6%
MIENYE; SUN (2022)	XGBoost + SMOTE-ENN + RFE	95,6%
MIENYE et al. (2020)	WAE + CART (ensemble)	93,0%
VELUSAMY; RAMASAMY (2021)	Ensemble SVM+KNN+RF (WAV)	100%

Fonte: MIENYE; SUN (2022) e este trabalho.

O KNN com K = 29 obtém desempenho competitivo como baseline não paramétrico (86,67%), sendo superado por Random Forest (98,6%), XGBoost (95,6%) e pelo ensemble heterogêneo SVM+KNN+RF (100%). Essa progressão documenta empiricamente a afirmação de Mienye e Sun (2022, p. 99129):

> "Ensemble classifiers are more robust and perform better than the individual ensemble learners." (MIENYE; SUN, 2022, p. 99129)

Considerações Finais

Este relatório apresentou um levantamento das principais técnicas de aprendizado de máquina supervisionado, fundamentado em Géron (2019), Giraldi (2021) e Mienye e Sun (2022). Os principais achados são:

1. O KNN é o algoritmo de referência canônico em AM baseado em instâncias: simples, interpretável e eficaz para datasets moderados após normalização (86,67% no Cleveland Heart Disease Dataset). Sua principal limitação é o custo de predição O(n*d) e a ineficácia do bagging como técnica de ensemble.

2. Random Forest e XGBoost consistentemente superam o KNN em acurácia em dados tabulares (98,6% e 95,6% no mesmo dataset), sendo as escolhas padrão quando desempenho máximo é o critério principal.

3. Métodos ensemble heterogêneos (SVM + KNN + RF) exploram a diversidade de erros entre classificadores distintos, alcançando 100% de acurácia no Cleveland dataset. A combinação do KNN com outros classificadores é mais valiosa que seu uso isolado.

4. O pré-processamento é determinante: normalização é obrigatória para KNN e SVM (Giraldi, 2021, p. 90); a maldição da dimensionalidade (Giraldi, 2021, p. 83) justifica seleção de atributos antes de algoritmos baseados em distância.

5. A escolha da técnica deve ser guiada pelos requisitos: interpretabilidade (KNN, Reg. Logística, Árvores de Decisão), desempenho máximo em dados tabulares (Random Forest, XGBoost, Stacking), ou dados não estruturados de alta dimensão (Redes Neurais profundas).

6. Como trabalho futuro, recomenda-se comparar formalmente KNN, Random Forest e XGBoost sobre o mesmo protocolo experimental (estratificação, normalização, CV-10) e investigar a aplicação de técnicas de balanceamento (SMOTE) para melhorar a revocação da classe Doente.

Referências

COVER, T. M.; HART, P. E. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, v. 13, n. 1, p. 21-27, 1967. DOI: 10.1109/TIT.1967.1053964.

FIX, E.; HODGES, J. L. Discriminatory Analysis: Nonparametric Discrimination, Consistency Properties. USAF School of Aviation Medicine, Randolph Field, Texas. Technical Report n. 4, 1951.

GÉRON, Aurélien. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow:

Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol, CA: O'Reilly Media, 2019.

GIRALDI, Gilson Antonio. Machine Learning and Pattern Recognition. Notas de Aula do Programa de Pós-Graduação. Petrópolis, RJ: UFRJ, 2021.

JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. Heart Disease Dataset. UCI Machine Learning Repository, 1988. Disponível em: https://archive.ics.uci.edu/dataset/45/heart+disease. Acesso em: mar. 2026.

MIENYE, I. D.; SUN, Y. A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, v. 10, p. 99129-99149, 2022. DOI: 10.1109/ACCESS.2022.3207287.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html. Acesso em: mar. 2026.